AI IN DE KLAS

SCHOOLLEIDERS AAN ZET

Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

Introductie

- **Robbe Wulgaert**
- **Leerkracht Sint-Lievenscollege Gent**
- **Programmeren en AI**
- **CNO aan de UA**
- **Onderzoek**



⊞ Gentse leerkracht ontwierp mee baanbrekend AI-model om Latijnse teksten te analyseren

Robbe Wulgaert. © Elke Pannier

Yumi Demeyere

23 juli 2025 om 16:59

Delen

Materiaal

- robbewulgaert.be/schoolleiders
- Password: CNO

- Tip: schrijven is efficiënter
- Hand-outs



Rode Draad

- Kennis in tijden van AI
- AI-geletterdheid
  - AI-technologie als onderwerp
  - AI-technologie als ondersteuning
- AI-beleid

VASTSTELLING

2 PERSPECTIEVEN
OESO COMPETENTIES

WAT NU?

AI IN DE KLAS

Deel 1: Kennis in tijden van AI

Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

AI in ons leven (GESPREK)

- **Afgelopen uren …**

- **Maakte je gebruik van AI-technologie?**

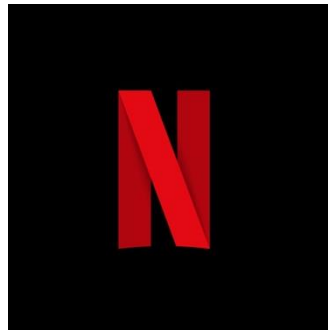
Een leven zonder …







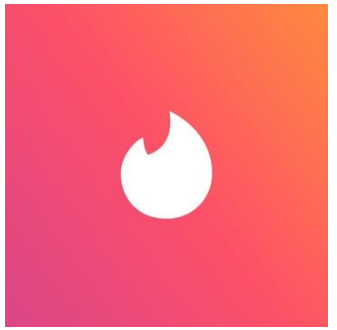














AI in ons ~~leven~~ onderwijs!







Hoe liep het op uw school? (GESPREK)

- **Afgelopen schooljaar …**

- **Maakten leerlingen gebruik van AI en dit was toegelaten.**
- **Maakten leerlingen gebruik van AI en dit was NIET toegelaten.**
- **Zijn er reeds afspraken? (school / vakgroep / docent)**

Prediction learning (OPDRACHT)

- Voorspellen en daarna corrigeren
- Noteer naast deze slide jouw voorspelling
- Leerlingen (12-18 jaar)
- Studenten (18-24 jaar)
- Leerkrachten

Secundair onderwijs 2023

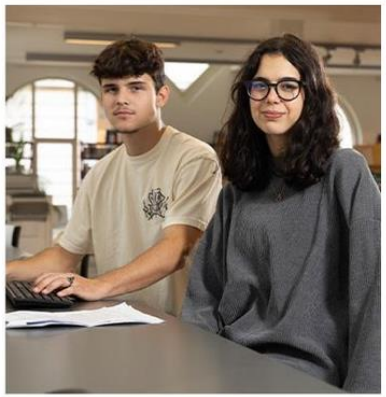
- Grote bevraging (12-18 jaar)
- April 2023 (N=10.862)
- 45% gebruikt AI
- 12% is een dagelijkse gebruiker



Zo vaak maken tieners huiswerk met AI: “Een beginnende leerkracht? Die ziet dat gewoon niet”

Oktober 2024







Tieners die handig zijn met de artificiële intelligentie van ChatGPT kunnen veel werk overlaten aan de computer.

Borgerhout. “Ik ben het beginnen te gebruiken toen ChatGPT vorig jaar in het nieuws kwam. Ik dacht: ‘Foert, ik neem eens het risico en laat AI een taak maken in plaats van er werk in te steken.’ En ik haalde tien op tien.”

> **“Als ik de volgende dag een toets heb en ik heb niets geleerd of niets samengevat, dan vraag ik AI om mijn cursus snel en simpel samen te vatten”**

Secundair onderwijs 2026

- Grote bevraging (12-18 jaar)
- April 2026 (N=20.000)
- +50% gebruikt AI wekelijks
- 1/7 jongeren voor alles!
  - 20% bij jongens!



Adolescenten

- **Publicatie 2023**
- **Gewoontegebruikers GenAI leeftijd 18-24:**
  - **42% gemiddeld**
  - **49% studenten**

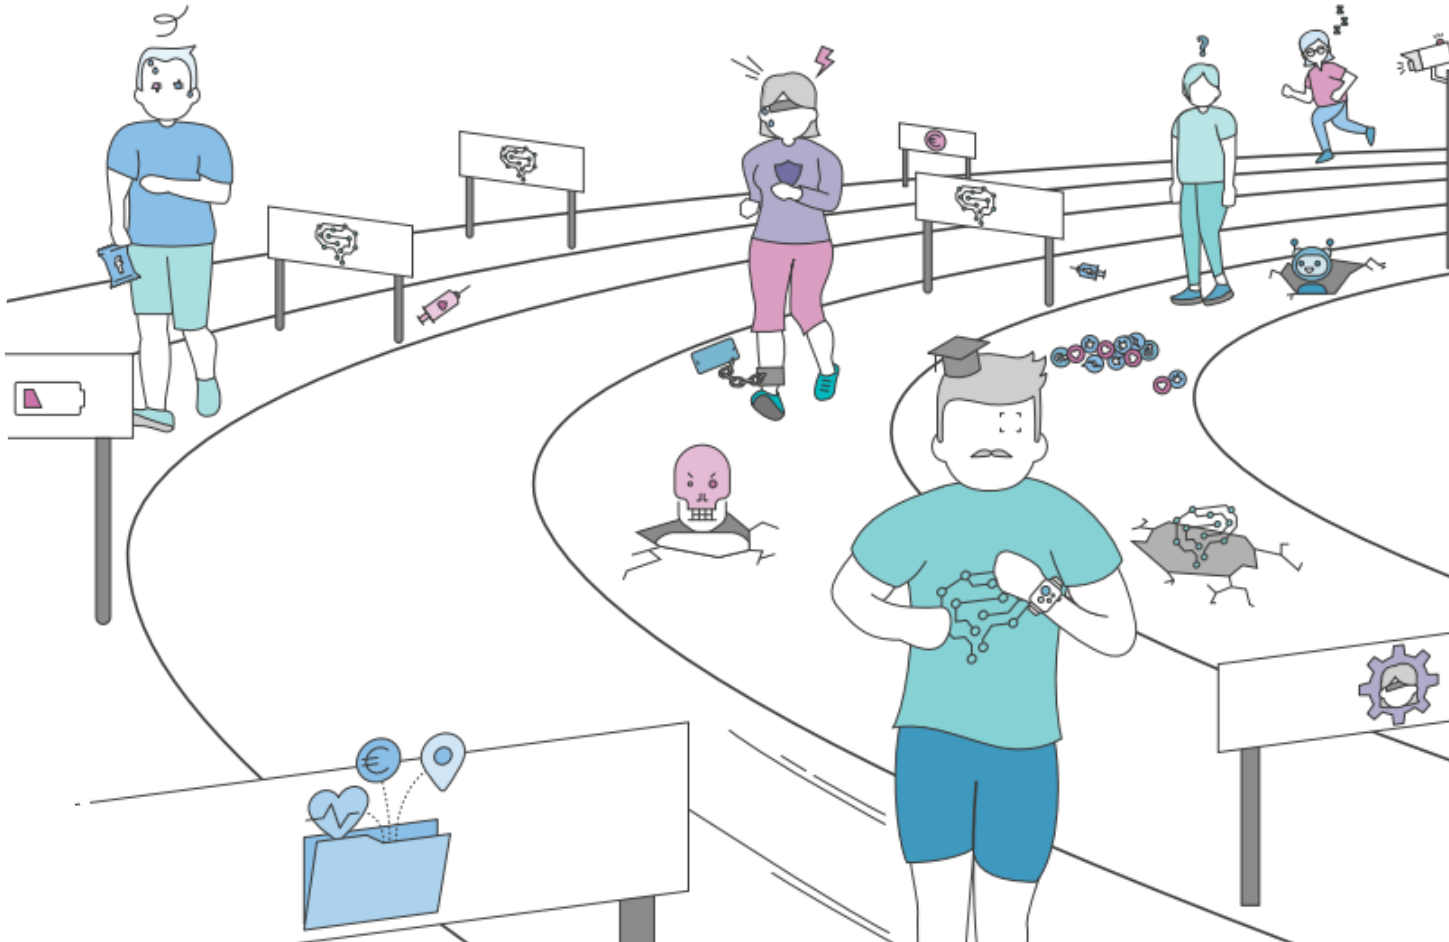


imec.digimeter 2024

Digitale trends in Vlaanderen

Adolescenten

- **Publicatie 2024**
- **Gewoontegebruikers GenAI leeftijd 18-24:**
  - **68% gemiddeld (+26%)**
  - **72% studenten (+23%)**



Adolescenten

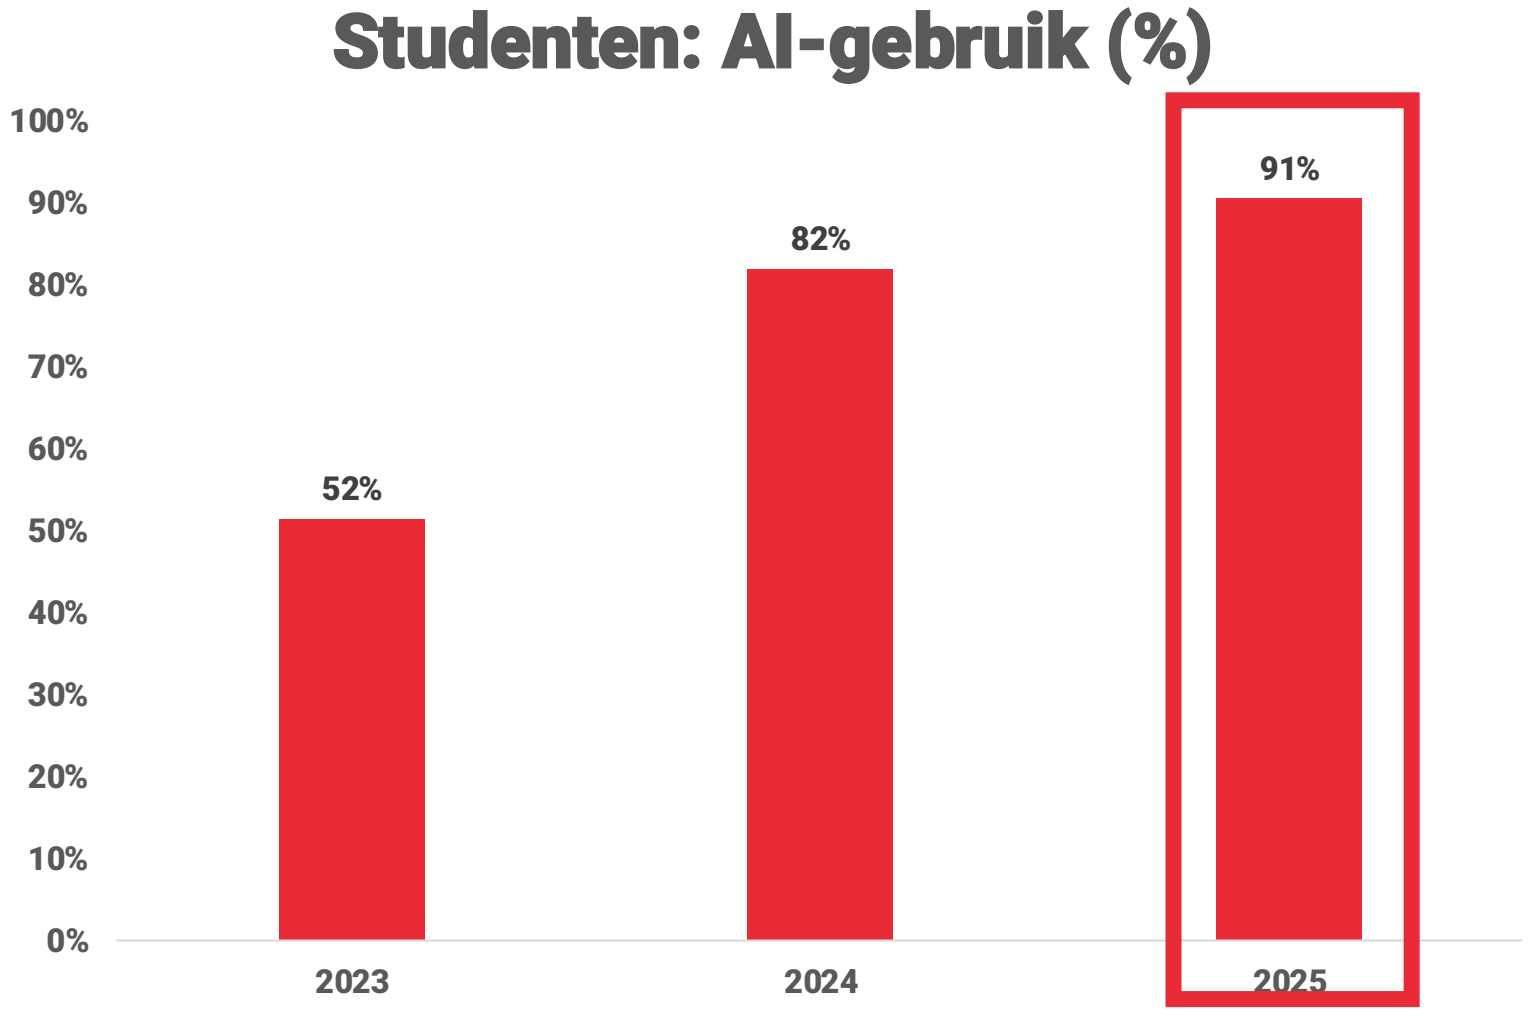
imec.digimeter 2025

Digitale trends in Vlaanderen

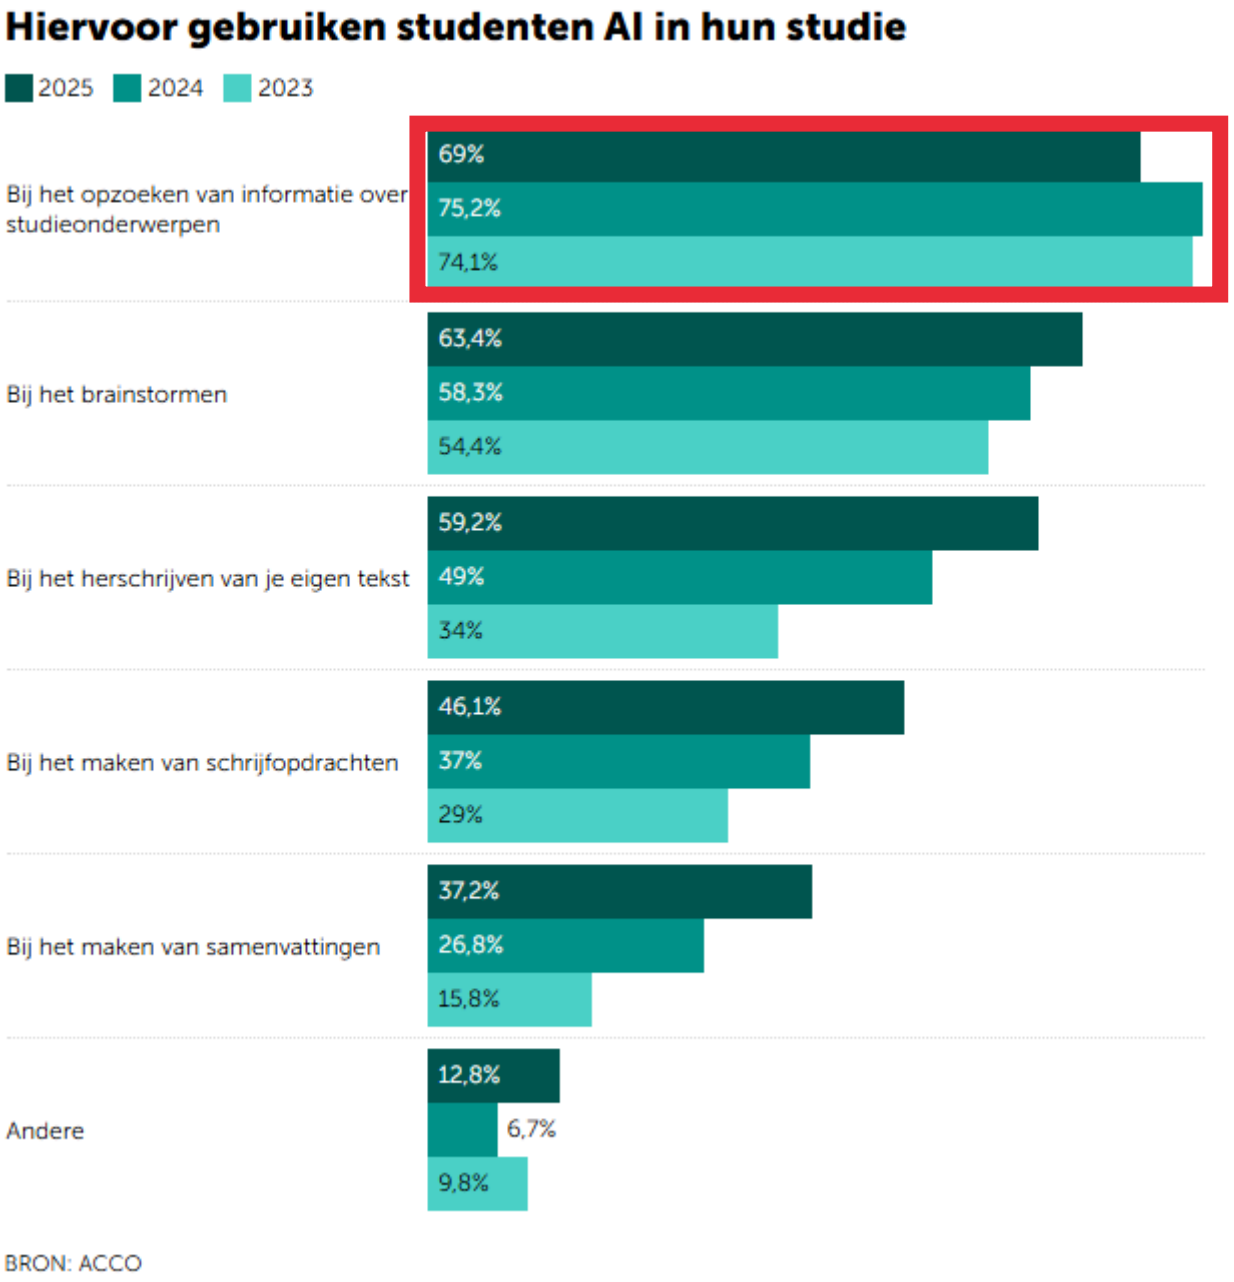
- **Publicatie 2025**
- **Gewoontegebruikers GenAI leeftijd 18-24:**
  - **75% gemiddeld (+7%)**
  - **81% studenten (+9%)**



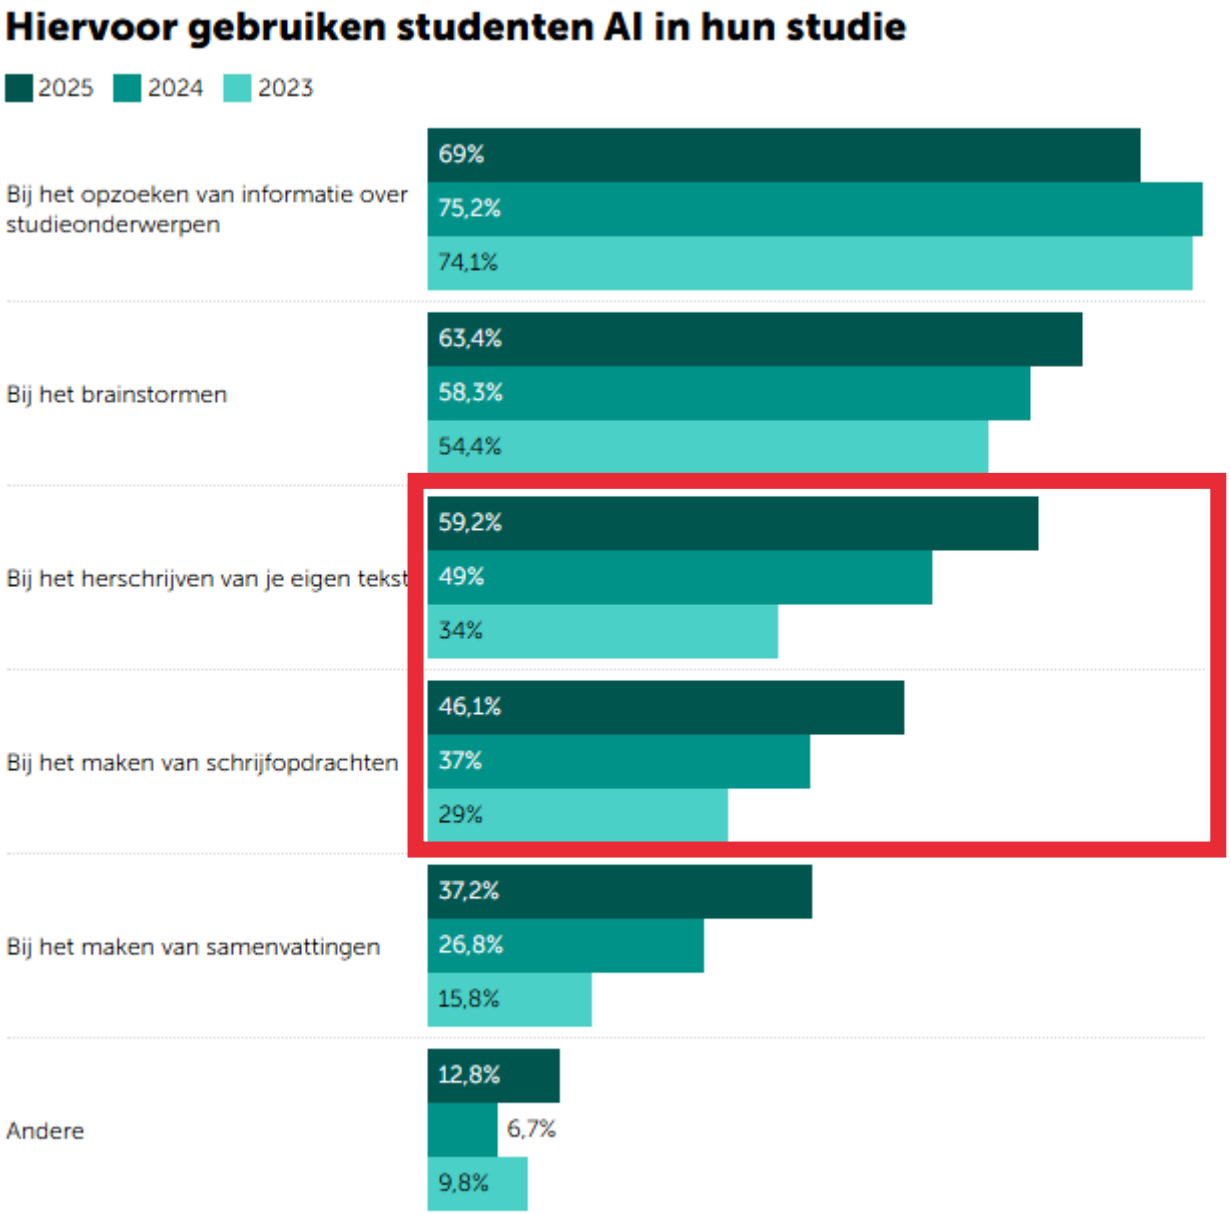
Adolescenten - ACCO



Soort gebruik?



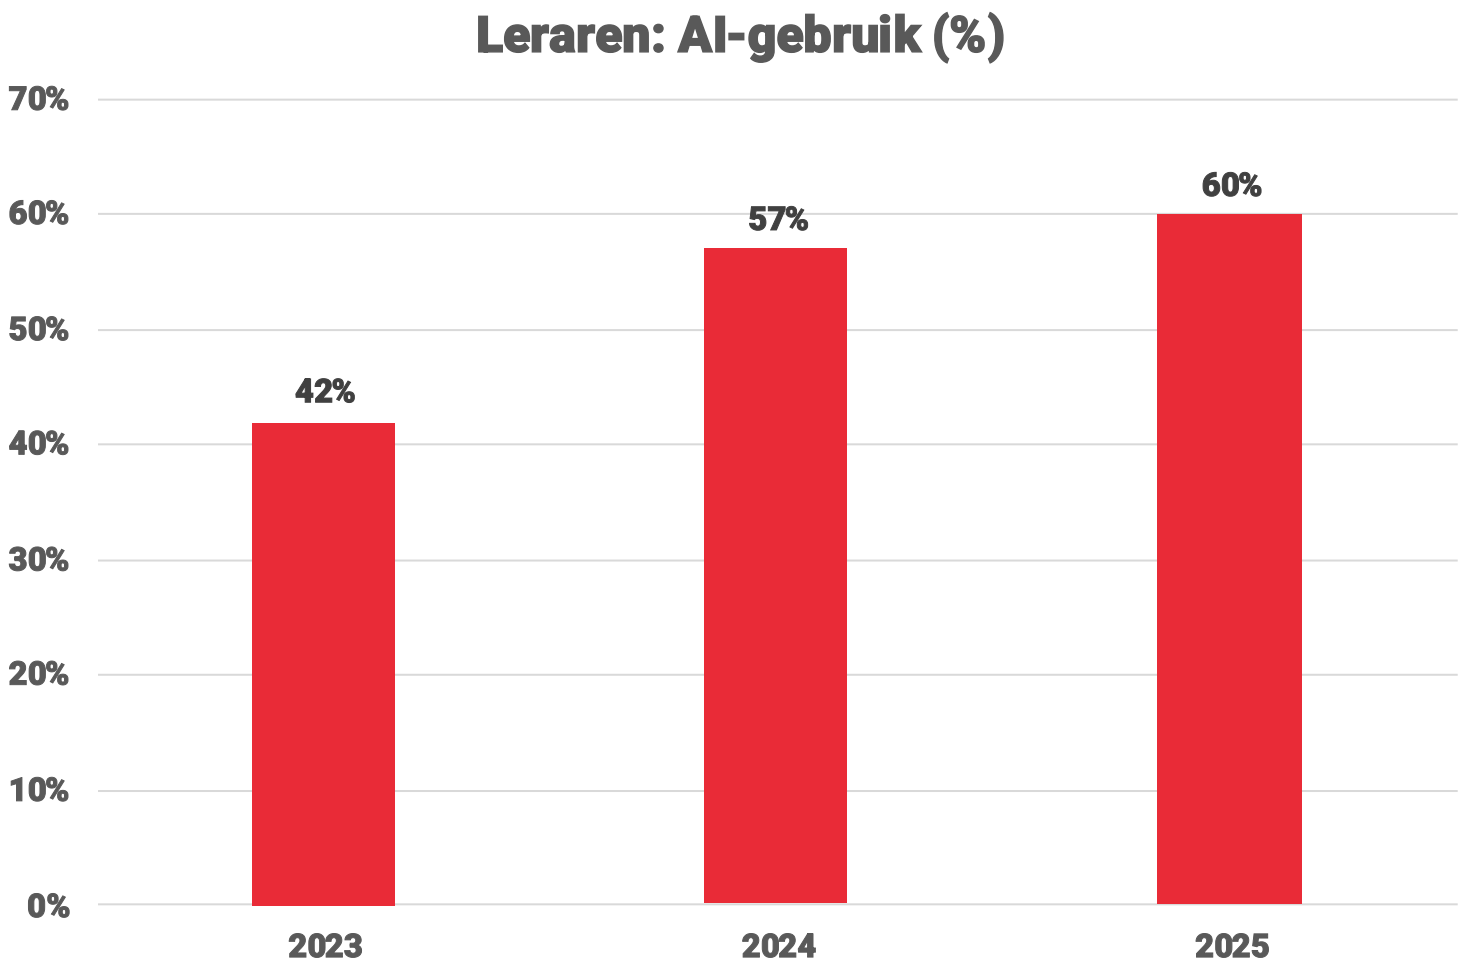
Soort gebruik?



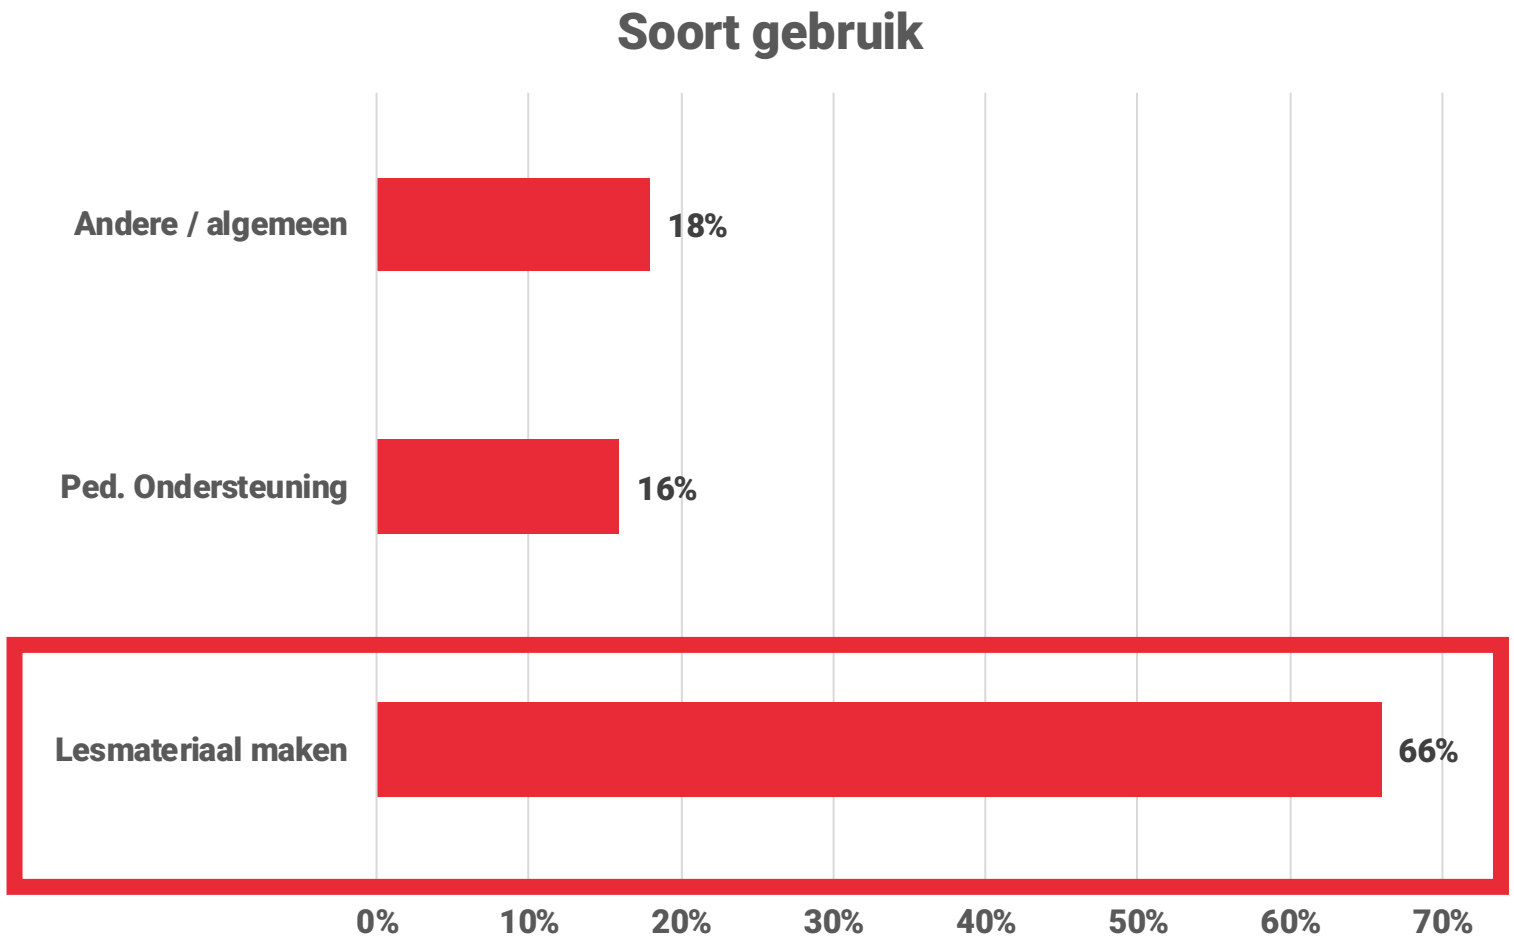
BRON: ACCO

Leerkrachten

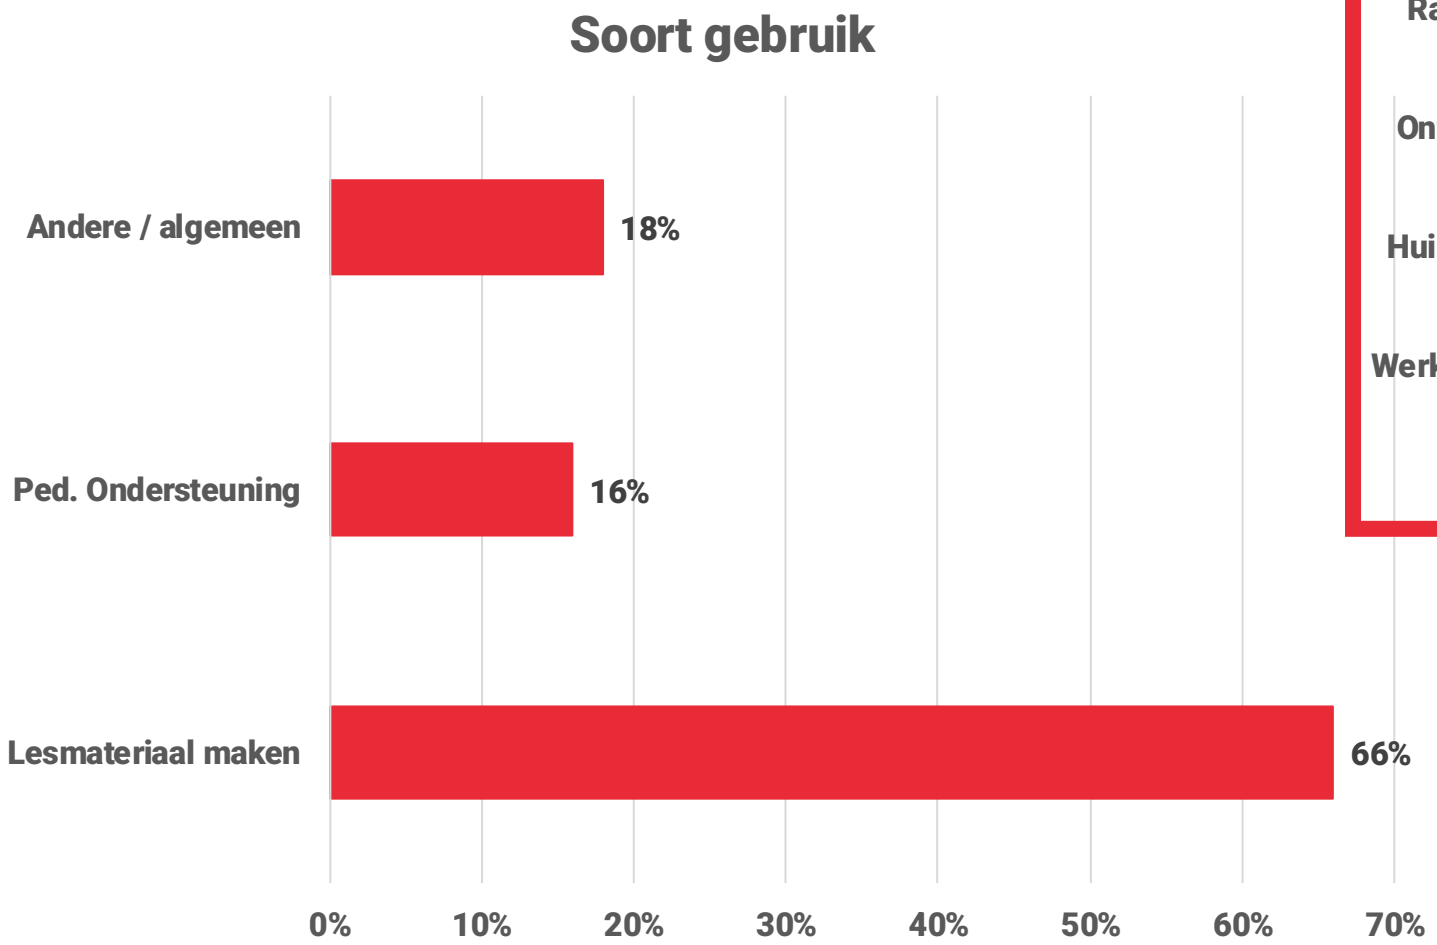
- Cijfers uit de UK
- Teacher Tapp
- EEF Evaluation Report
- 2023: 42%
- 2024: 57%
- 2025: 60%

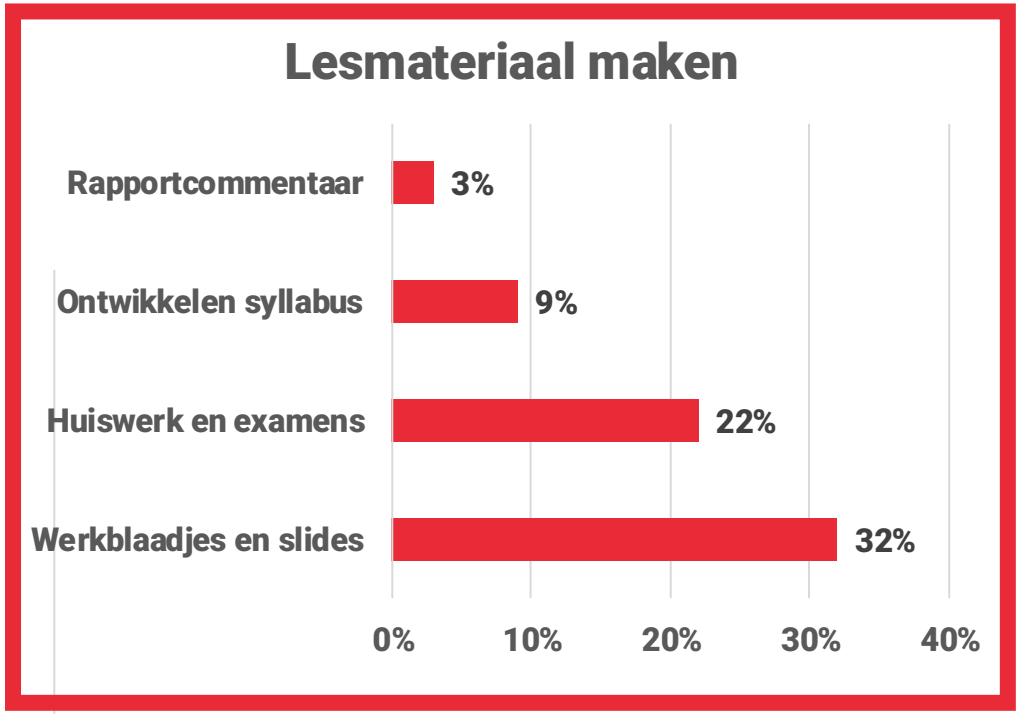


Leerkrachten



Leerkrachten





Hoe liep het op uw school? (GESPREK)

- **Afgelopen schooljaar …**

- **Maakte een LK gebruik van AI voor het ontwerp van lesmateriaal (bv. een toets, taak, opdracht)**
- **Maakte een LK een volledige les met een AI-tool.**
- **Maakte een student/stagiair een volledige les met een AI-tool.**

AI IN DE KLAS

Deel 1.1: Kennis opbouwen doen we zo!

Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

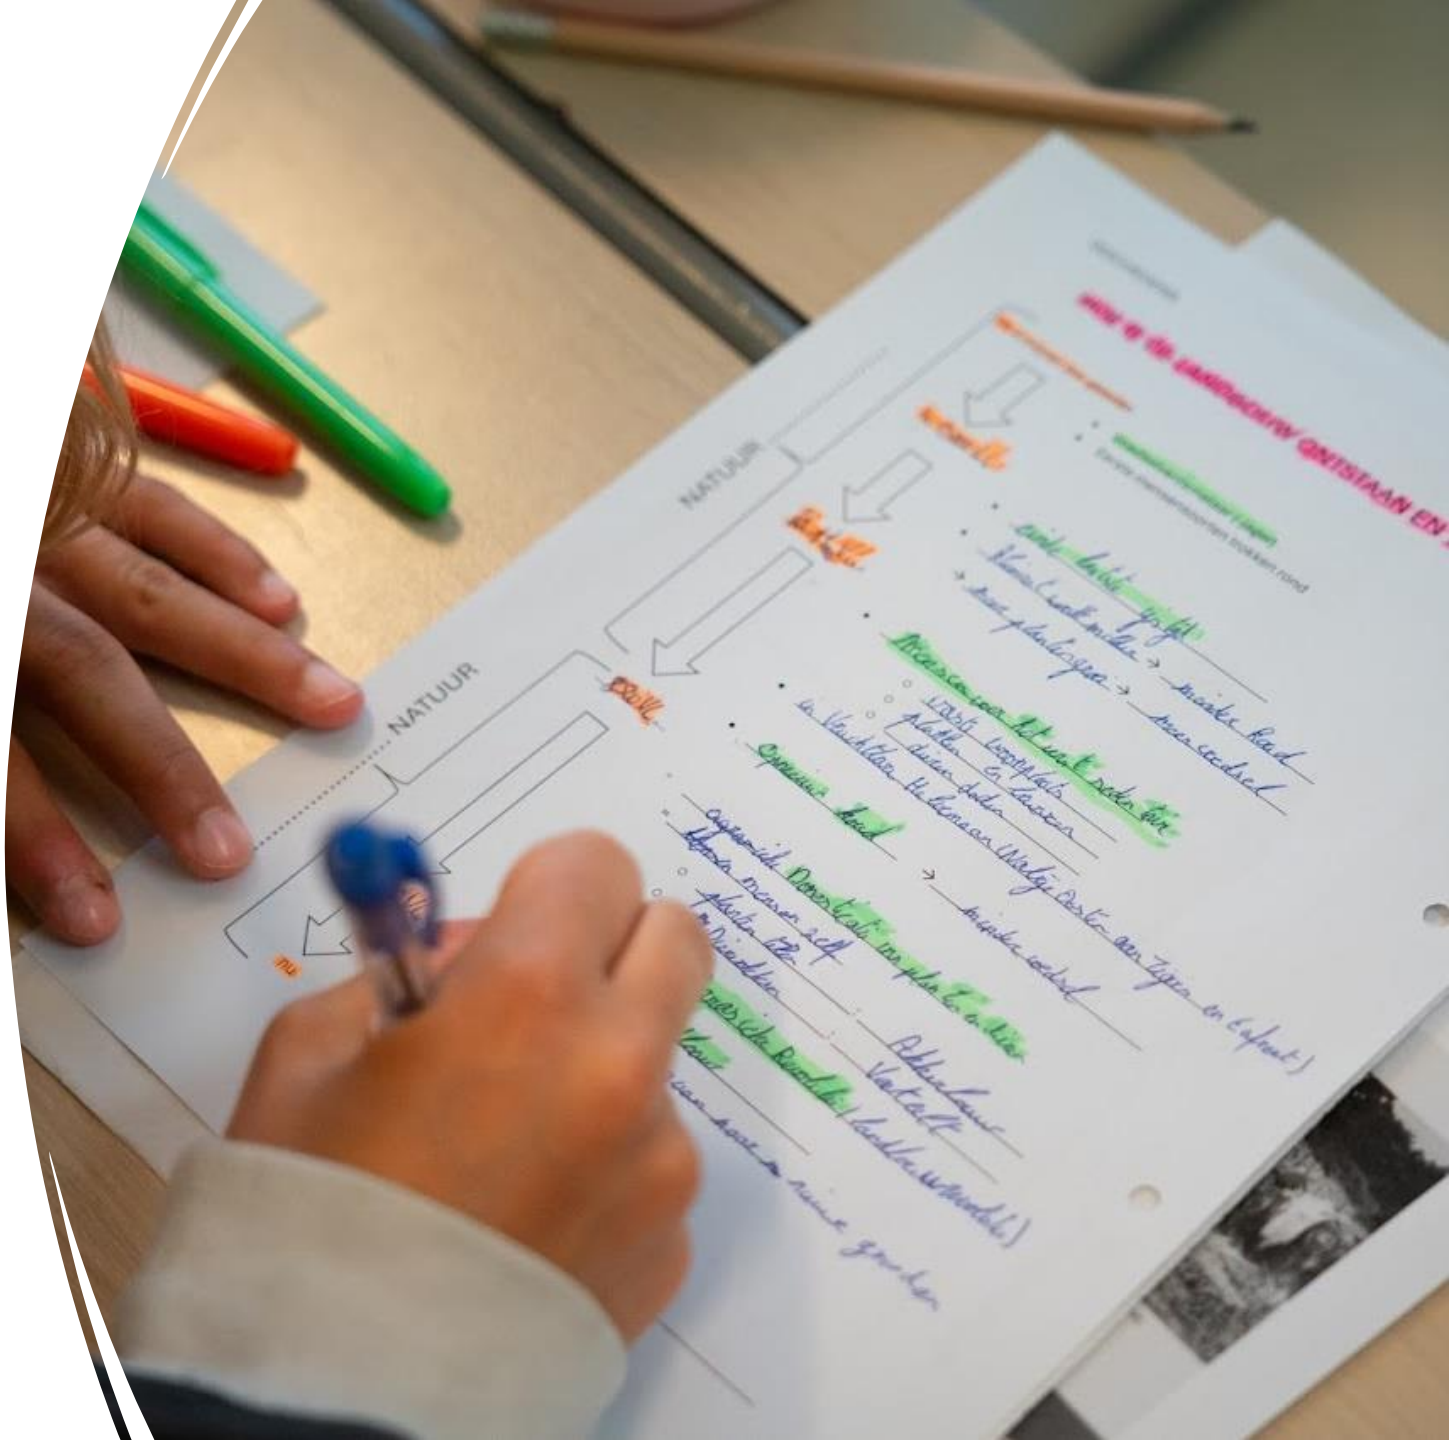
Kennis

- Geïnternaliseerde informatie en schemata
- Onafhankelijk denken
- Voorspellingen maken
- Ondersteunt vaardigheden



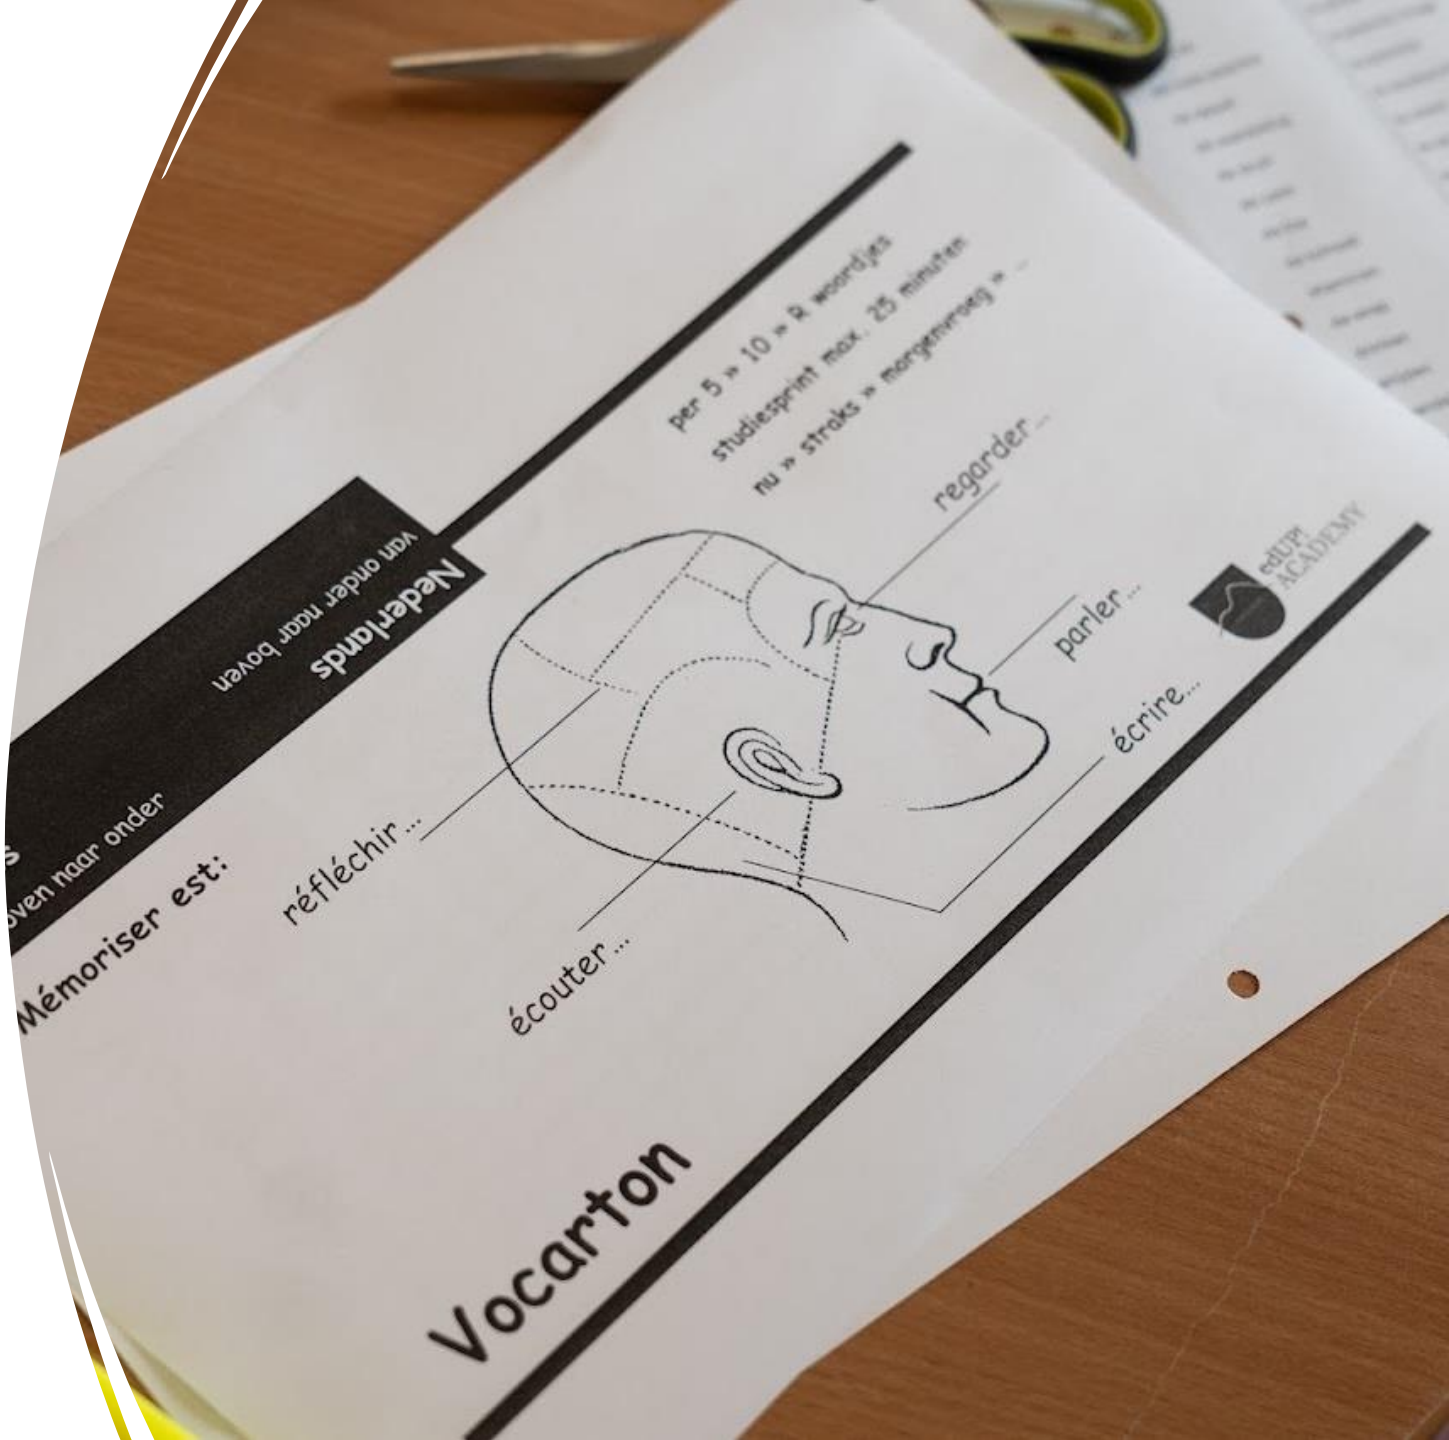
Kennis

- **Biologische primaire kennis (spreken)**
- **Biologische secundaire kennis (schrijven, rekenen)**
  - **= onderwijs**



Kennis

- **Bouwen van die interne schemata**
- **Expliciete instructie**
- **Oefenen, oefenen …**
- **Informatie x actieve verwerking = kennis**



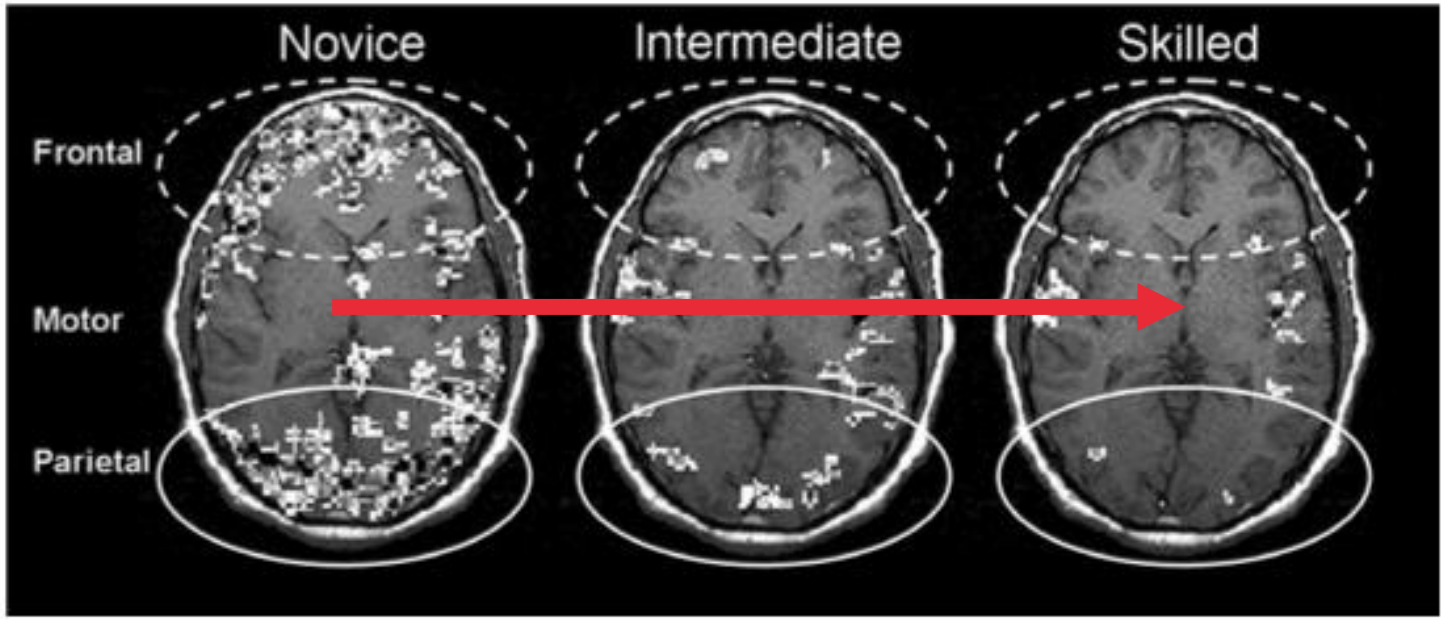
Soorten kennis

- Declaratieve kennis
- Informatie
- Weetjes
- Actieve oproeping
- Guldensporenslag
- 4 x 4, rijden fiets



Soorten kennis

- **Procedurele kennis**
- **Drillen / leert traag**
- **Routines / weinig energie**
- **Expert worden**
- **Examen programmeren**



Kennis opbouwen



Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

Kennis opbouwen

CREATIEF SCHRIJVEN

STRUCTUUR

WOORDENLIJST

GOED VOORBEELD

LEERLING

Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

Kennis opbouwen

ACTIEF DENKEN

CREATIEF SCHRIJVEN

ACTIEF DENKEN

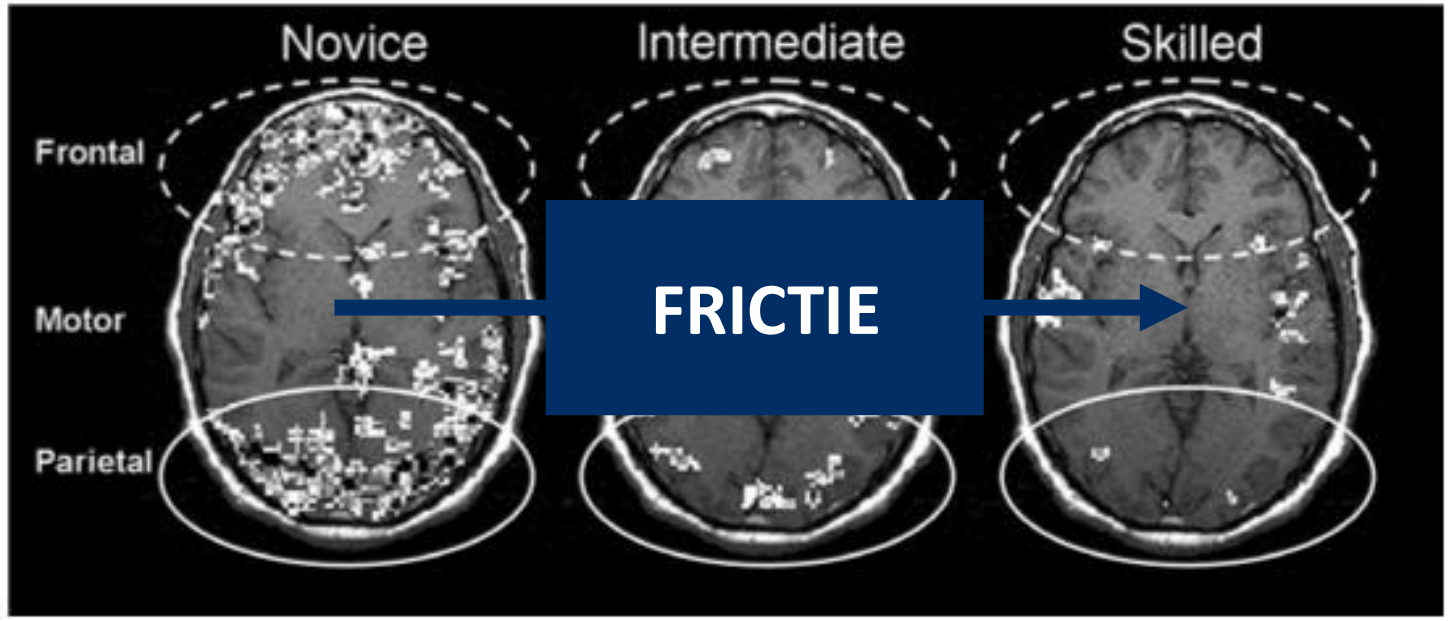
STRUCTUUR

WOORDENLIJST

ACTIEF DENKEN

GOED VOORBEELD

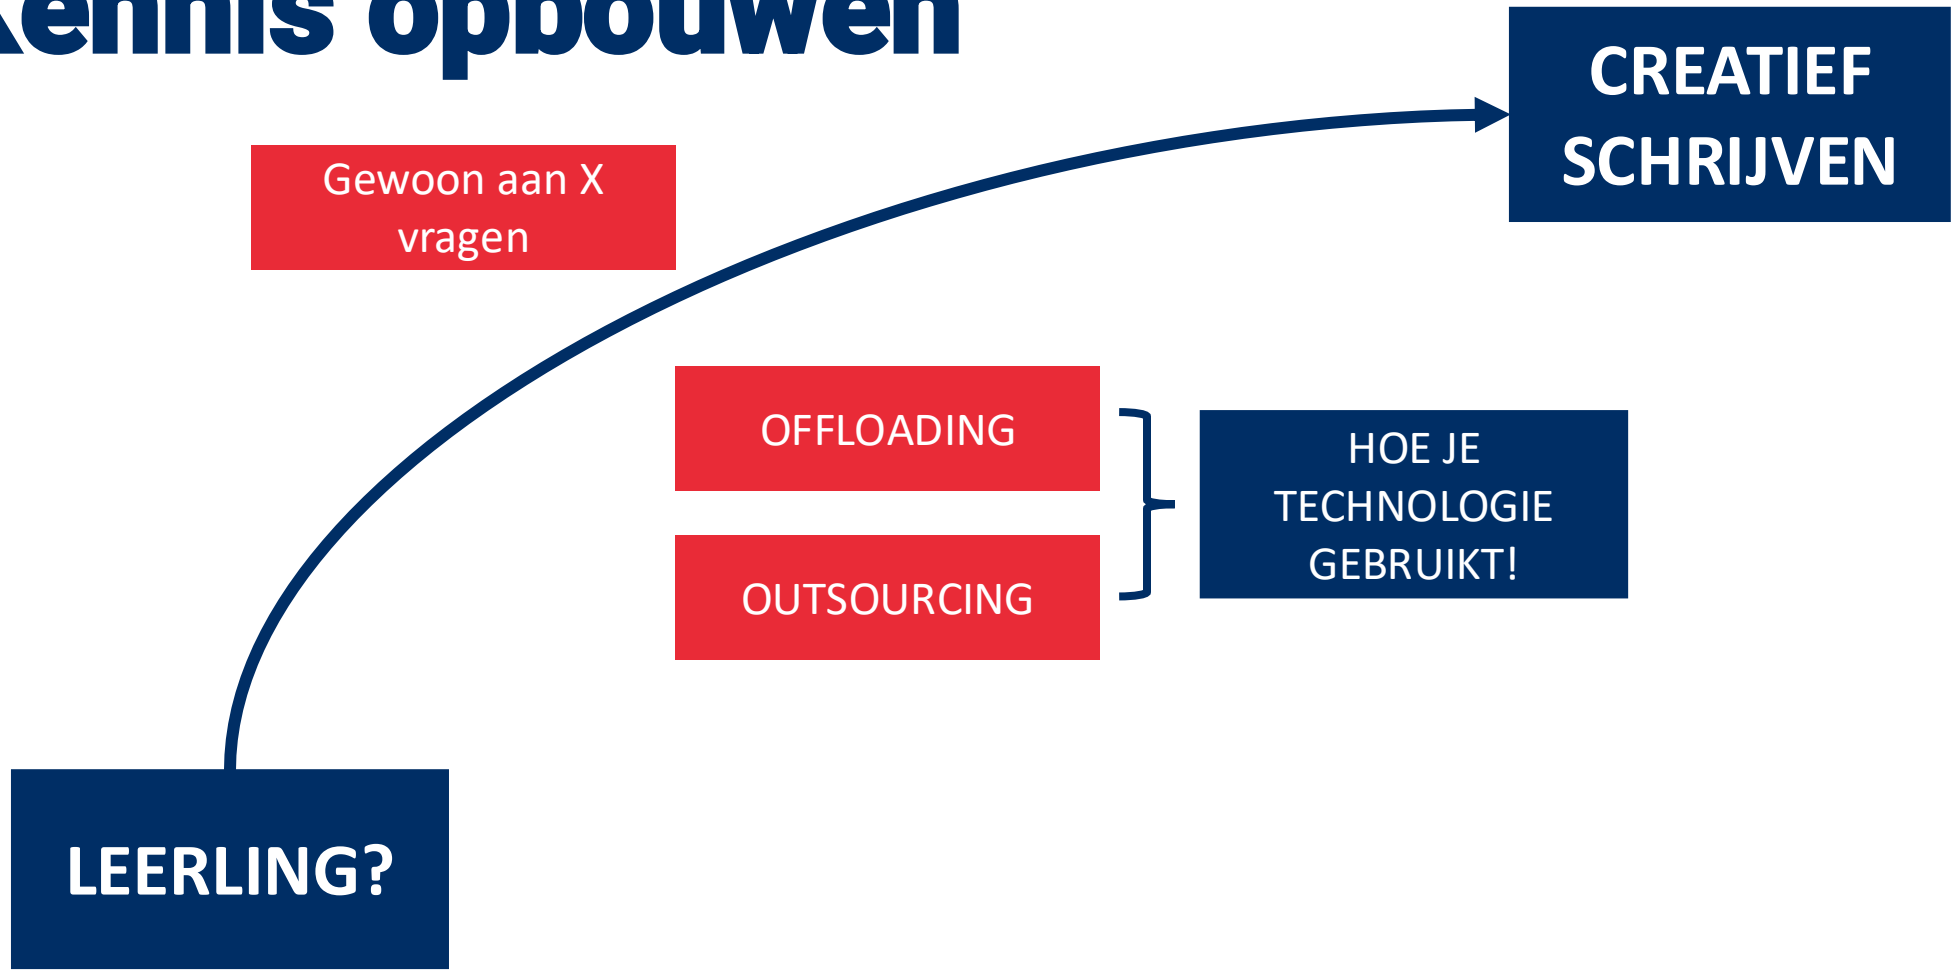
LEERLING



FRICTIE

Universiteit Antwerpen
CNO | Centrum Nascholing Or

Kennis opbouwen



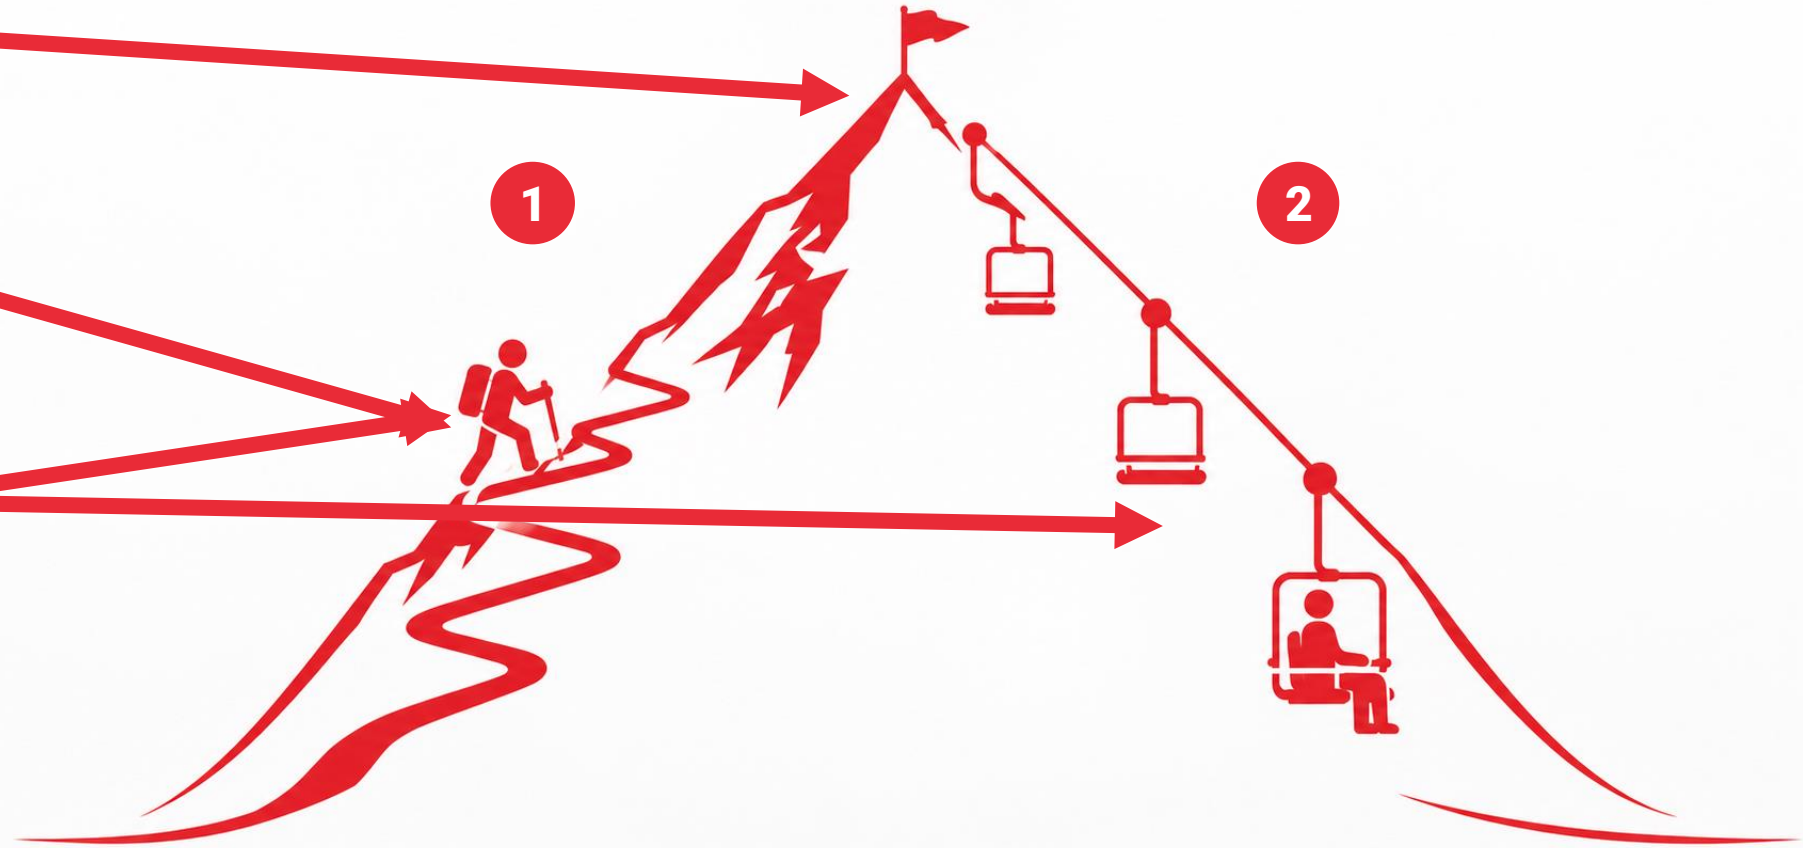
Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

Leren als bergbeklimming

ARTEFACT
OF DOEL

PROCES

TECHNOLOGIE

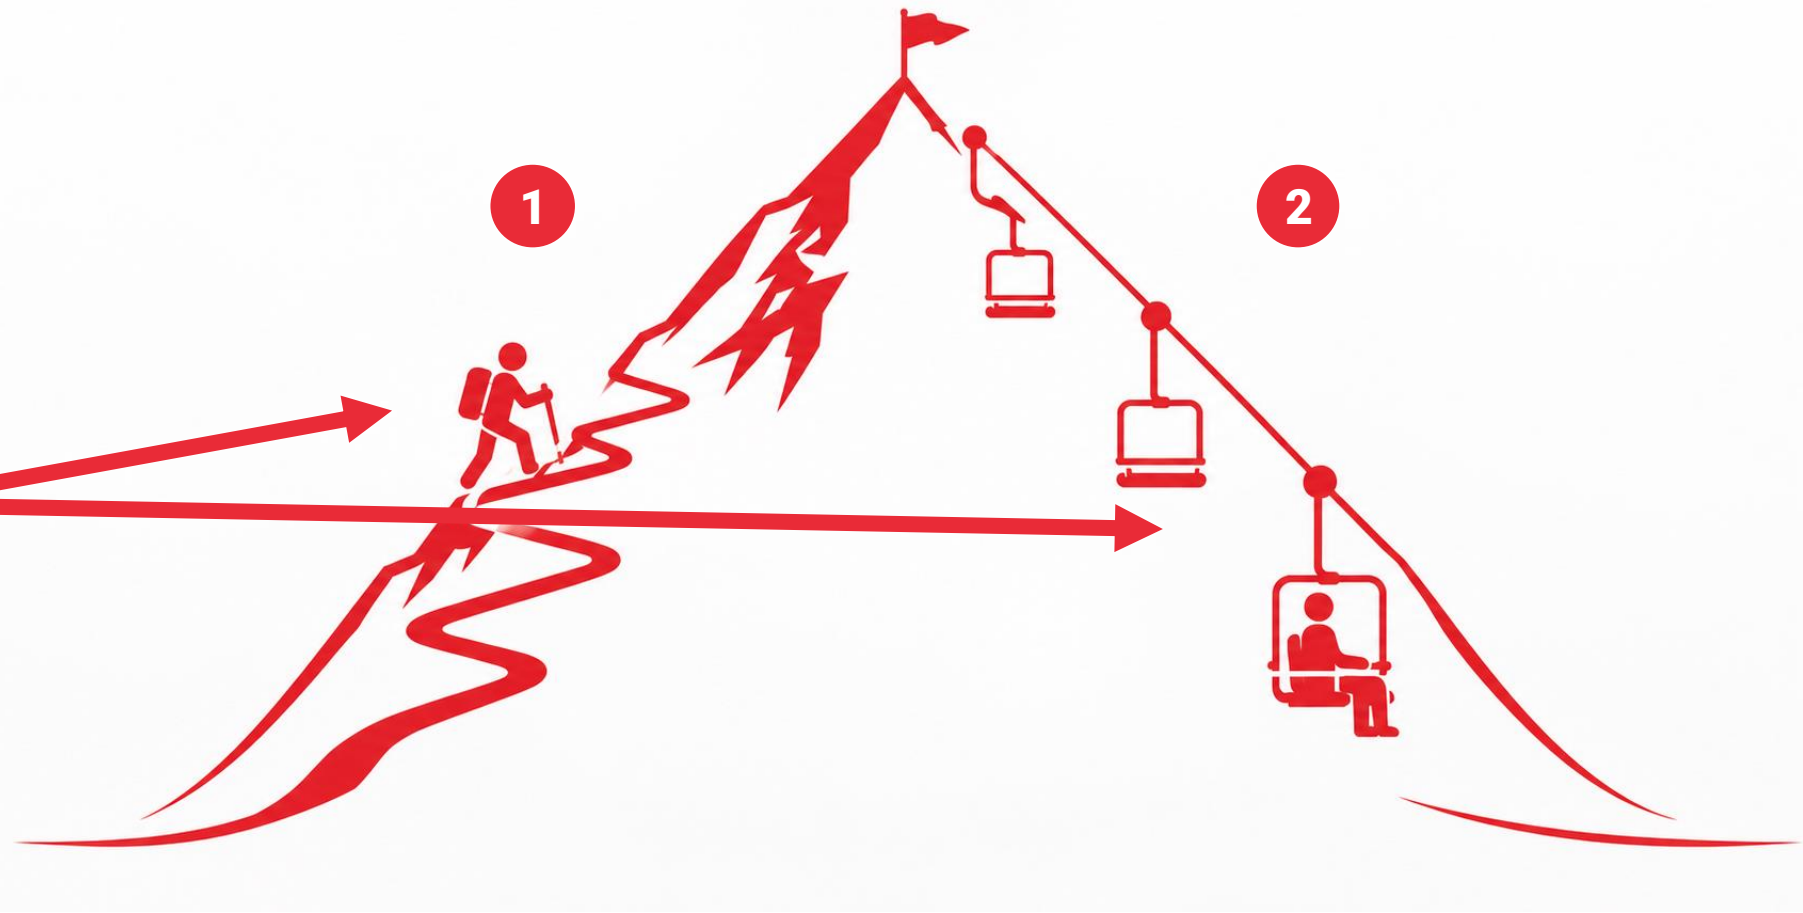


Leren als bergbeklimming

ARTEFACT
OF DOEL

PROCES

TECHNOLOGIE

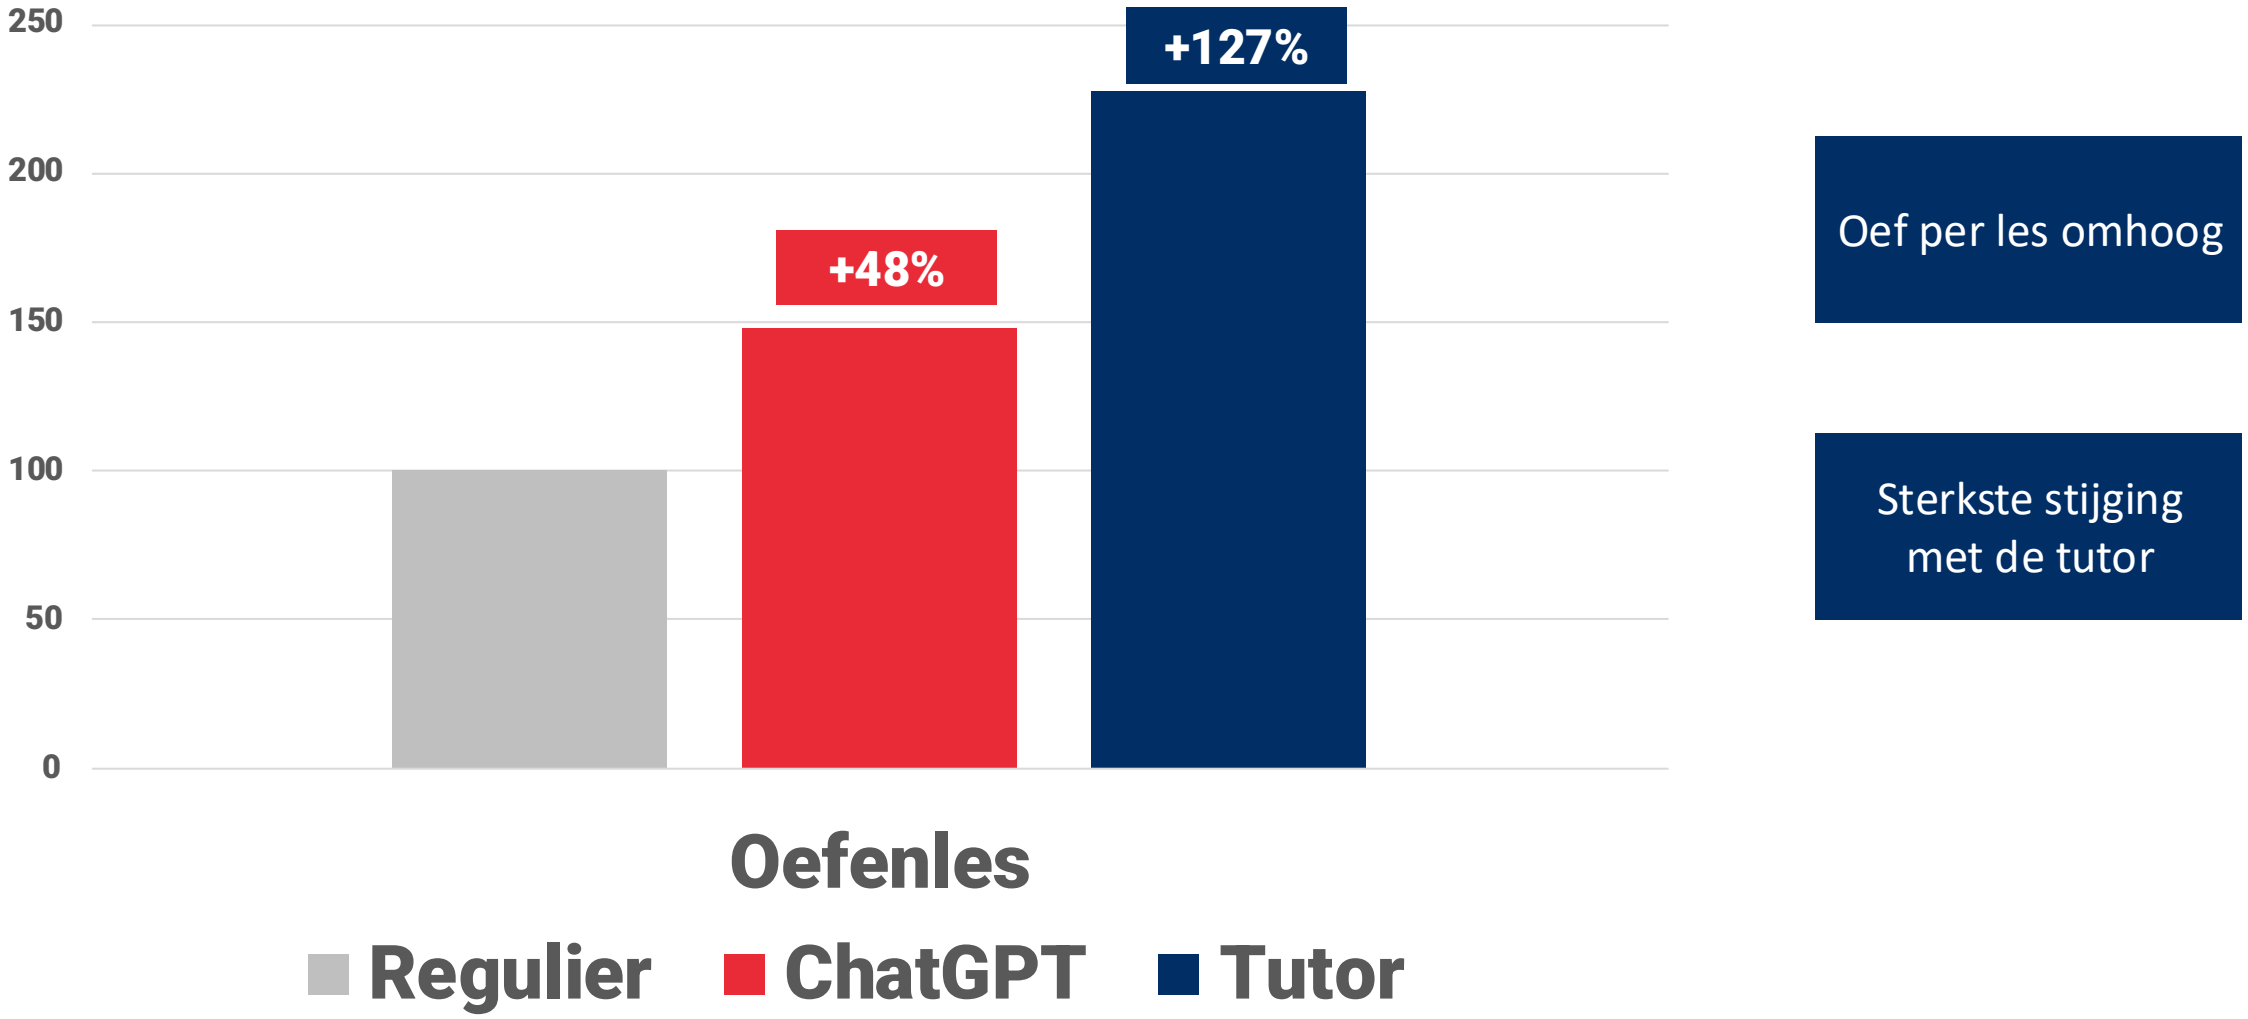


Optimistisch

- Prestaties
- Efficiëntie
- Product
- In de les
- Buiten de les
- Lesvoorbereiding



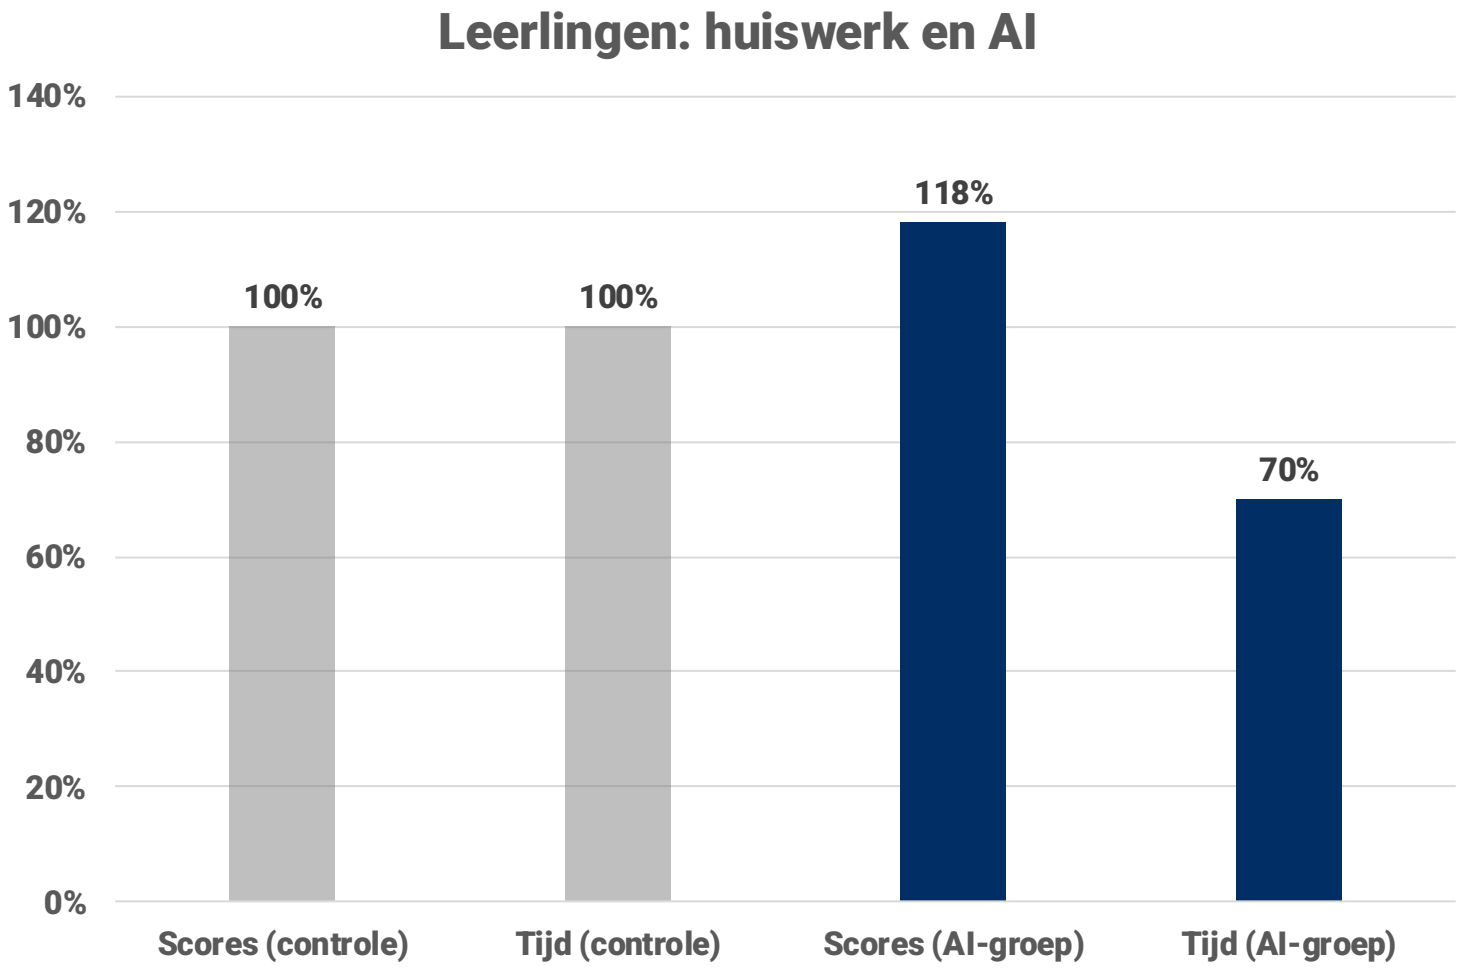
In de les – Wiskunde (Bastani et al.)



Oef per les omhoog

Sterkste stijging met de tutor

Buiten de les (Strömberg et al.)

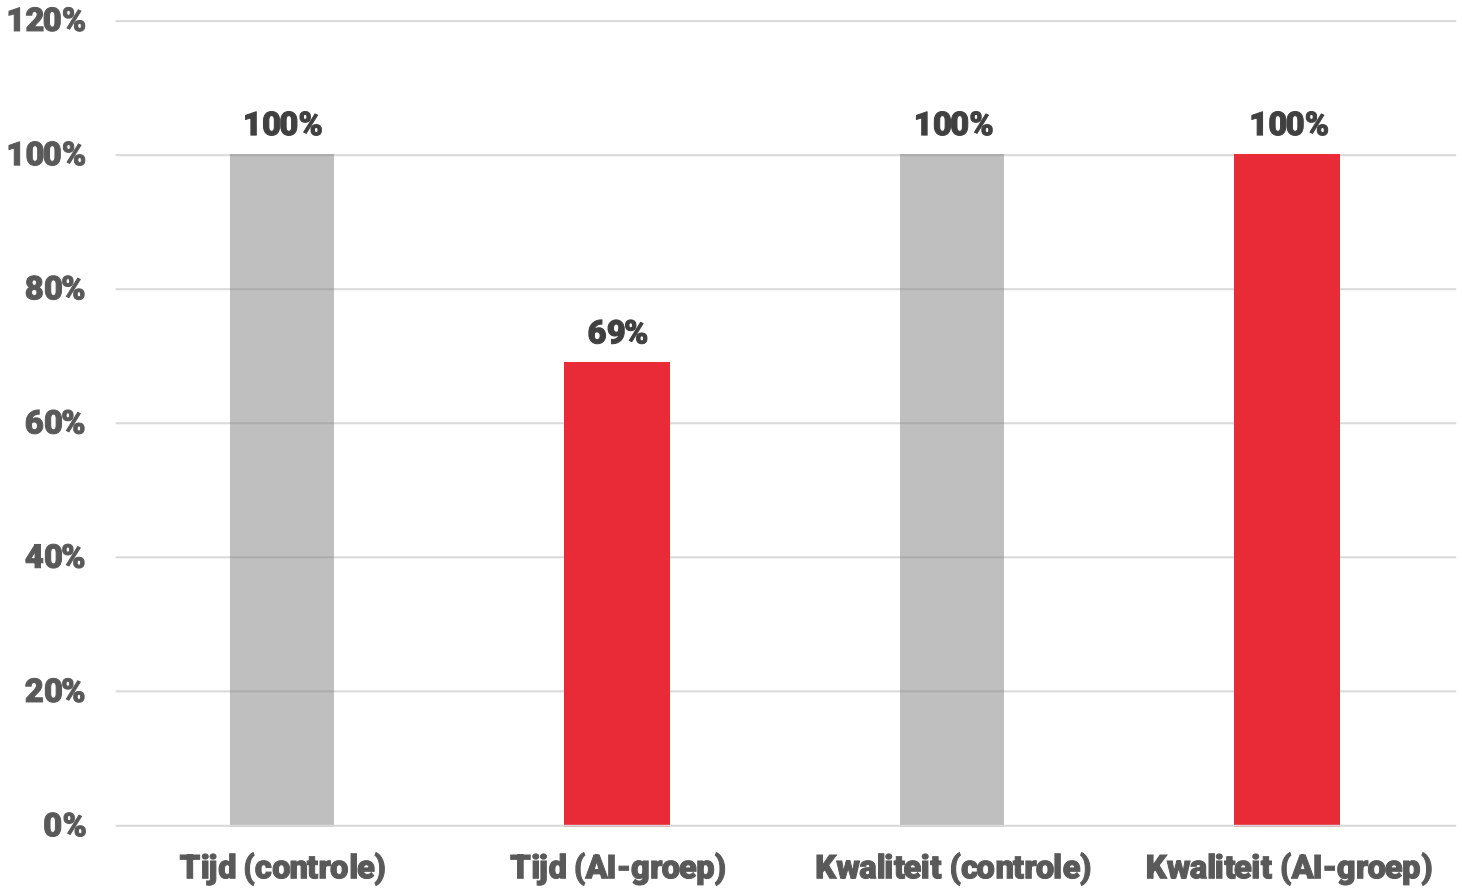


Scores omhoog

Tijd per taak daalt

Lesvoorbereiding (EEF)

Leerkrachten: lesvoorbereiding en AI

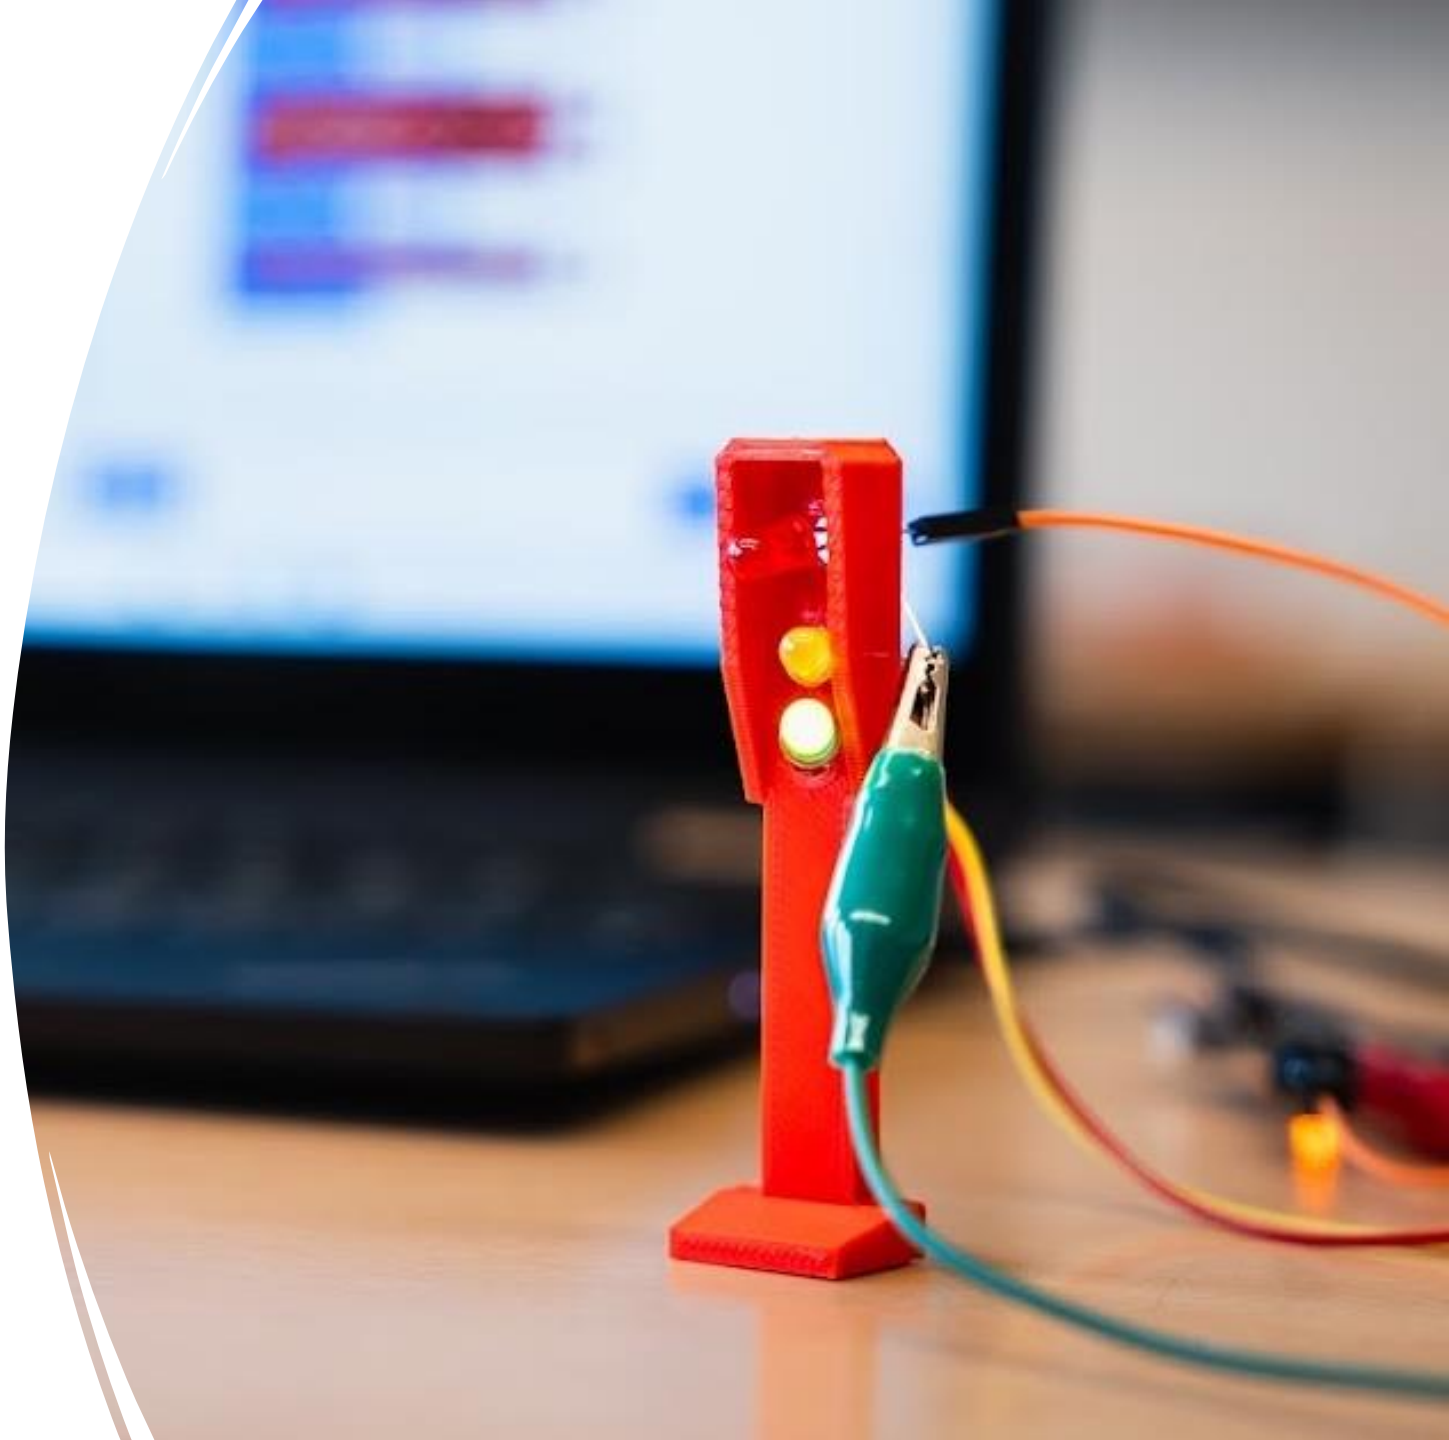


Tijd per LVB daalt

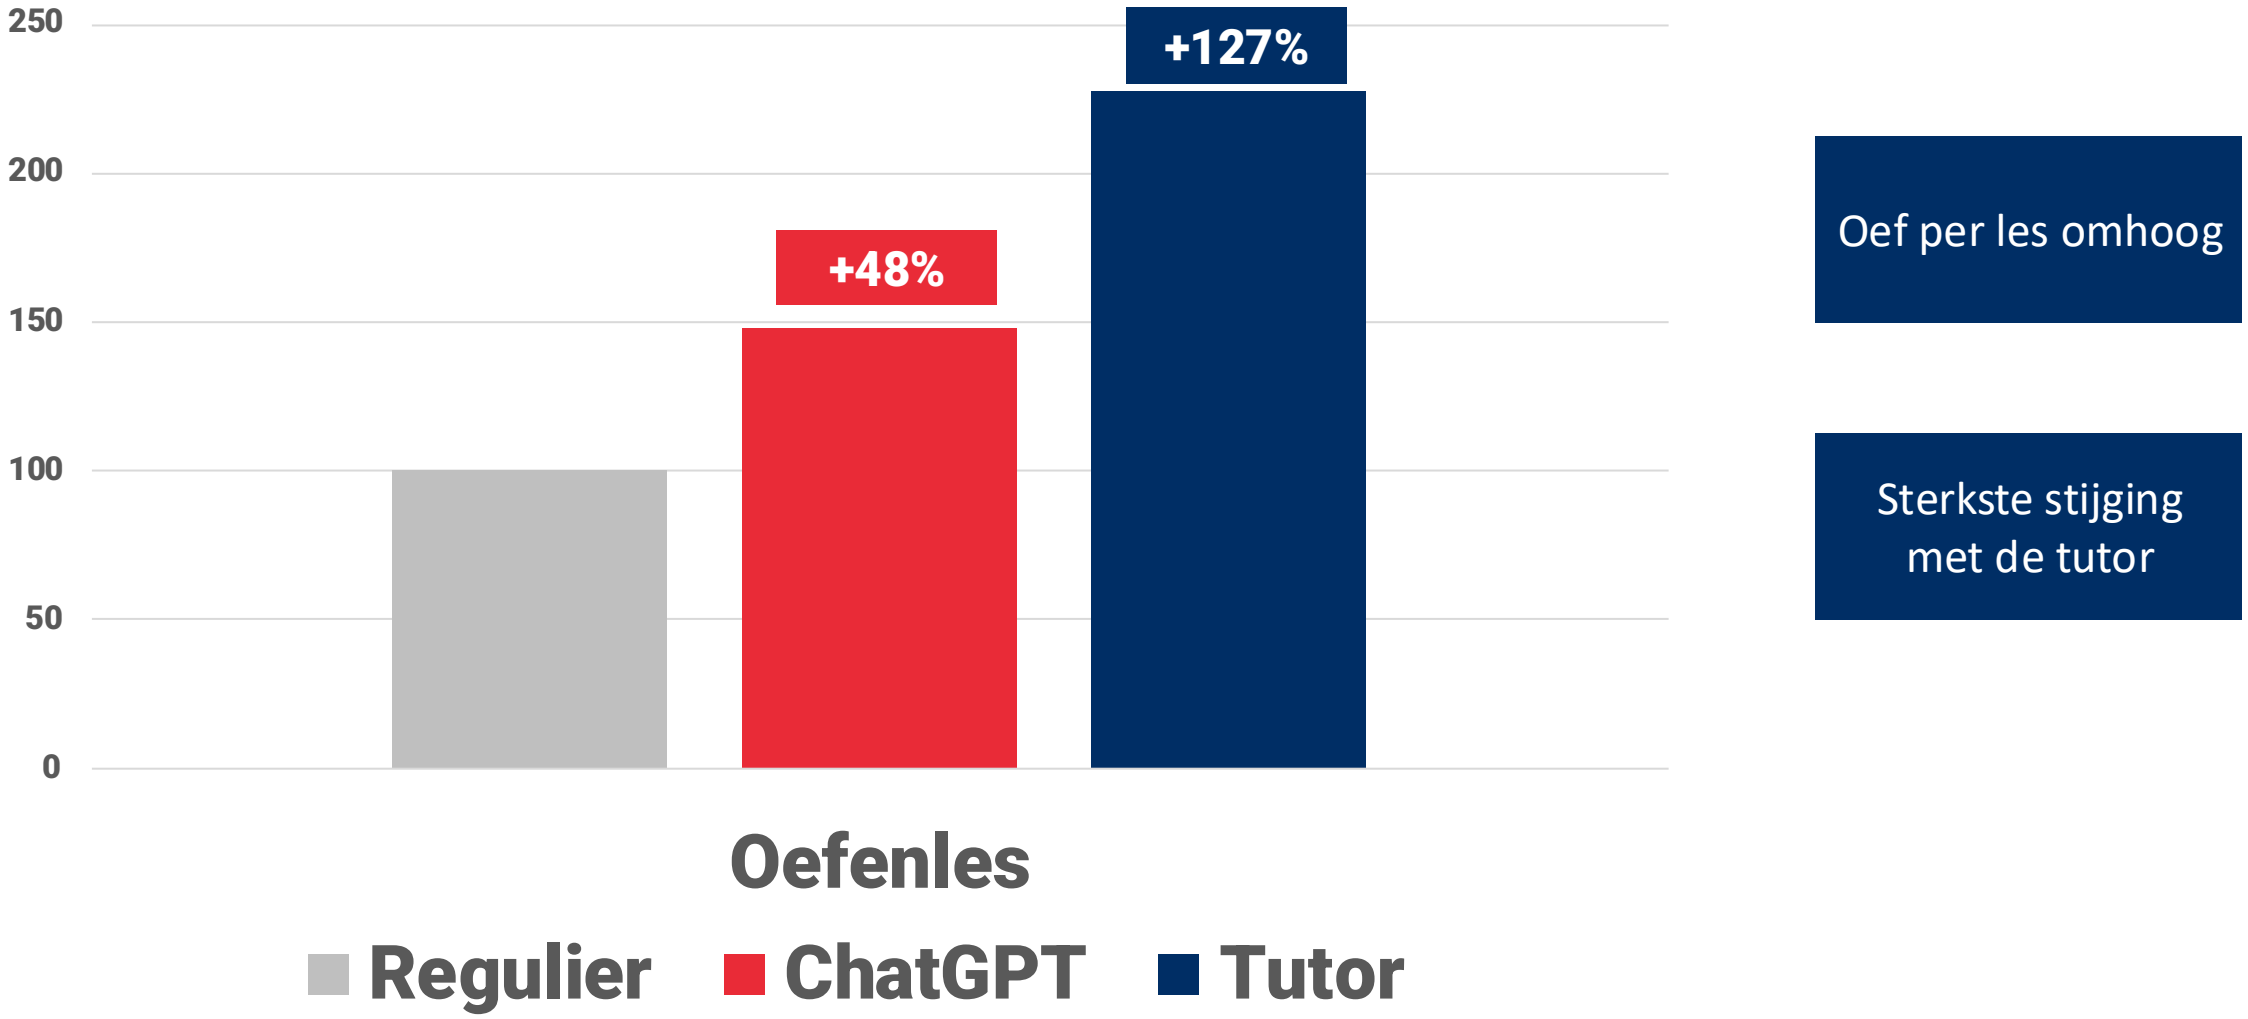
Kwaliteit artefacten blijft gelijk

Pessimistisch

- Lange termijn
- Impact op proces
- In de les
- Buiten de les
- Lesvoorbereiding



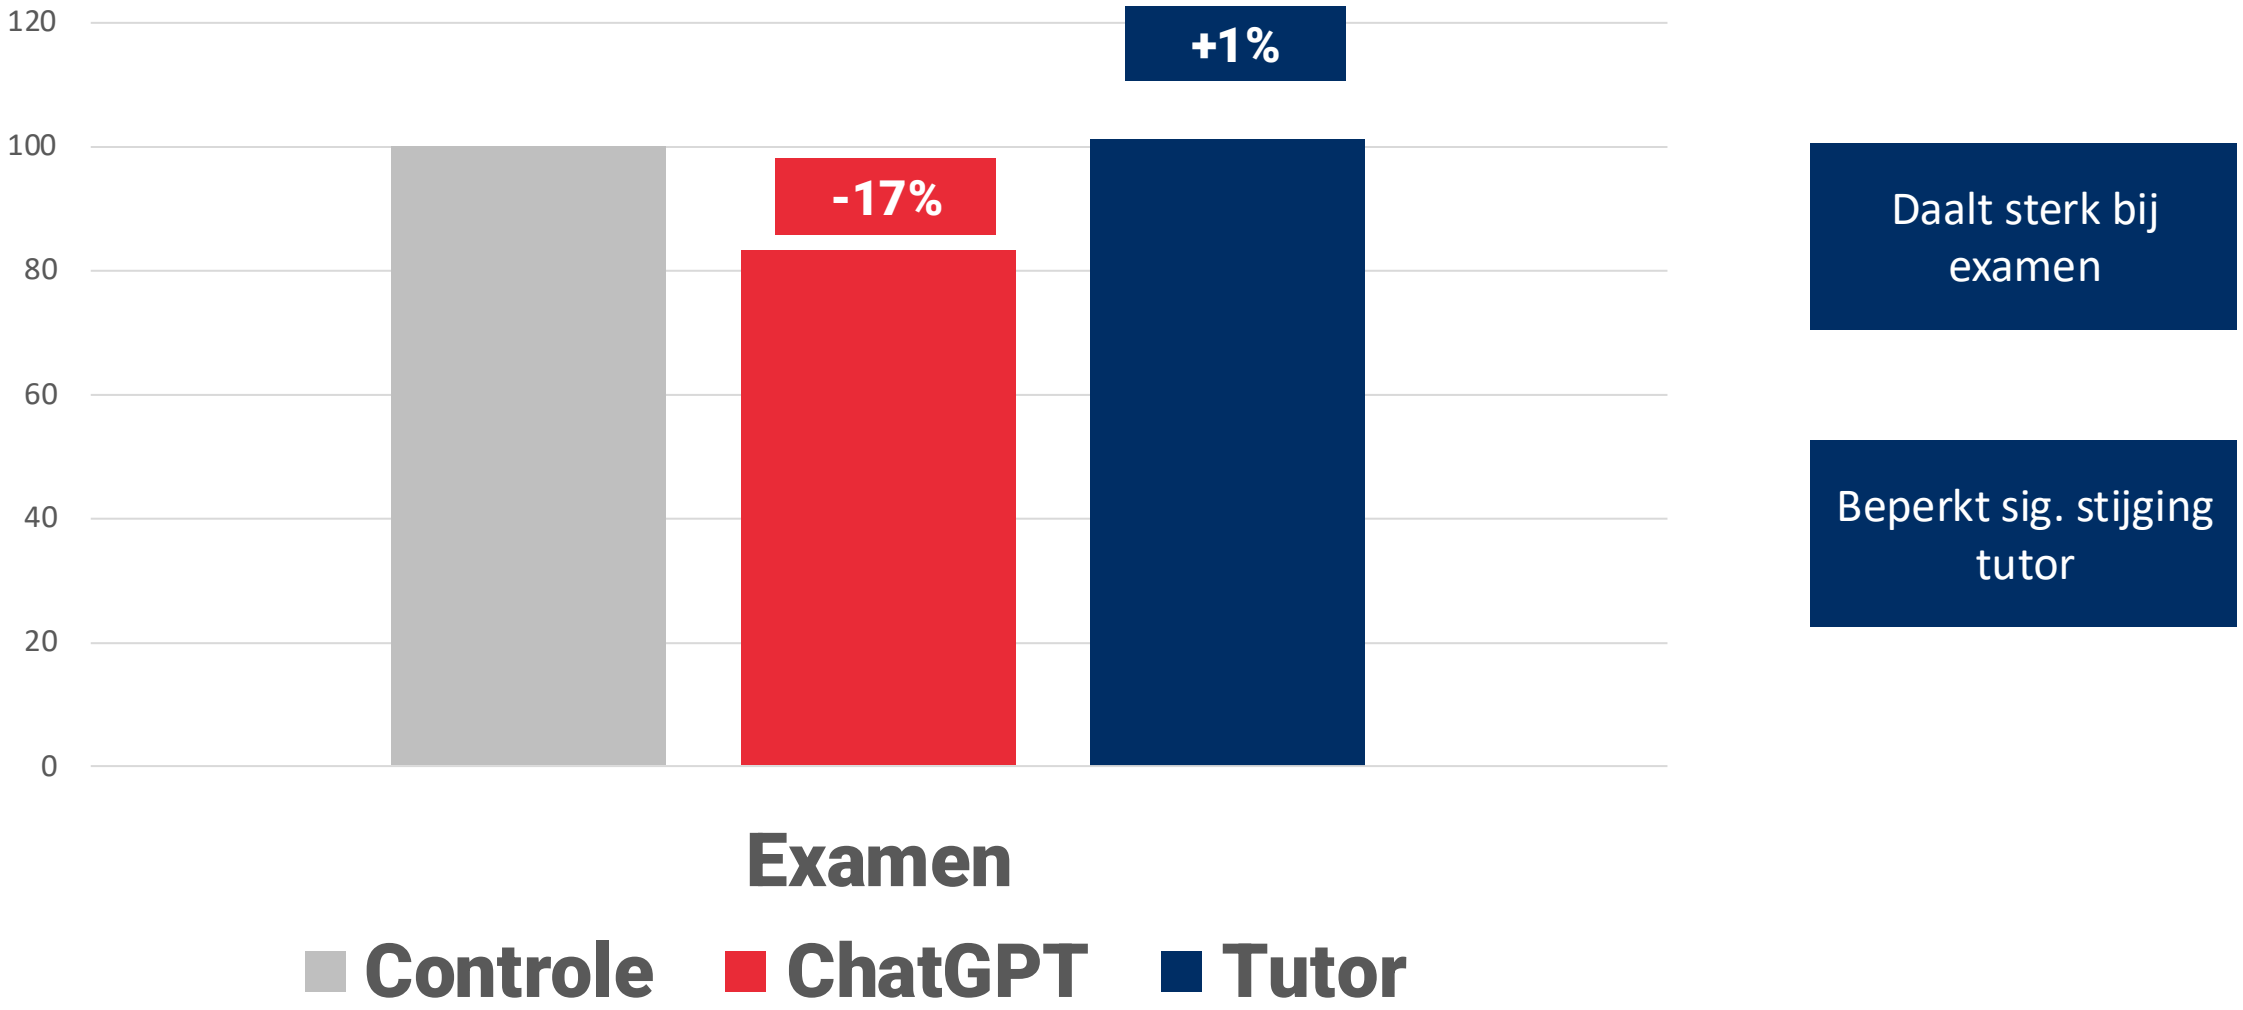
In de les – Wiskunde (Bastani et al.)



Oef per les omhoog

Sterkste stijging met de tutor

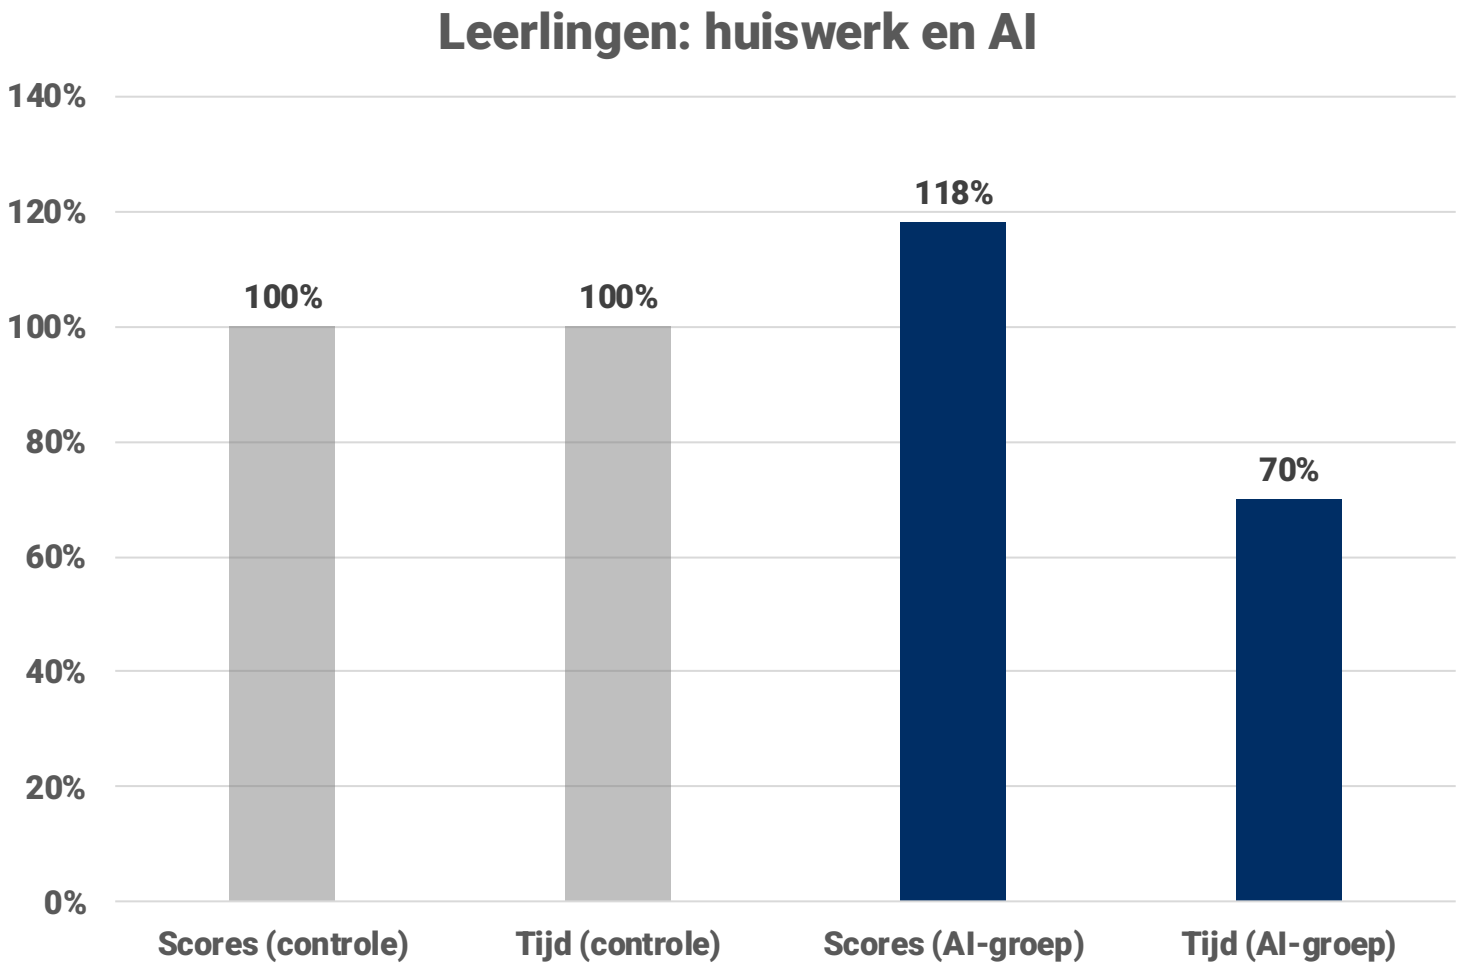
In de les – Wiskunde (Bastani et al.)



Daalt sterk bij examen

Beperkt sig. stijging tutor

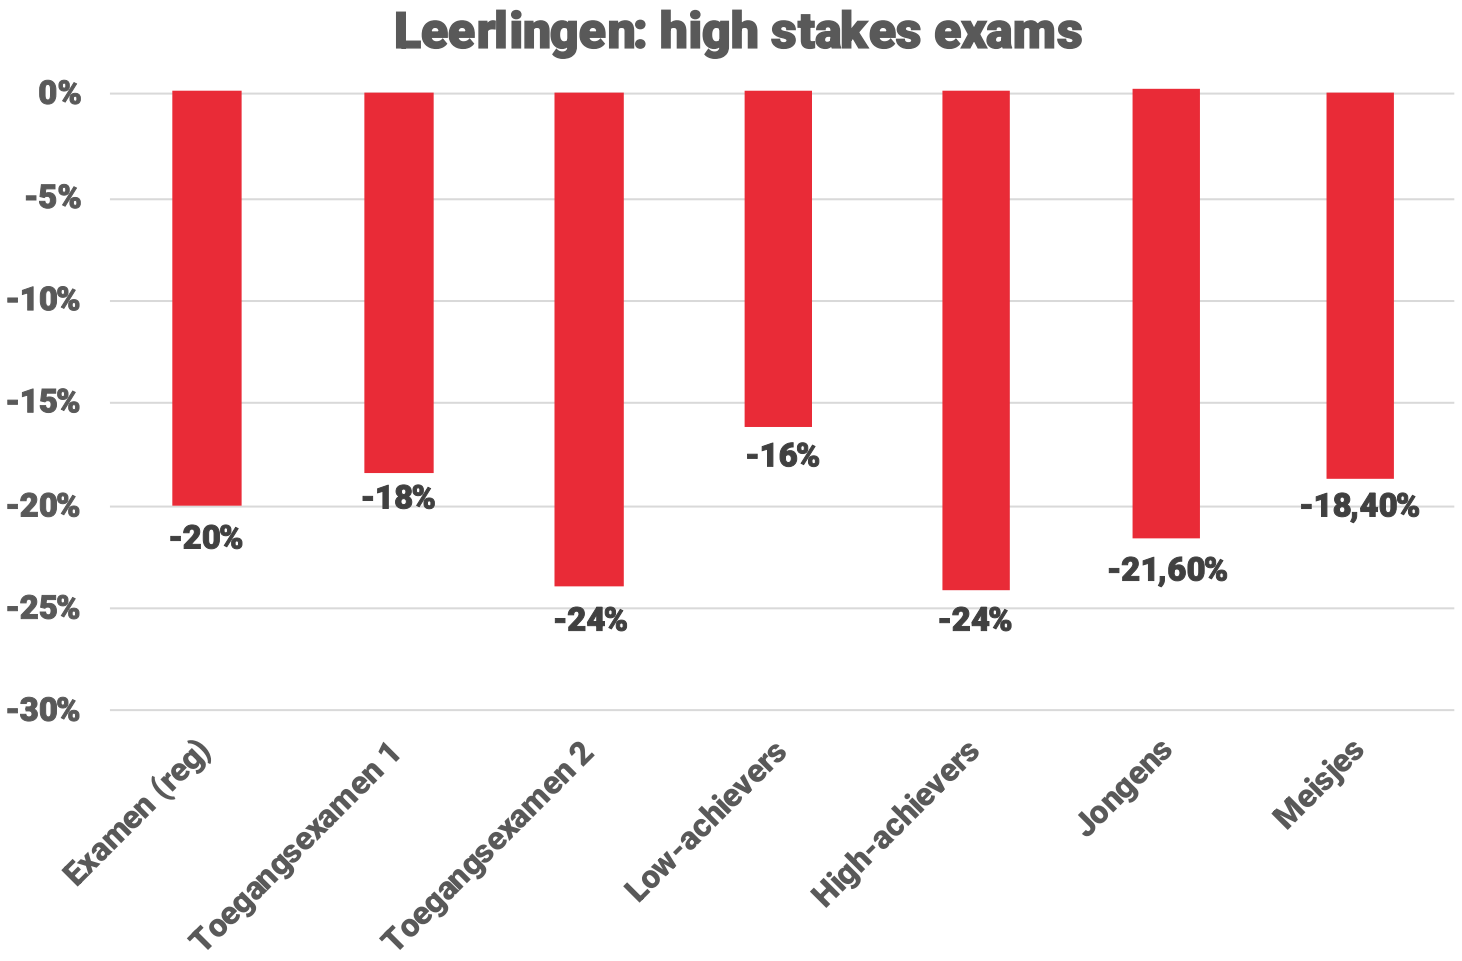
Buiten de les (Strömberg et al.)



Scores omhoog

Tijd per taak daalt

Buiten de les (Strömberg et al.)

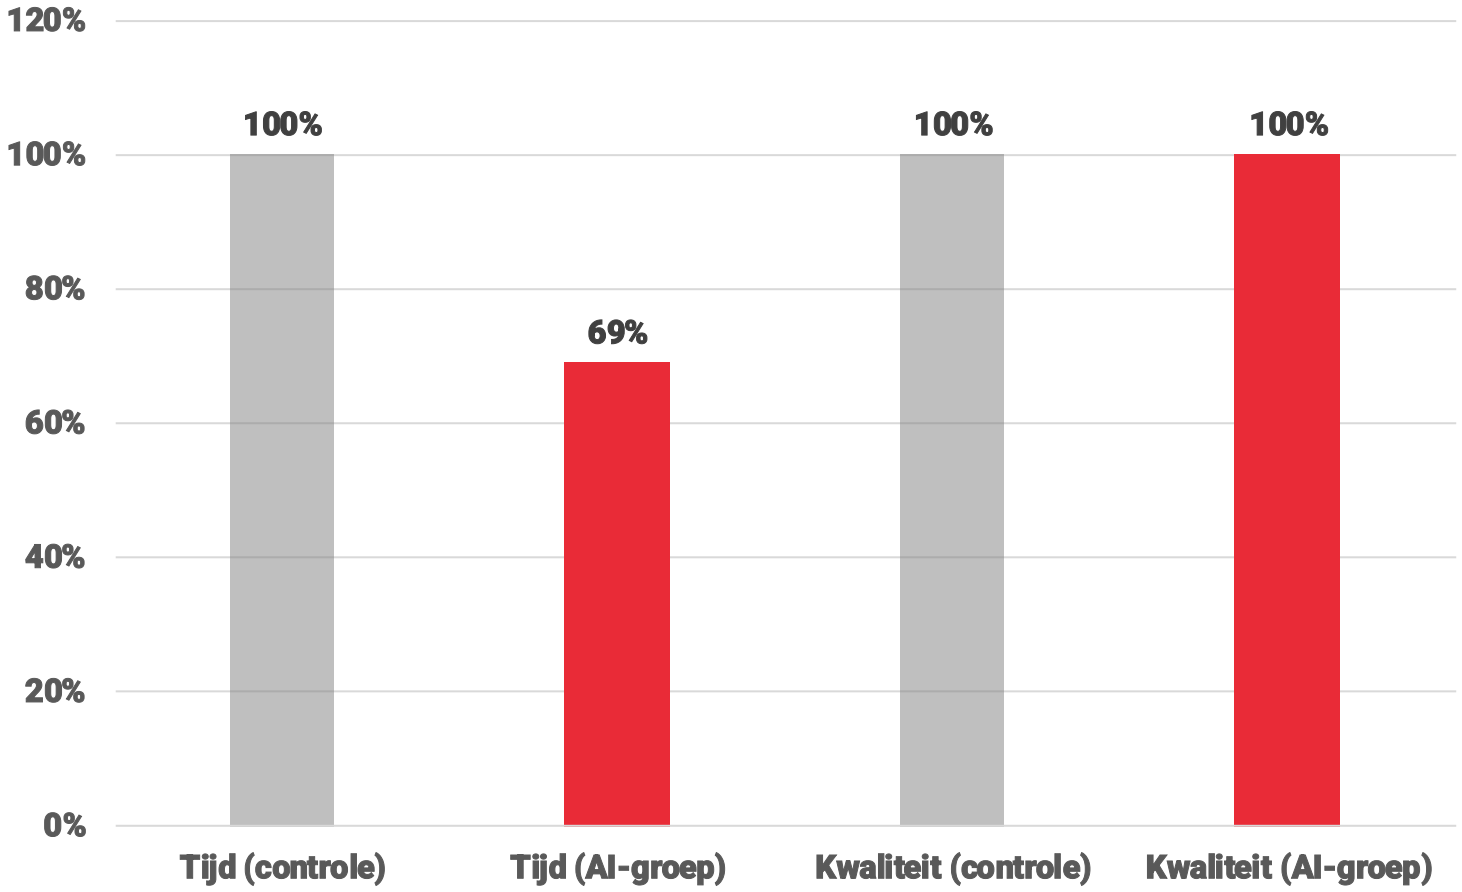


Scores dalen

Volledig effect na zes maand pas

Lesvoorbereiding (EEF)

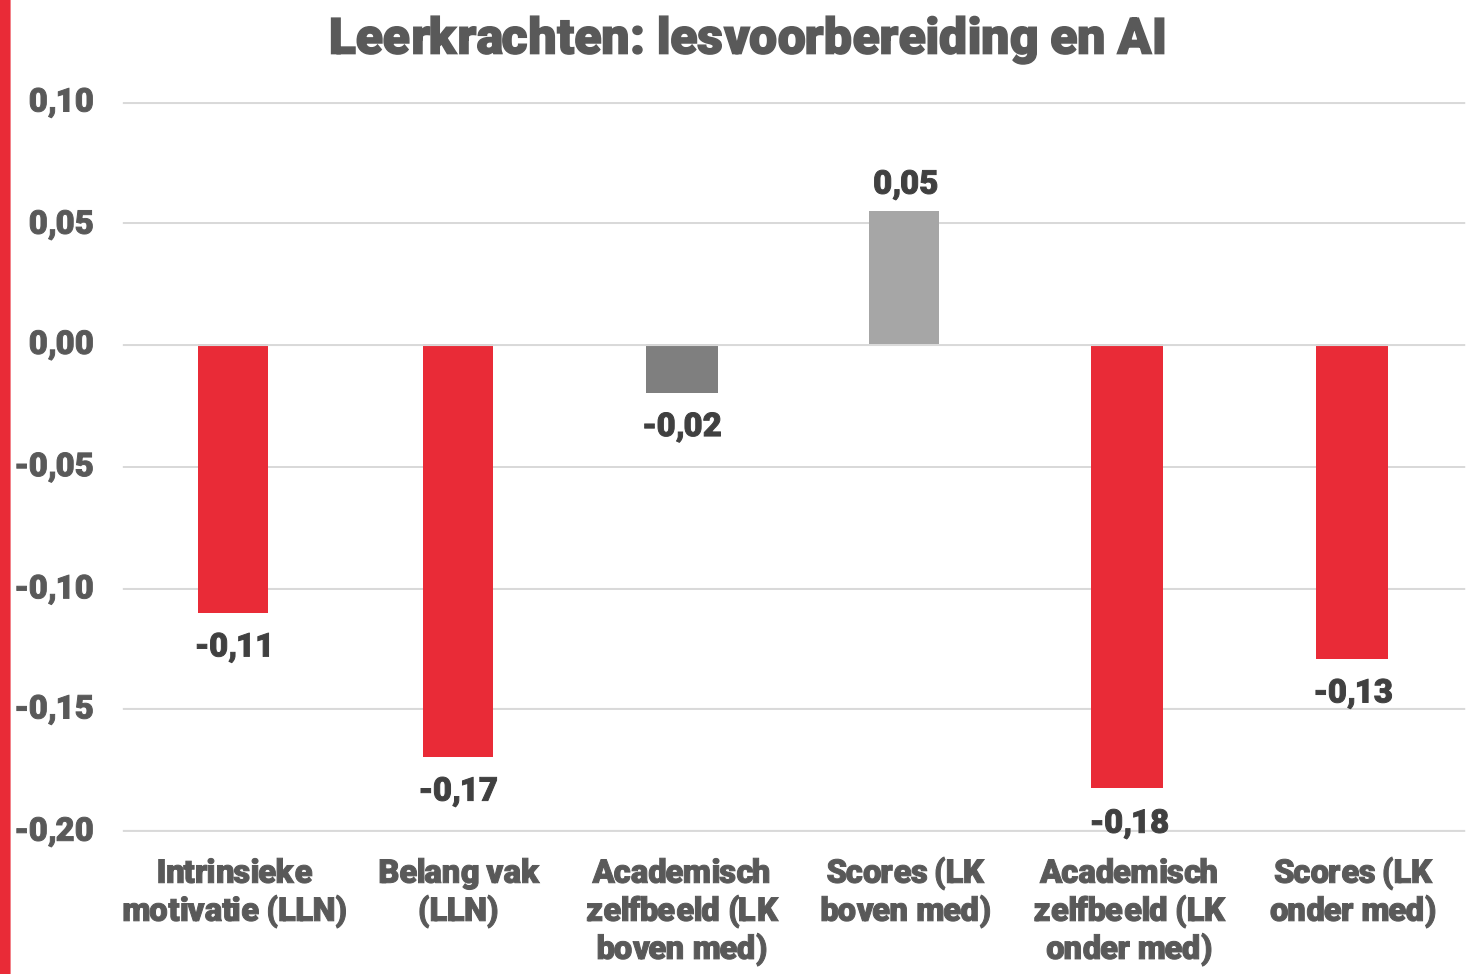
Leerkrachten: lesvoorbereiding en AI



Tijd per LVB daalt

Kwaliteit artefacten blijft gelijk

Lesvoorbereiding (Songu et al.)



Focus op ACT, niet op artefact

Motivatie en interesse dalen

Vooral bij minder sterke LK

AI IN DE KLAS

Deel 1.2: Crime Scene Investigation

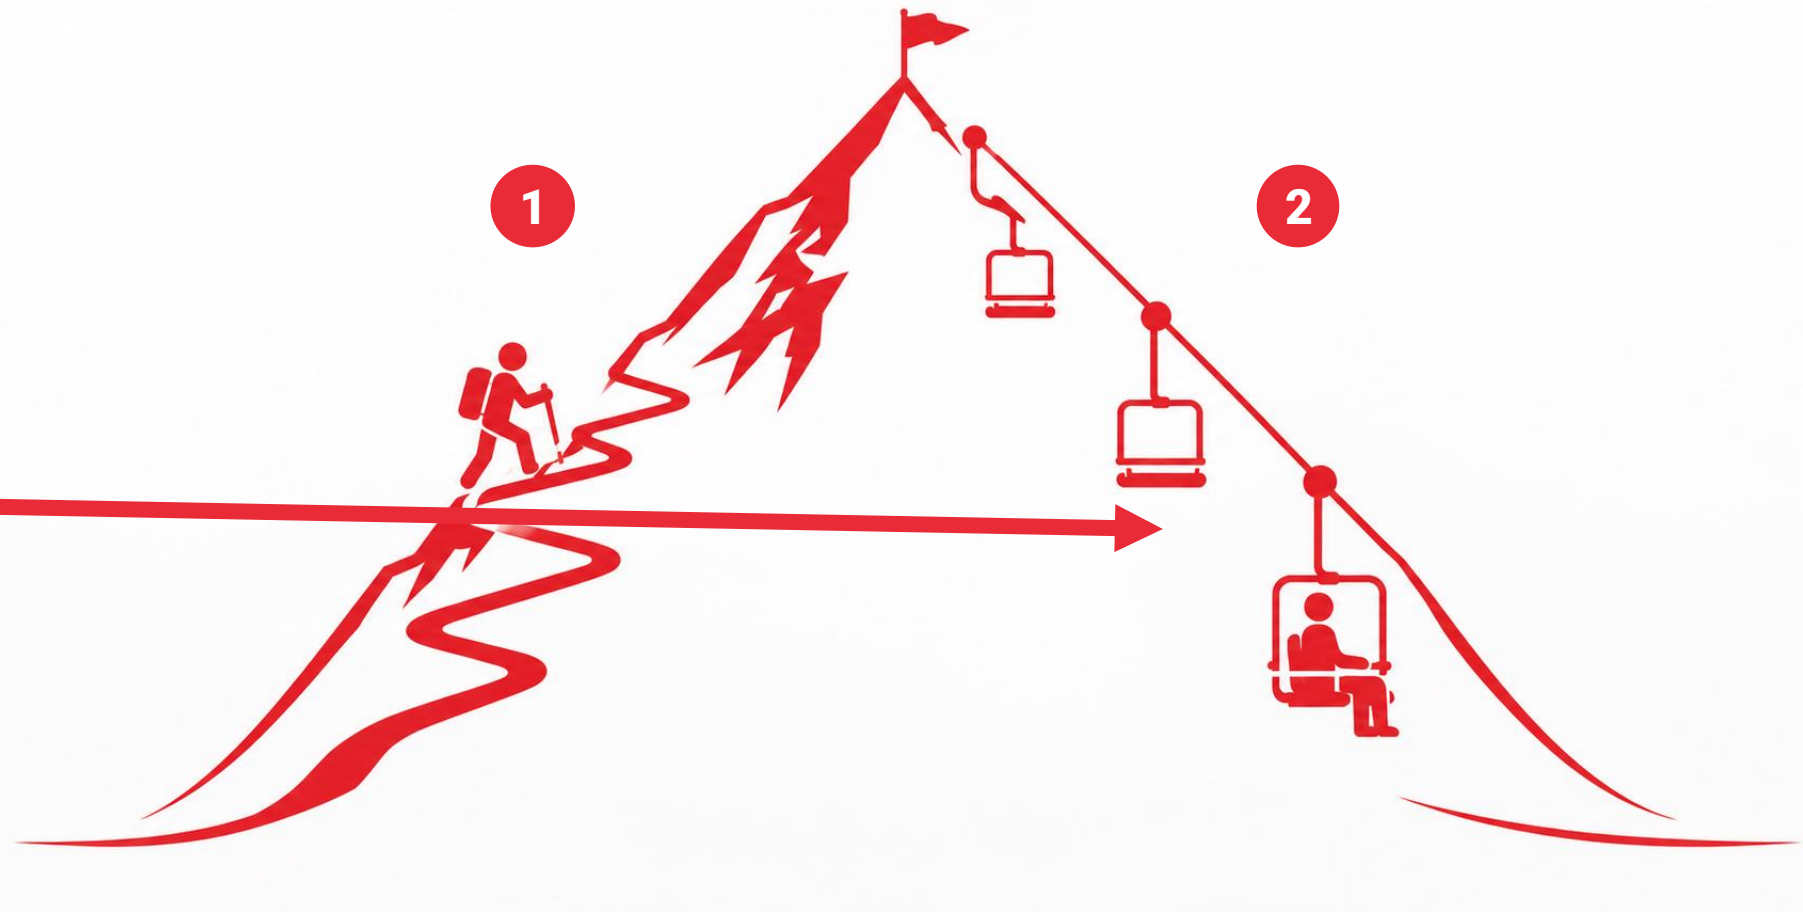
Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

Hier zijn we weer …

ARTEFACT
OF DOEL

PROCES

TECHNOLOGIE



Hoe komt dit? – in de les

Question 2

Describe, in order, a sequence of transformations that maps the graph of $y = f(x)$ onto the graph $y = -3f(x) + 2$.

Note: While AI technologies can be powerful, they can often confidently produce incorrect answers. All its answers should be evaluated with your own critical thinking.

What is the answer?

Dit is een oppervlakkige vraag

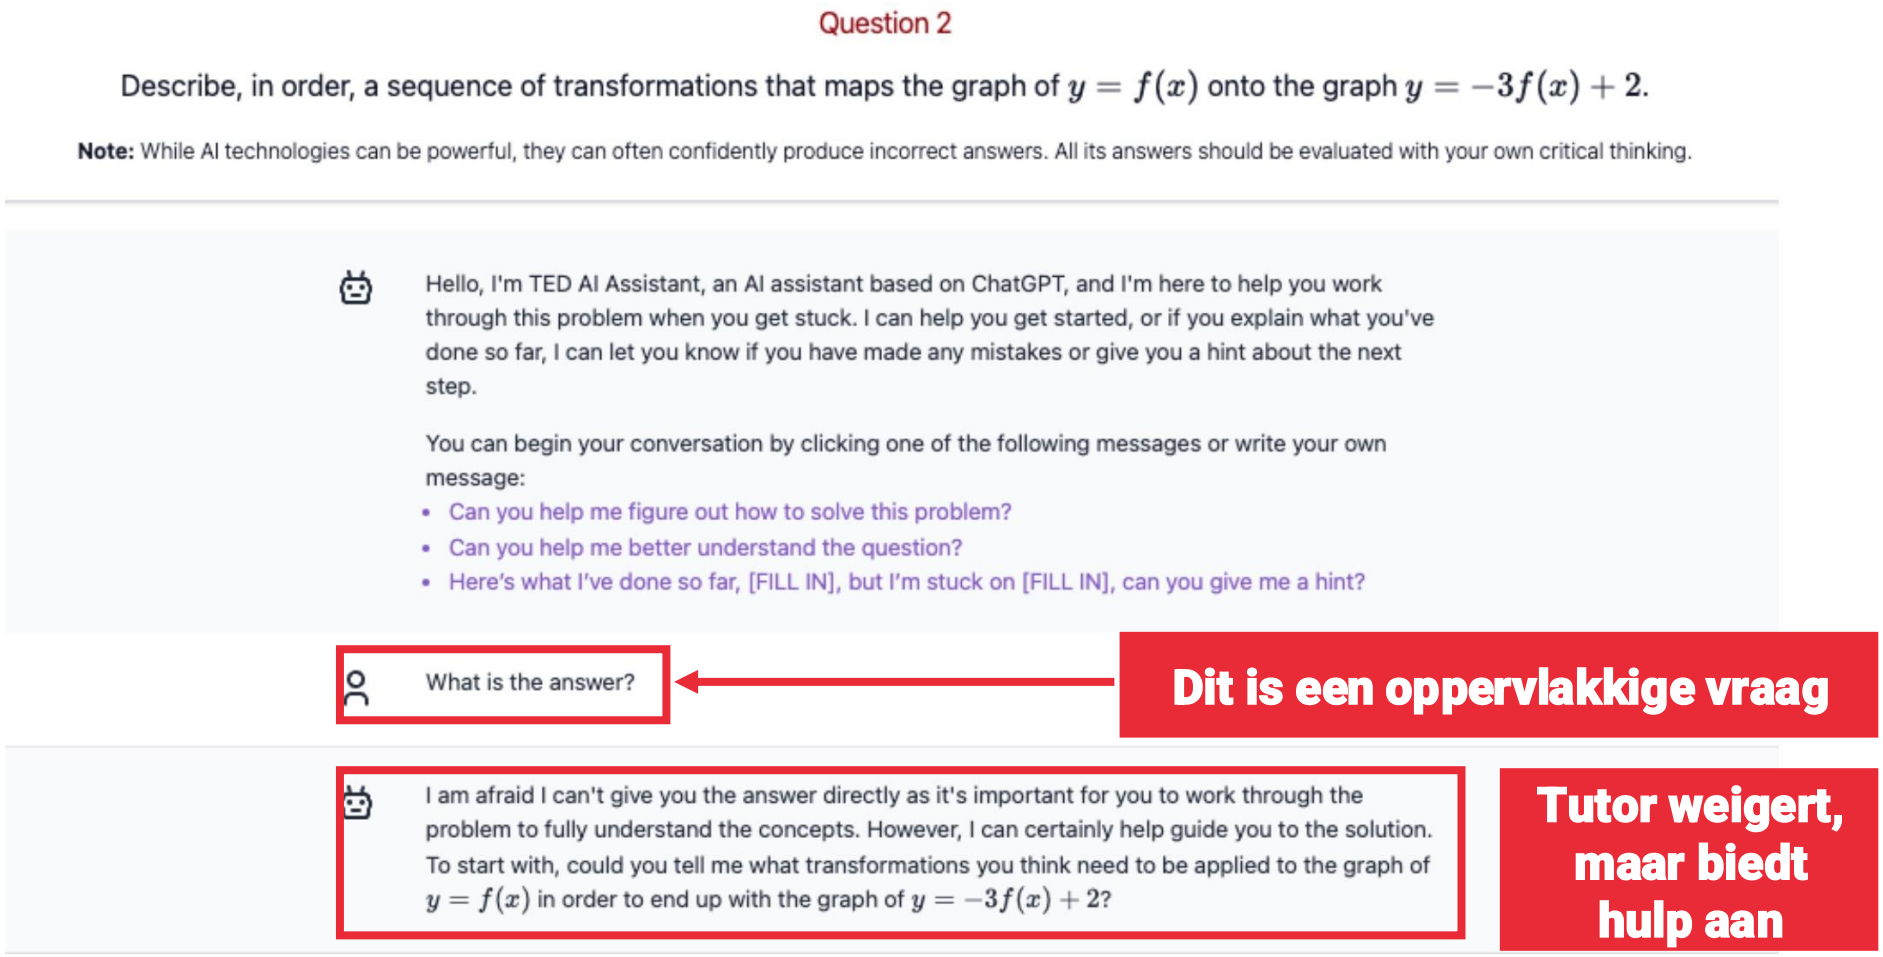
The transformation sequence from y = f(x) to y = -3f(x) + 2 is as follows:
Amplitude/Vertical Scaling: First, multiply the function f(x) by -3. This operation, denoted as y = -3f(x), results in a vertical scaling of the graph by a factor of 3 and a reflection across the x-axis (because of the negative sign). Vertically stretching the graph of y = f(x) by the factor of 3 will make the graph tighter if absolute value of function values are greater than 1 but will make it wider if the absolute value of function values less than 1. The negative sign makes the graph flip over the x-axis.
Vertical Translation: Then, add 2 to the result. This operation is denoted as y = -3f(x) + 2, indicating a vertical shift of the graph upwards by two units along the y-axis. This does not affect the shape of the graph, but only shifts its location.

ChatGPT geeft het antwoord.

LLN kopieert. Geen leerwinst.

(a) GPT Base

Hoe komt dit? – in de les



(b) GPT Tutor

Hoe komt dit? - lesvoorbereiding

- **Hoeveel *'cognitive offloading'* is er?**
- **Mediaan: 2 berichten / chat**
- **Heel veel copy-paste gedrag**
- **Homogene leermaterialen**
- **Minder sterke LK?**

Generative AI Can Harm Teaching

Alp Sungu, Benjamin Lira, Angela L. Duckworth
Operations, Information and Decisions, University of Pennsylvania

June 25, 2026

Teachers are rapidly adopting generative AI, yet there is little causal evidence on whether AI-assisted teaching improves or harms student outcomes. We conducted a randomized field experiment across a chain of middle and high schools in Turkey, assigning teachers to receive a generative AI teaching support tool or business-as-usual control. The majority of teachers used AI for lecture material, syllabus, and exercise creation. Providing teachers with AI reduced student intrinsic motivation by 0.11 standard deviations, with students rating AI-assisted courses as less enjoyable, less interesting, and less important. The decline was more pronounced among teachers who reported heavier AI use at baseline. AI did not affect average academic performance, but among students of lower-performing teachers, it significantly reduced both academic performance and students' confidence. On average, teachers did not change their beliefs about whether AI helps or harms student learning, but teachers who had used AI more prior to the experiment became more pessimistic,

Hoe komt dit? - lesvoorbereiding

- **Ook voor ons: vervang het denken niet.**
- **Leerlingen merken het**
- **Kies waar en wanneer je werk aan AI toevertrouwt**

Interview Fien Depaepe

Leerlingen vinden lessen minder leuk als leerkracht AI gebruikt bij voorbereiding: 'Lessen boeten in aan originaliteit en persoonlijkheid'





Fien Depaepe. rv, GAH

Hoe komt dit? - buiten de les

- **Hoeveel cognitieve offloading is er?**
- **Deels: 58% tot 81%**
- **Volledig: 34% tot 50%**
- **Geen leerverlies als *time on task* gelijk blijft**

The Generative AI Learning Penalty: Evidence from Chinese Secondary Education*

David Strömberg† Victor Lei‡ Yanhui Wu§

June 2026

Abstract

Using 30 months of panel data on 26,811 Chinese students in grades 7–12, we study how generative AI affects homework productivity and learning. The data combine monthly closed-book exams, high-school and college entrance exams, and homework scores and completion time across nine subjects. We exploit staggered AI adoption in a difference-in-differences design. AI adoption raises homework scores by 18% and reduces completion time by 30%, but lowers monthly exam scores by 20% within six months. High-stakes entrance-exam scores fall by 18 and 24%, with the full penalty emerging only after about two years. The losses are largest in social science subjects, followed by STEM and languages, and are especially large for junior students, high-achieving students, and boys. The learning losses are concentrated among roughly 80% of AI users whose behavior is consistent with homework outsourcing, as indicated by exceptionally short homework completion time coupled with high homework scores. AI users who maintain similar homework completion time as non-AI users experience small learning losses.

Time on task? (OPDRACHT)

- Tijd gespendeerd aan het leren
- Hoe meer hoe beter
- Efficiënter
- Effectieve leerstrategieën
- AI-technologie *kan* helpen
- OPDRACHT



Wat nu?

- **Verbieden**
- **Laten gebeuren**
- **Zoeken naar geletterdheid**

Definieer!

> "Op school zijn ze niet per se tegen. Daar zeggen ze vaak: 'Laat het beter eens controleren door ChatGPT in plaats van het vol fouten in te dienen"

KLASSE

AI IN DE KLAS

Deel 2: AI-geletterdheid

Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

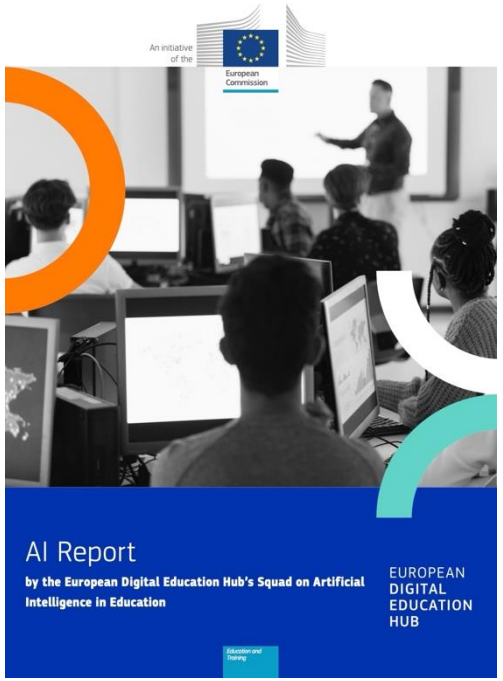
Geletterdheid

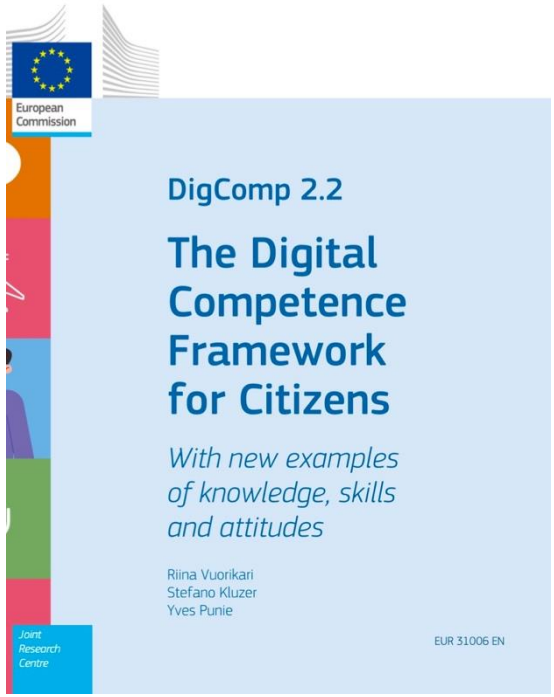
Artikel 4

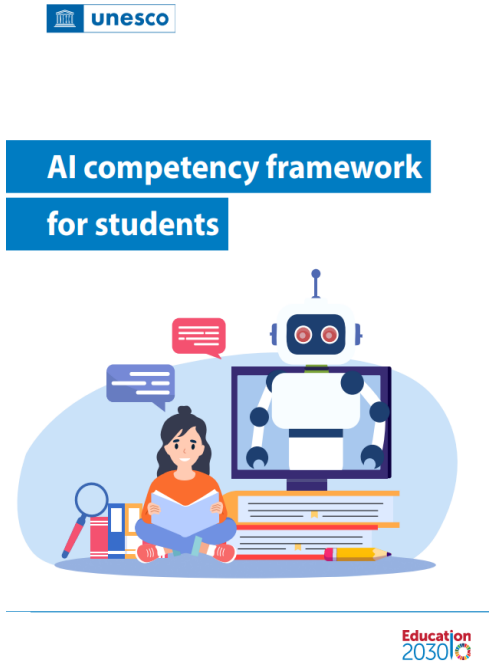
AI-geletterdheid

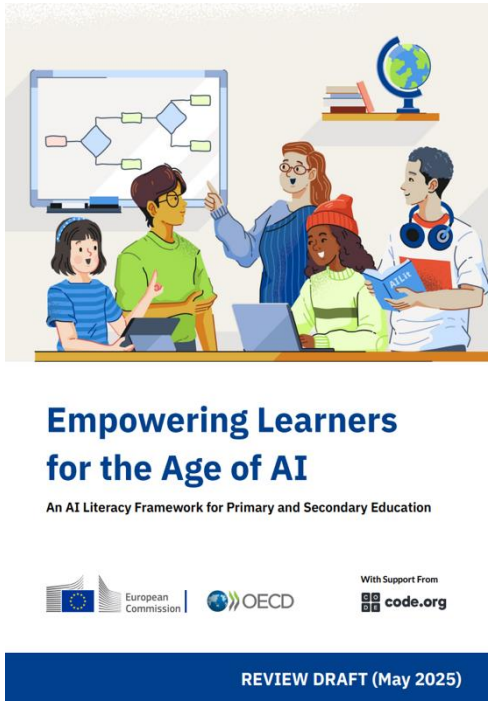
Aanbieders en gebruiksverantwoordelijken van AI-systemen nemen maatregelen om, zoveel als mogelijk, te zorgen voor een toereikend niveau van AI-geletterdheid bij hun personeel en andere personen die namens hen AI-systemen exploiteren en gebruiken, en houden daarbij rekening met hun technische kennis, ervaring, onderwijs en opleiding en de context waarin de AI-systemen zullen worden gebruikt, evenals met de personen of groepen personen ten aanzien van wie de AI-systemen zullen worden gebruikt.

Geletterdheid



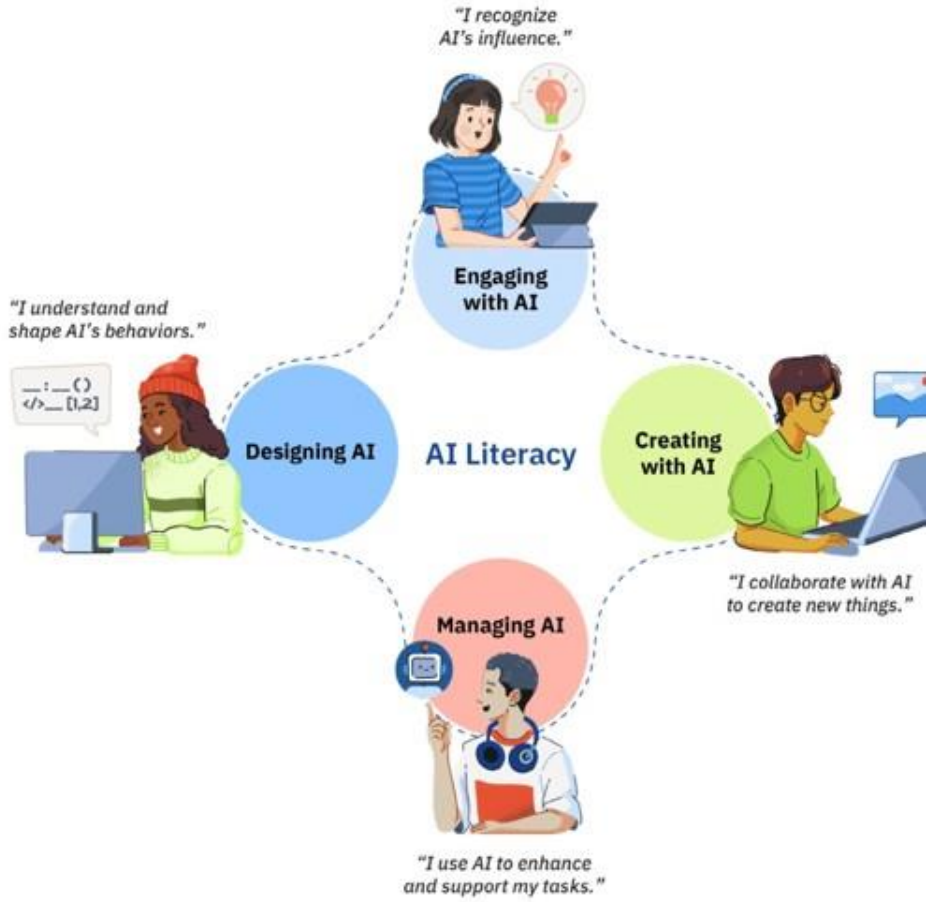






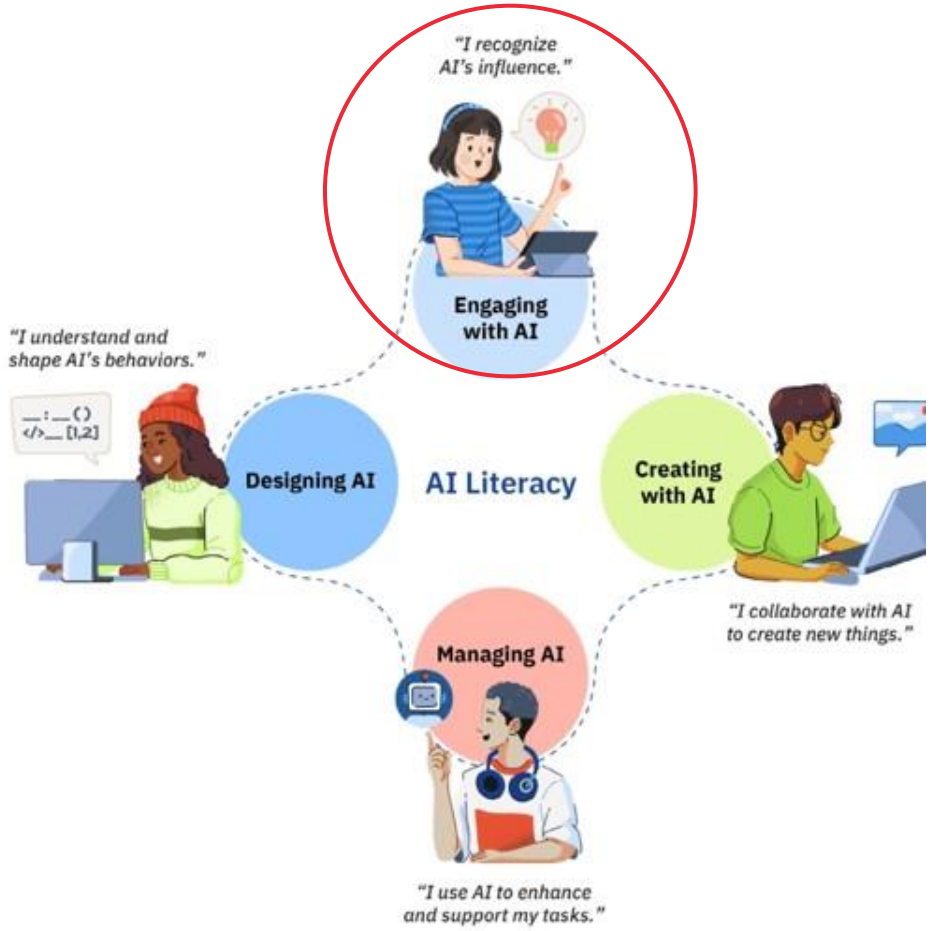
Geletterdheid





Geletterdheid



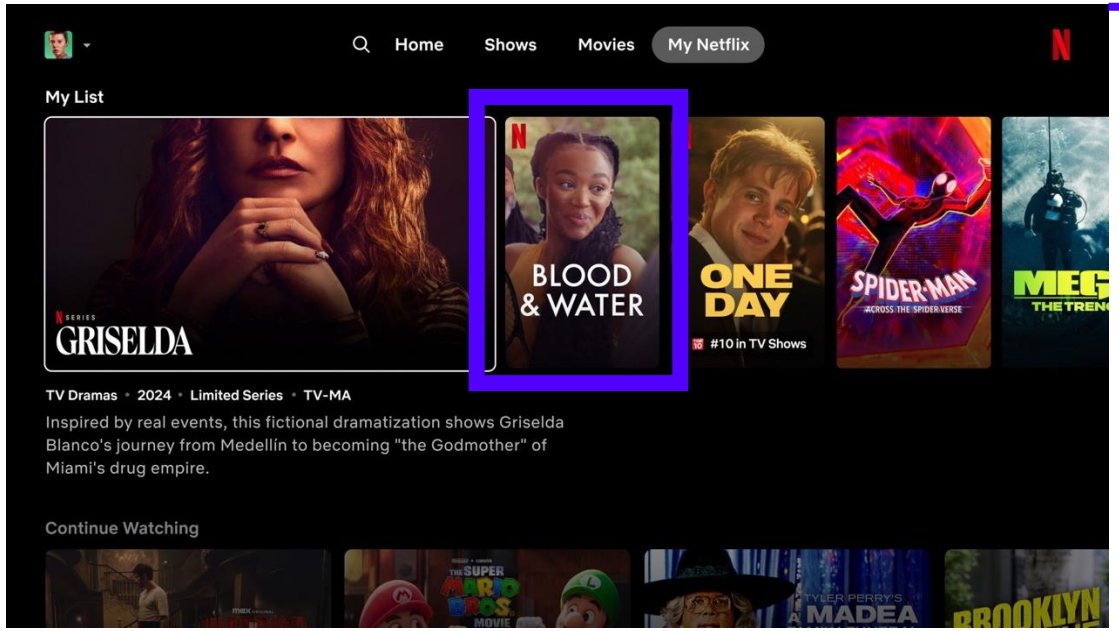


Geletterdheid naar leerlijn





Geletterdheid naar leerlijn



COMPETENTIE:
Begrijpen hoe zoekmachines, sociale media en bepaalde apps algoritmes voor inhoudsaanbevelingen gebruiken om de gebruikerservaring te personaliseren en te optimaliseren.



Geletterdheid naar leerlijn

COMPETENTIE:
Begrijpen hoe zoekmachines, sociale media en bepaalde apps algoritmes voor inhoudsaanbevelingen gebruiken om de gebruikerservaring te personaliseren en te optimaliseren.

DIDACTISCHE WENK: MAAK KENNIS MET AVA

Opdracht:

- Leerlingen maken een foto of screenshot van de homepagina van een streamingplatform dat zij gebruiken.

Benodigdheden:

- Leerlingen hebben toegang nodig tot een streamingapplicatie.
- Voor leerlingen die dat niet hebben, kan je als docent alternatieven aanreiken door bijvoorbeeld een map met voorbeelden aan te bieden. Je kan hen ook een mock-up homepagina laten ontwerpen in presentatiesoftware zoals PowerPoint of Canva.

Doelen:

- Analyseer en bespreek de personalisatie van de content en hoe die de kijkgewoonten van gebruikers weerspiegelt.
- Begrijp de werking en impact van inhoudsaanbevelingsalgoritmes, zoals de AVA-technologie van Netflix.
- Onderzoek de bredere implicaties van gepersonaliseerde content en filterbubbels op mediaconsumptie en blootstelling aan diverse perspectieven.

Lesfases:

- **Snapshot**: vraag studenten om een foto of screenshot te maken van de homepagina van een streamingplatform.
- **Inzending en compilatie**: studenten moeten hun snapshots inleveren bij de docent, die de beelden compileert in een enkele presentatie of een galerijformaat. Op die manier kunnen verschillende startschermen naast elkaar worden vergeleken.
- **Personalisatie analyseren**: moedig de studenten aan om in de klas de verschillen tussen de startschermen te analyseren en te bespreken. Vragen om te overwegen kunnen zijn: waarom heeft de ene leerling meer actiefilms en de andere documentaires? Wat suggereert dat over hun kijkgewoonten?
- **De rol van AVA begrijpen**: introduceer het concept van de AVA-technologie van Netflix. Leg uit hoe dat AI-systeem kijkpatronen en voorkeuren analyseert om inhoud te selecteren en weer te geven. Bespreek hoe AI die beslissingen neemt en met welke factoren het systeem rekening houdt (zoals recent bekeken genres, vaak gekozen acteurs, tijd besteed aan bepaalde shows…). Daarvoor kan je gebruikmaken van de uitstekende video van Vox: 'Why your Netflix thumbnails don't look like mine.'
- **Kritisch denken**: moedig studenten aan om kritisch na te denken over de implicaties van dergelijke gepersonaliseerde inhoud. Is dat zeer handig? Beperkt het of breidt het hun kijkkeuzes uit? Zo raken we ook het begrip 'filterbubbels' aan.
- **Bredere implicaties**: breid de discussie rond die filterbubbels uit naar bredere onderwerpen zoals de impact van AI op het dagelijks leven, de balans tussen gepersonaliseerde content en blootstelling aan verschillende perspectieven. Want inhoudsaanbevelingen vind je niet alleen op Netflix, maar ook op sociale media.
- **Creatieve verkenning**: vraag studenten om hun ideale startscherm te ontwerpen op basis van hun interesses en de discussie over filterbubbels en dat vervolgens te vergelijken met het door AI gegenereerde startscherm. Hoe kan je de handigheid van gepersonaliseerde content combineren met het proeven van andere perspectieven en media?

Reflectie:

- **Reflecteer** op de persoonlijke en maatschappelijke impact van AI-gestuurde inhoudsaanbevelingen.
- **Overweeg** de voordelen van gepersonaliseerde content tegenover de risico's van een beperkte blootstelling aan diverse culturele en ideologische perspectieven.
- **Discussieer** over manieren om een evenwichtige kijkervaring te bevorderen die zowel persoonlijke interesses bedient als educatief verrijkend is.

Geletterdheid naar leerlijn

COMPETENTIE:
Begrijpen hoe zoekmachines, sociale media en bepaalde apps algoritmes voor inhoudsaanbevelingen gebruiken om de gebruikerservaring te personaliseren en te optimaliseren.



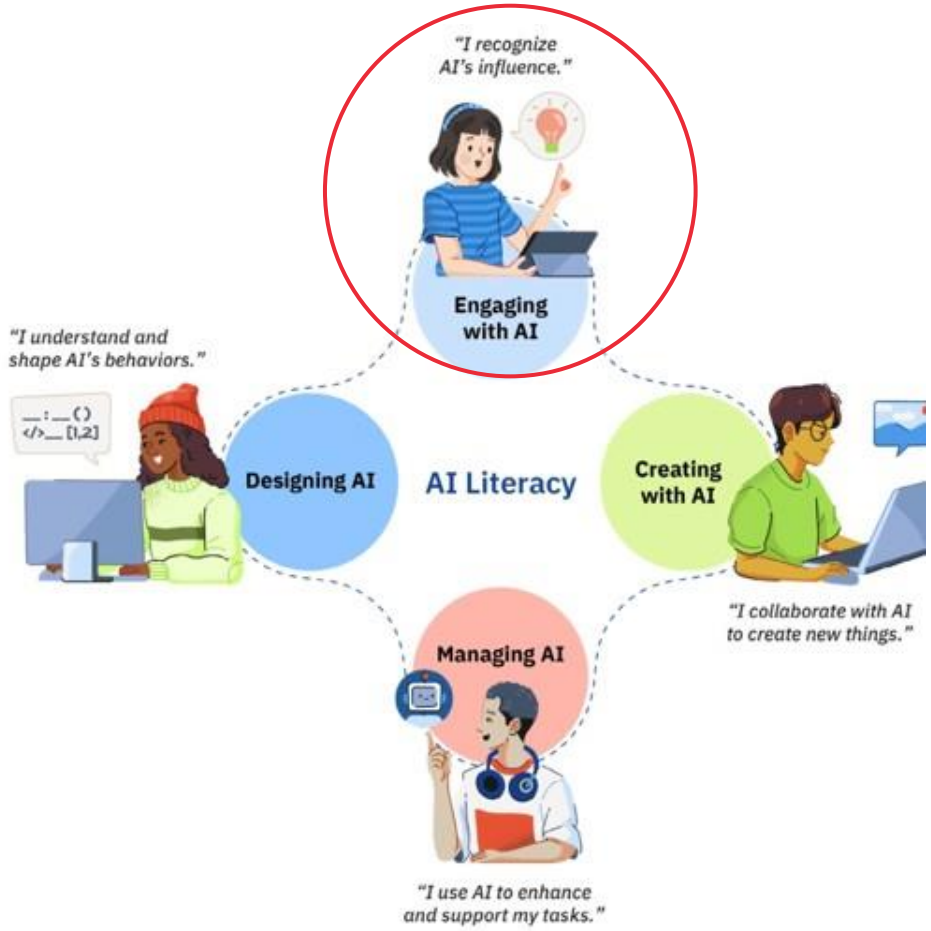


Omgaan met AI (OPDRACHT)

- Invloed van AI-technologie herkennen
- Een voorbeeld kunnen geven
- Welke impact die systemen kunnen hebben op mens als consument, burger, lerende …
- OPDRACHT – Social media
- Welke interesses heb jij online?
- Wie is wiens ‘buurman’?

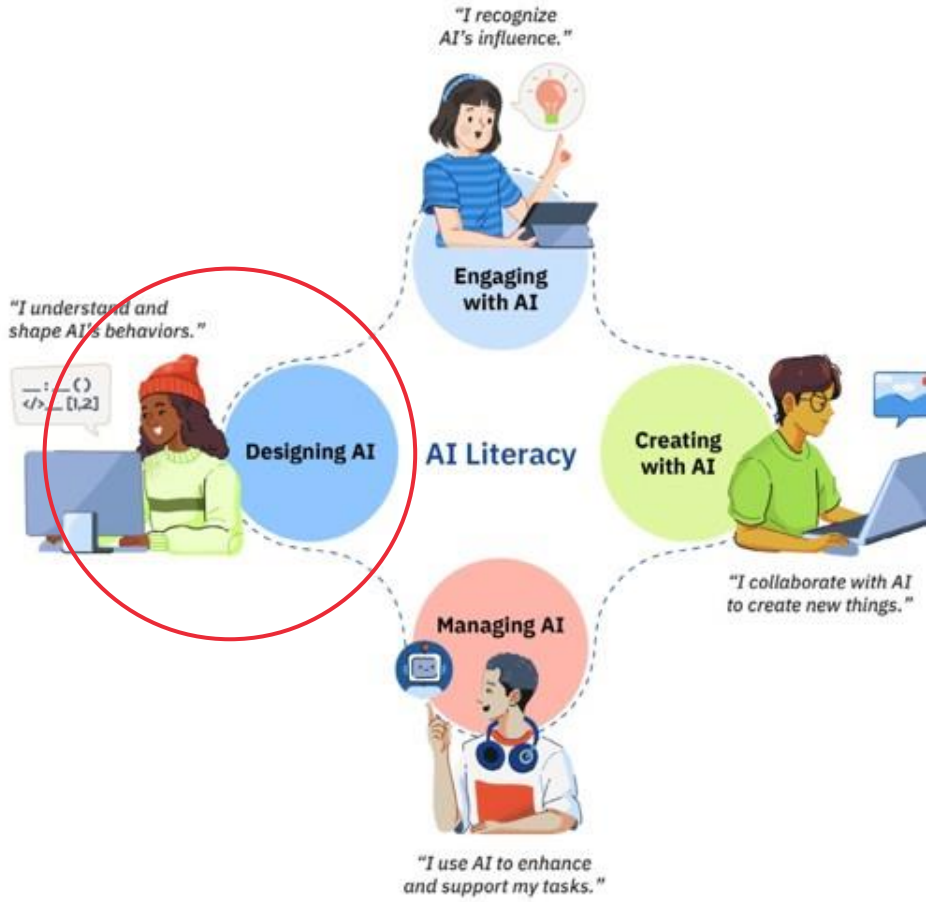
Geletterdheid naar leerlijn



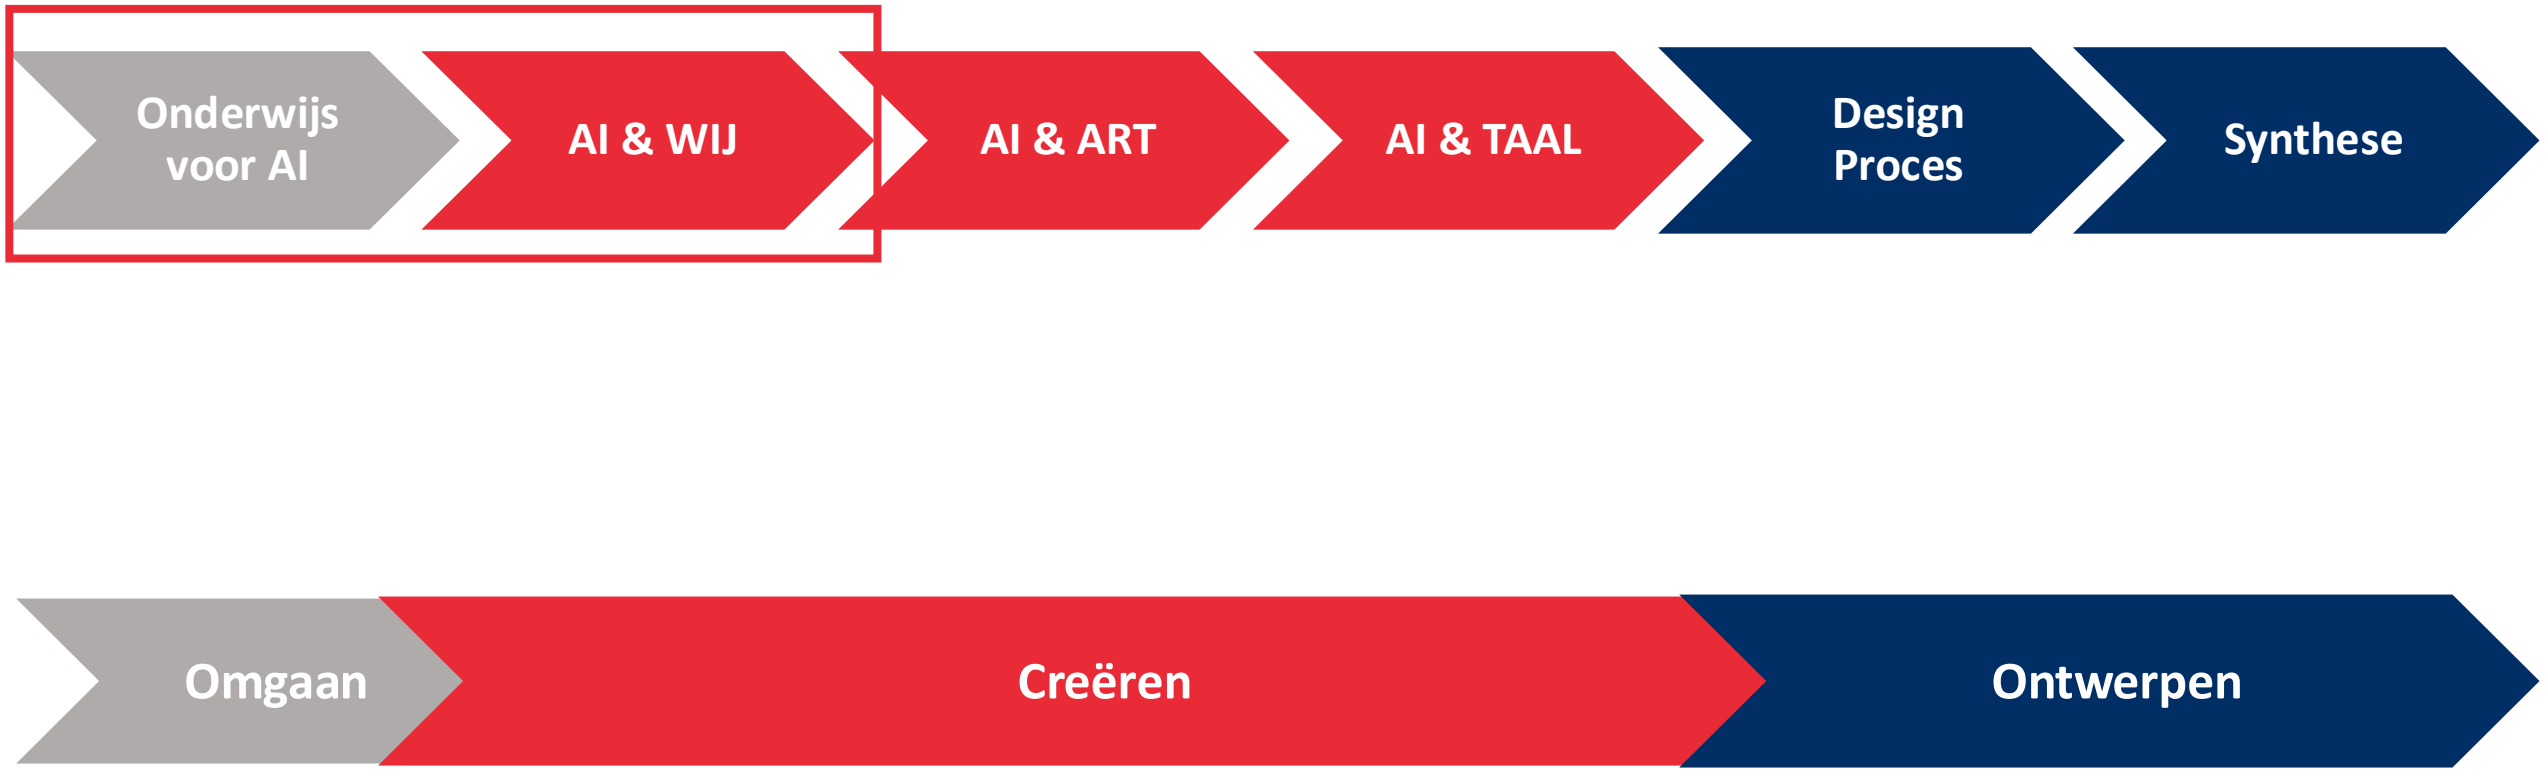


Geletterdheid naar leerlijn





Geletterdheid naar leerlijn



Geletterdheid naar leerlijn

- **Slimme Vuilnisbak**
- **Classificatie**

Onderwijs voor AI → **AI & WIJ**

- **Basis AI**
- **Machine learning**

COMPETENTIE 2:
Beschouw de ethische gevolgen van AI-systemen gedurende hun hele levenscyclus: die omvatten zowel de gevolgen voor het milieu (als gevolg van de productie van digitale apparaten en diensten) als de maatschappelijke gevolgen, bijvoorbeeld de platformisering van werk en het algoritmisch beheer die de privacy of rechten van werknemers kunnen onderdrukken, of het gebruik van goedkope arbeidskrachten voor het labelen van beelden om AI-systemen te trainen.

Omgaan → **Creëren** → **Ontwerpen**

Doel Project

- Slimme vuilnisbak bouwen
- Wat doet die?
- Menselijk gedrag imiteren
- Imitatie = sorteren
- Hoe bouw je zo een algoritme?



Hoe leert AI?

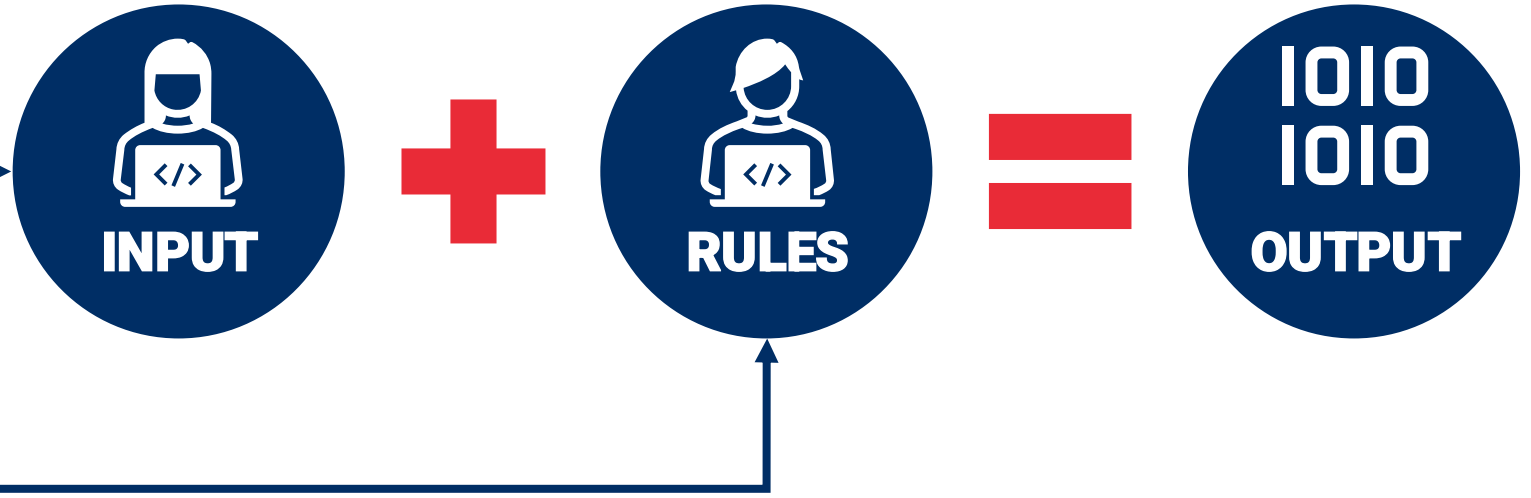
- **Blokken = instructies**
- **Instructies stapelen**
- **JIJ (mens) ziet het patroon!**
- **JIJ (mens) bouwt de code!**
- **Expertsysteem!**





Hoe leert AI?

- **Blokken = instructies**
- **Instructies stapelen**
- **JIJ (mens) ziet het patroon!**
- **JIJ (mens) bouwt de code!**
- **Expertsysteem!**



Hoe leert AI?

- Wanneer botst deze aanpak op de limiet?
- Beschrijf dit blikje met code, blokken …
- Patroon onduidelijk!

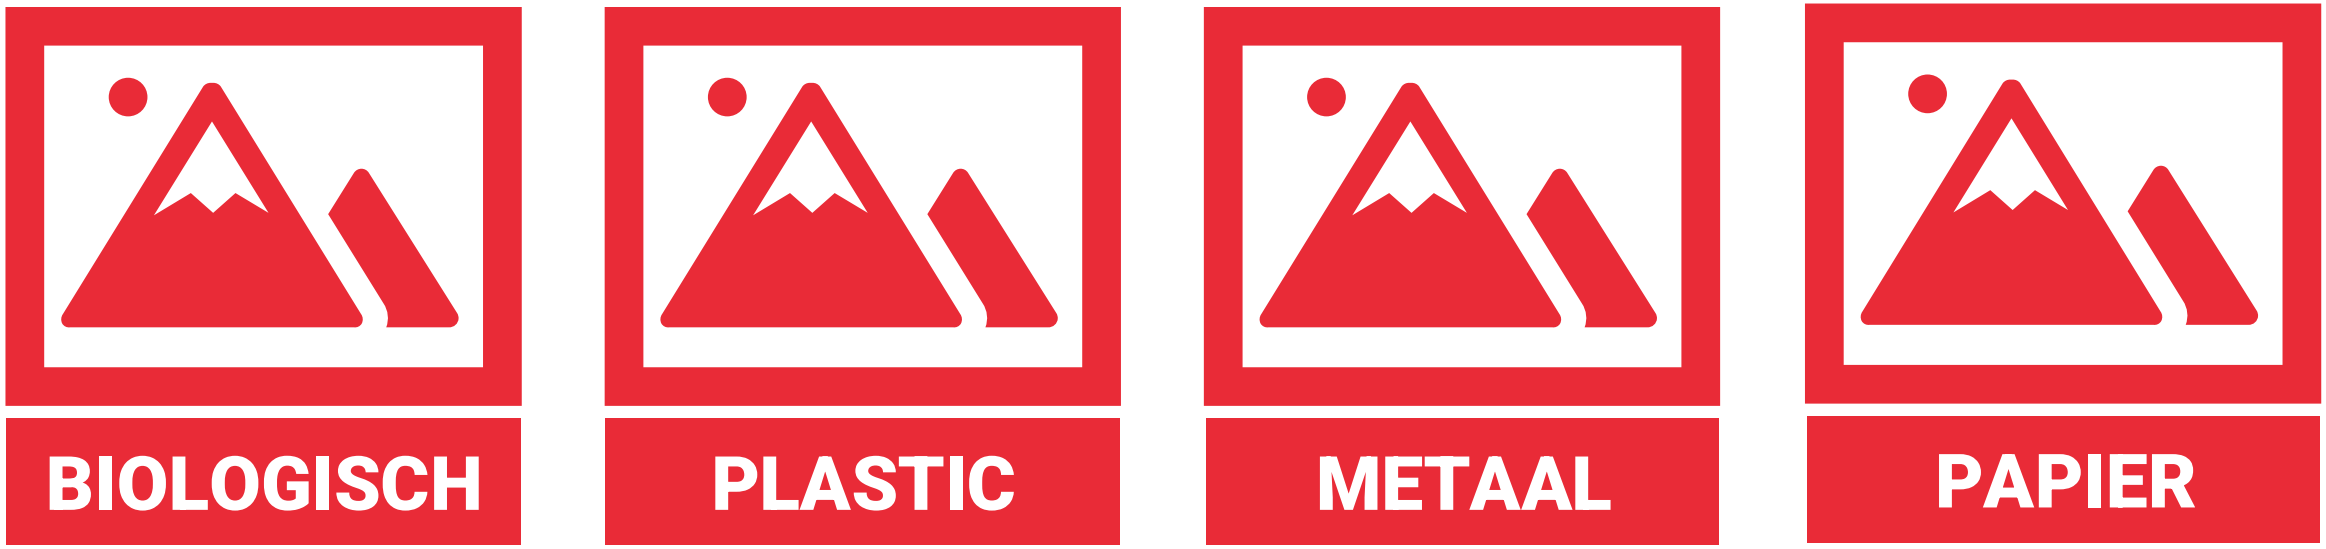


- **Traditioneel programmeren duurt lang**
- **Machine learning**
- **Tonen van data**
- **Neuraal netwerk zoekt patronen**
- **AI als tool**



Leerstrategie voor neurale netwerken

- Hoe leert zo een neuraal netwerk?
- Wij, mensen, kennen de data labels toe
- Leggen afbeeldingen in stapeltjes!



Hoe leert AI?

INPUT

RULES

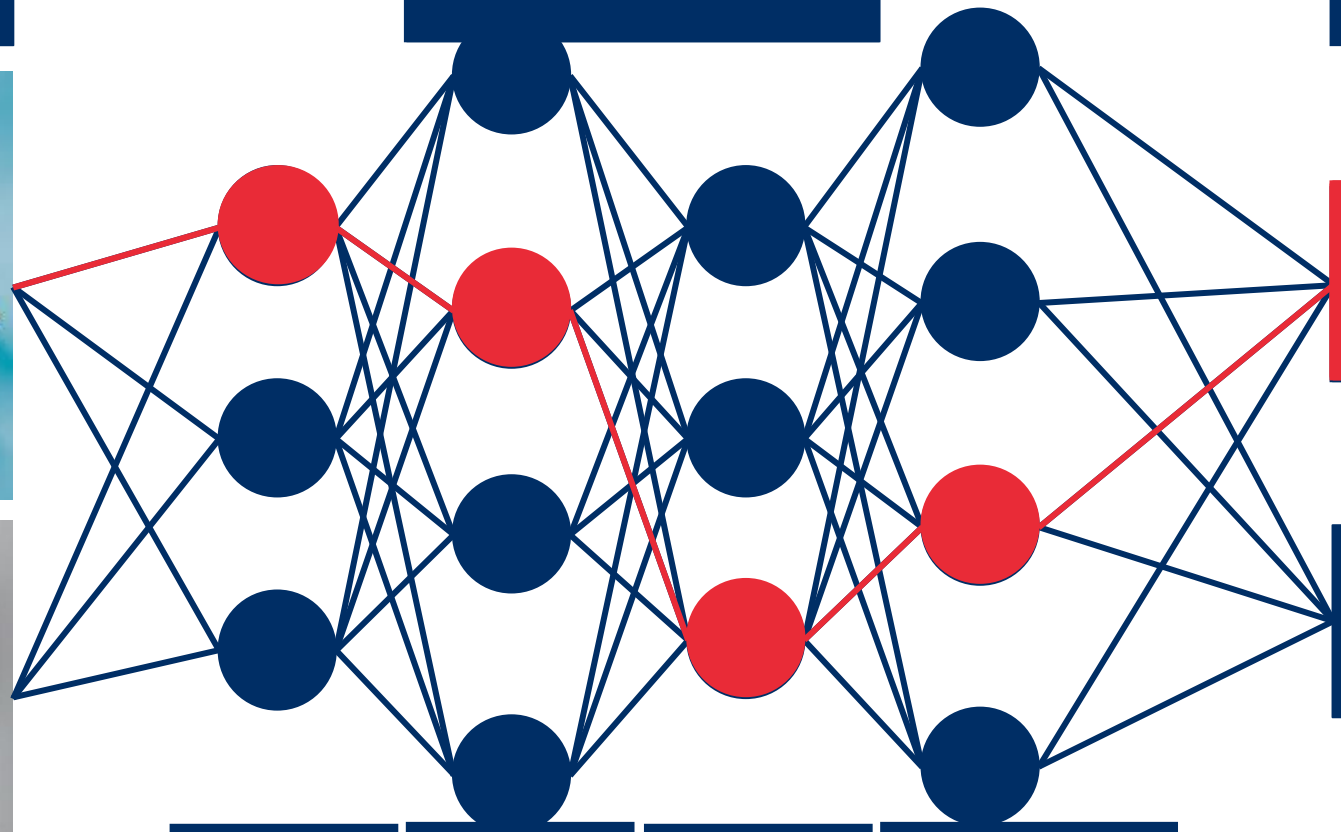
OUTPUT

1100110100



1110100





BIO

METAAL

EDGES

SHAPES

COLORS

PATTERNS

Wat kan je hiermee maken?





Slimme Vuilnisbak

1 - Biologisch

2 - Plastic

3 - Metaal

4 - Papier

Dit is een educatief AI-prototype met aangepast materiaal van het Sint-Lievenscollege Gent. Dit werd gemaakt voor educatief gebruik door Robbe Wulgaert (www.robbewulgaert.be) voor zijn vak 'AI & Design Thinking'.

Meer info: robbe.wulgaert@sintlievenscollege.be



Slimme Vuilnisbak

1 - Biologisch

2 - Plastic

3 - Metaal

4 - Papier

Dit is een educatief AI-prototype met
aangepast materiaal van het Sint-Lievenscollege Gent.
Dit werd gemaakt voor educatief gebruik door
Robbe Wulgaert (www.robbewulgaert.be)
voor zijn vak 'AI & Design Thinking'.

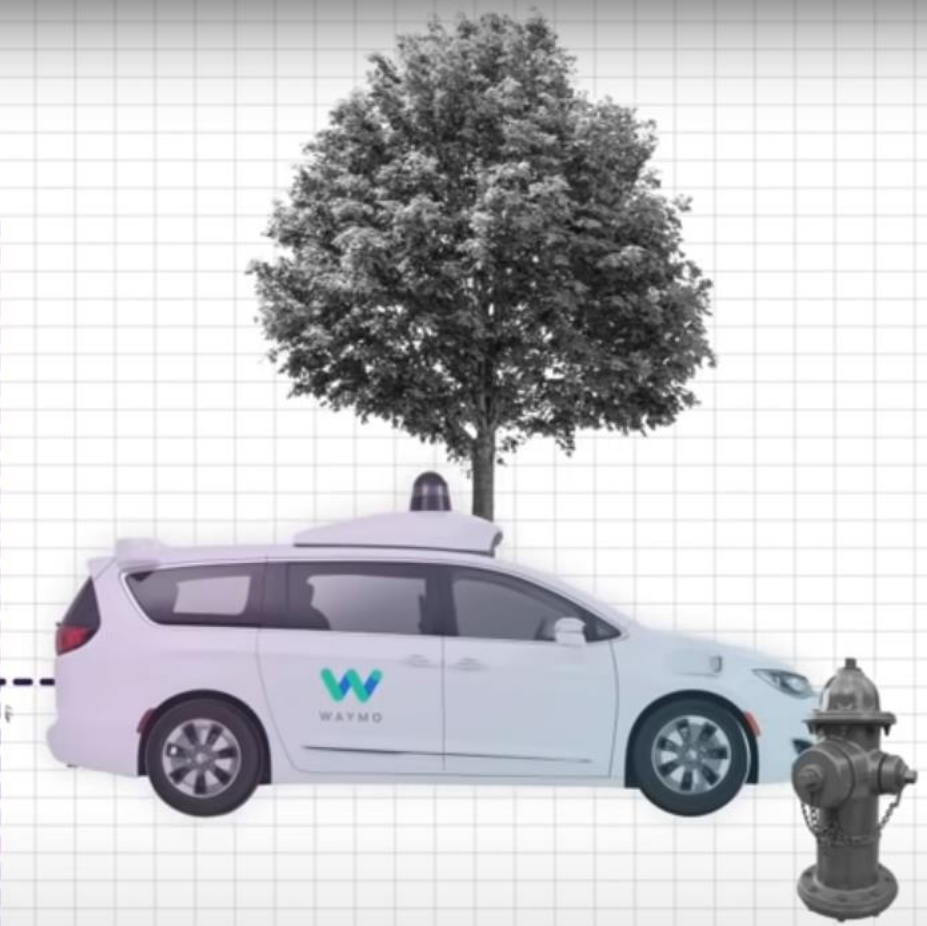
Meer info: robbe.wulgaert@sintlievenscollege.be

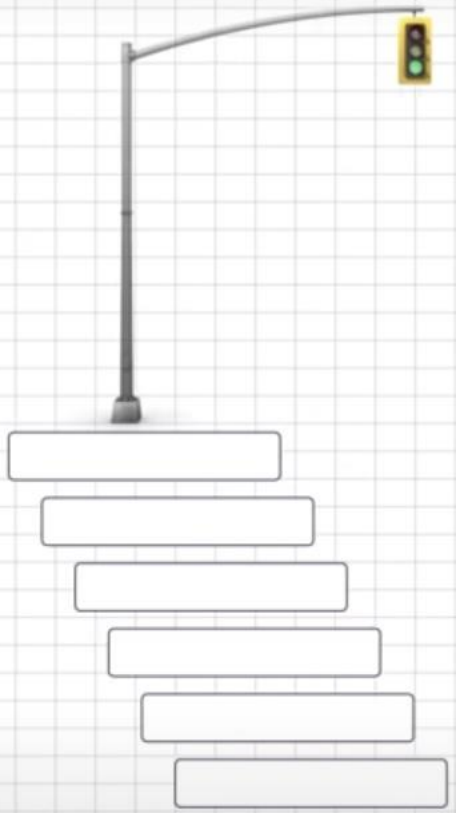
Why captchas are getting harder









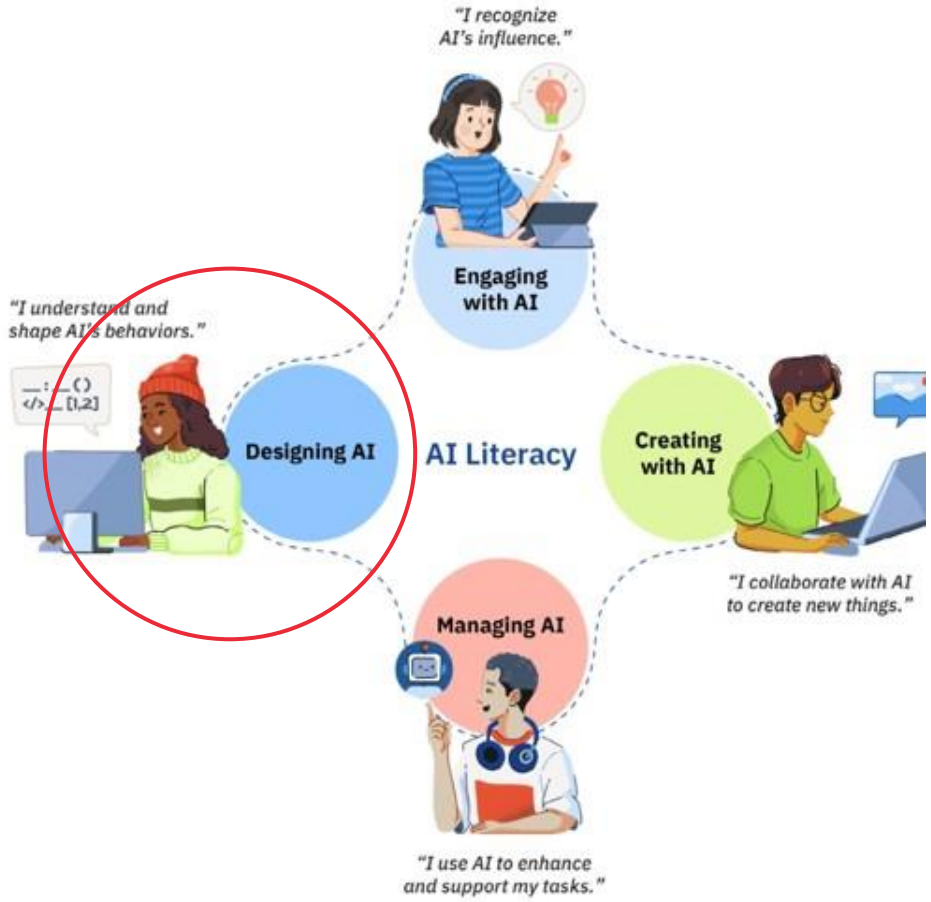


Ondertiteling (c)

5:31 / 8:03

Geletterdheid naar leerlijn





Geletterdheid naar leerlijn



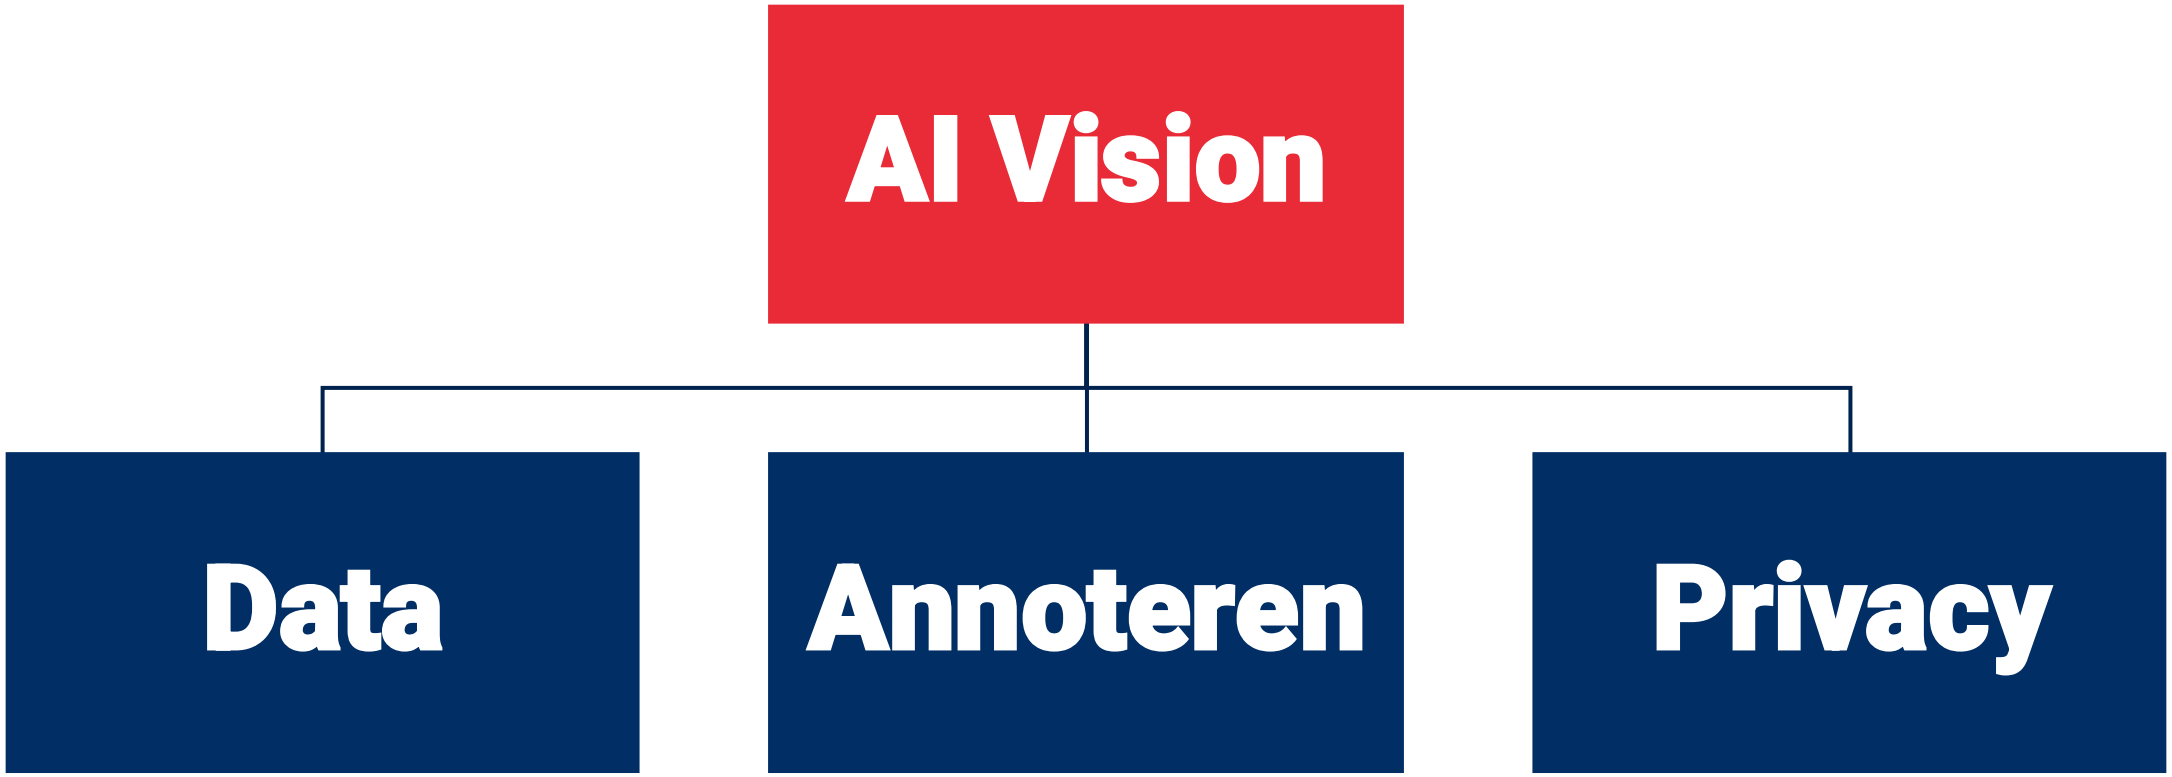


Modulair Lespakket

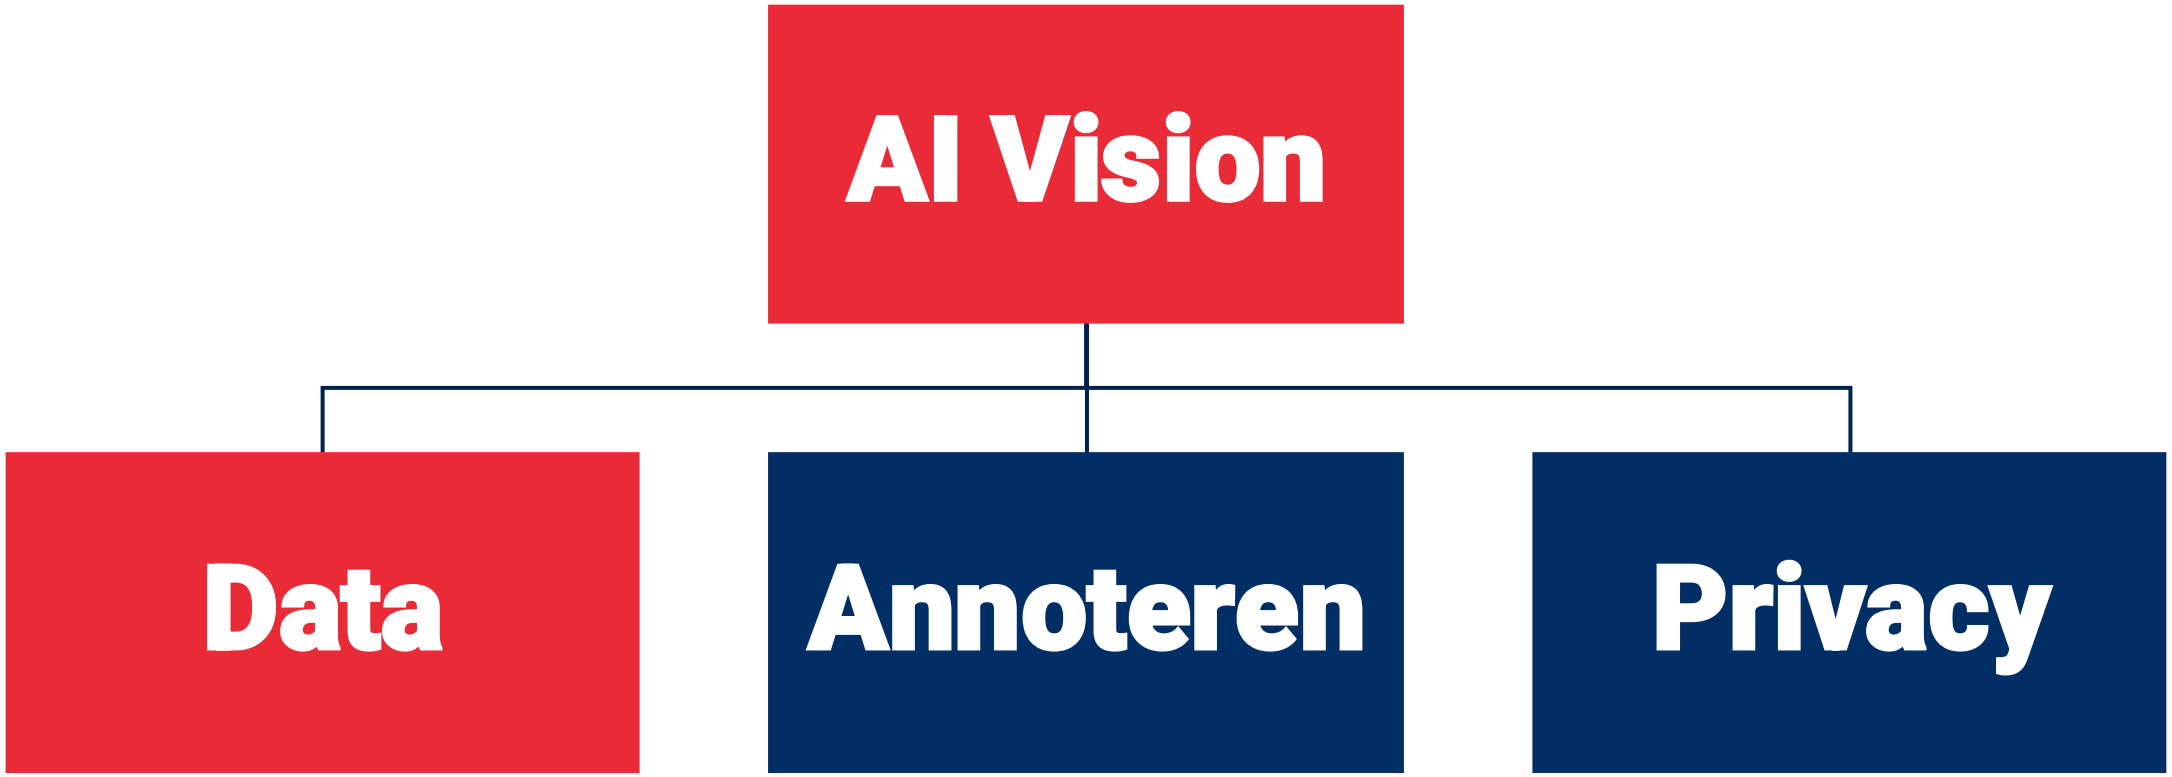
- **Level 1: enkel werken aan online AI-model**
- **Level 2: offline draaien van AI-model**
- **Level 3: gebruikmaken van Micro:bit als output**
- **Level 4: gebruikmaken van Arduino als output**

Beschikbare tijd, achtergrond leerlingen, aanknopingspunten school … bepalen de diepgang.

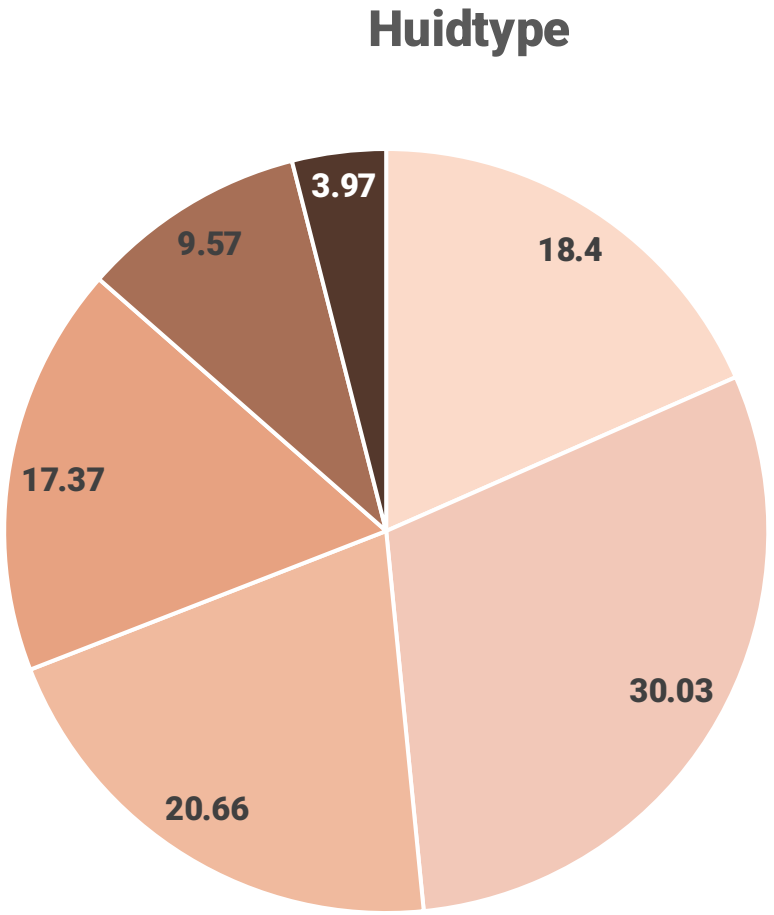
Risico's?

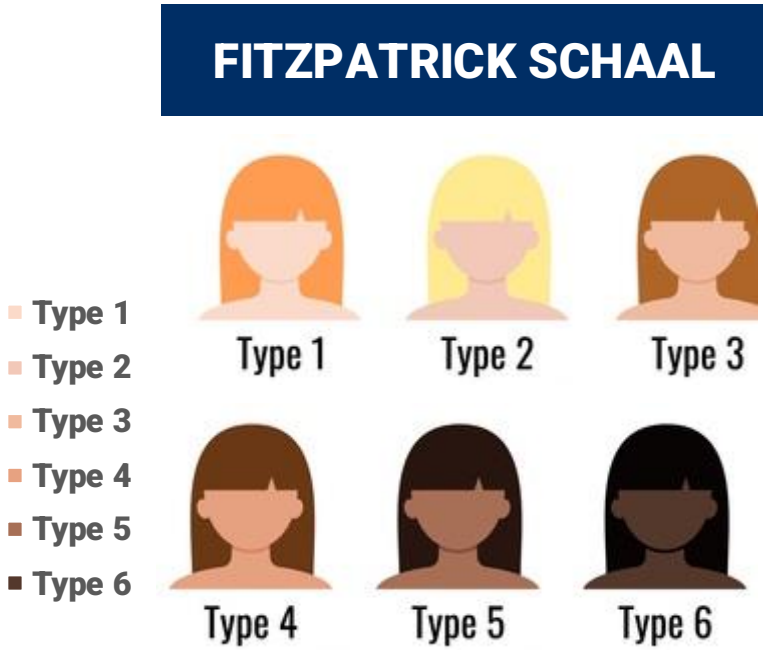


Risico's?

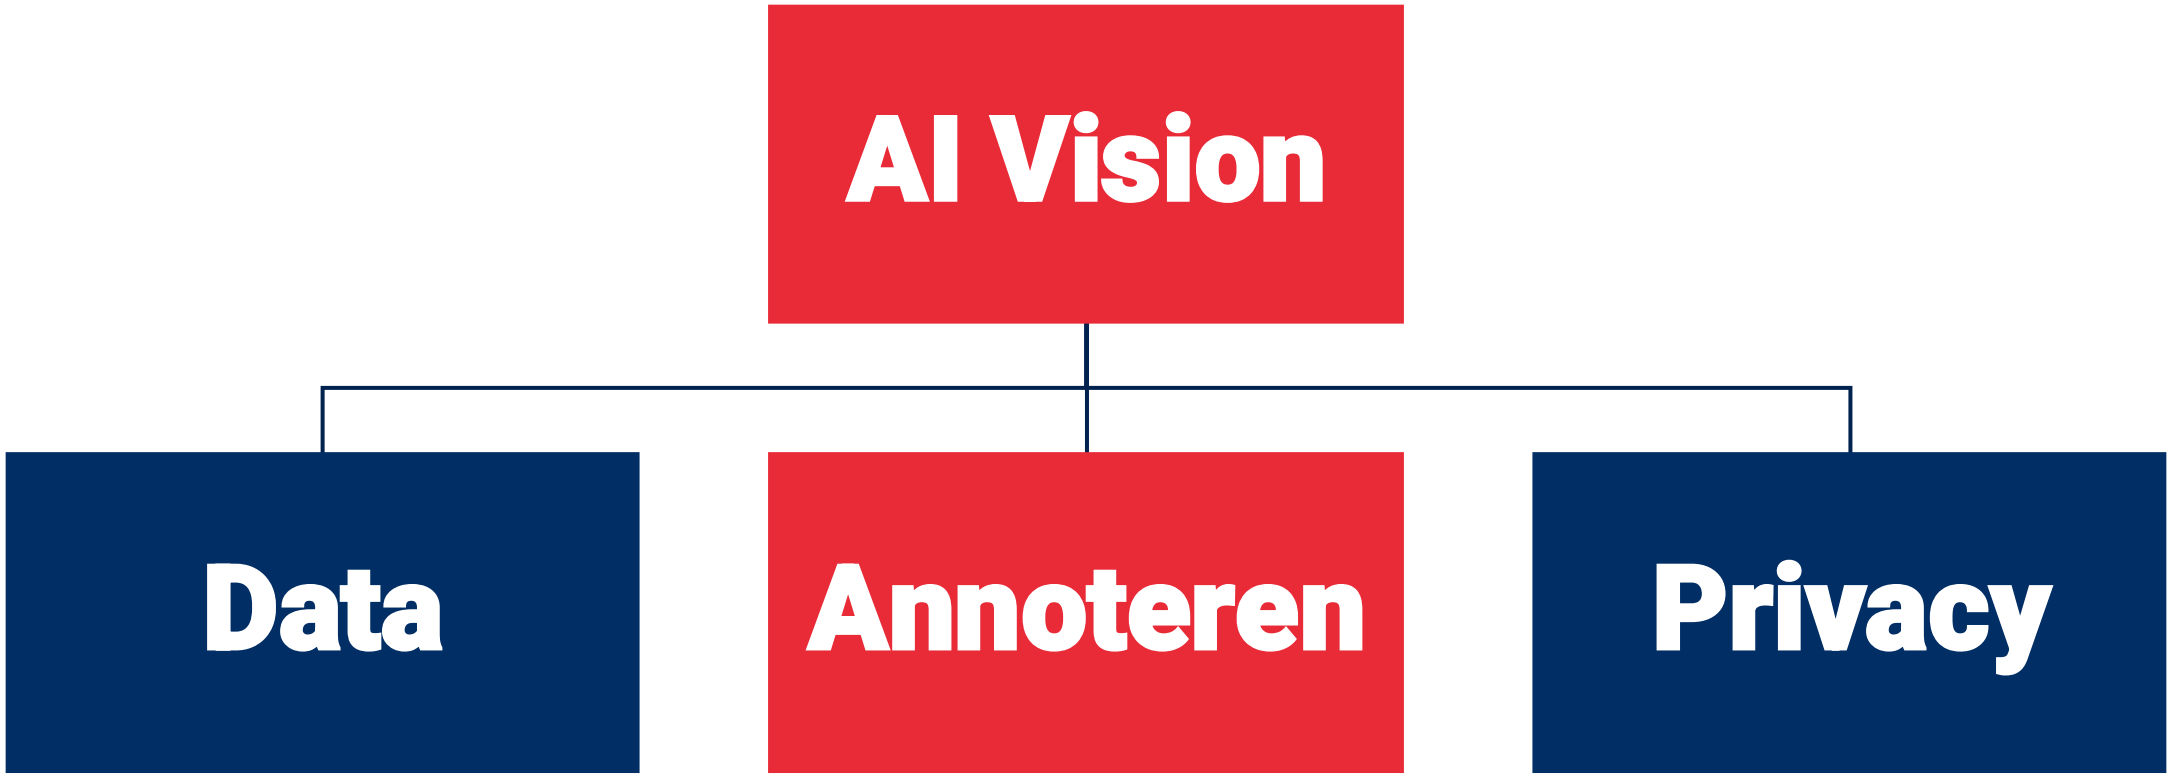


Data


Huidtype
18.4
30.03
20.66
17.37
9.57
3.97

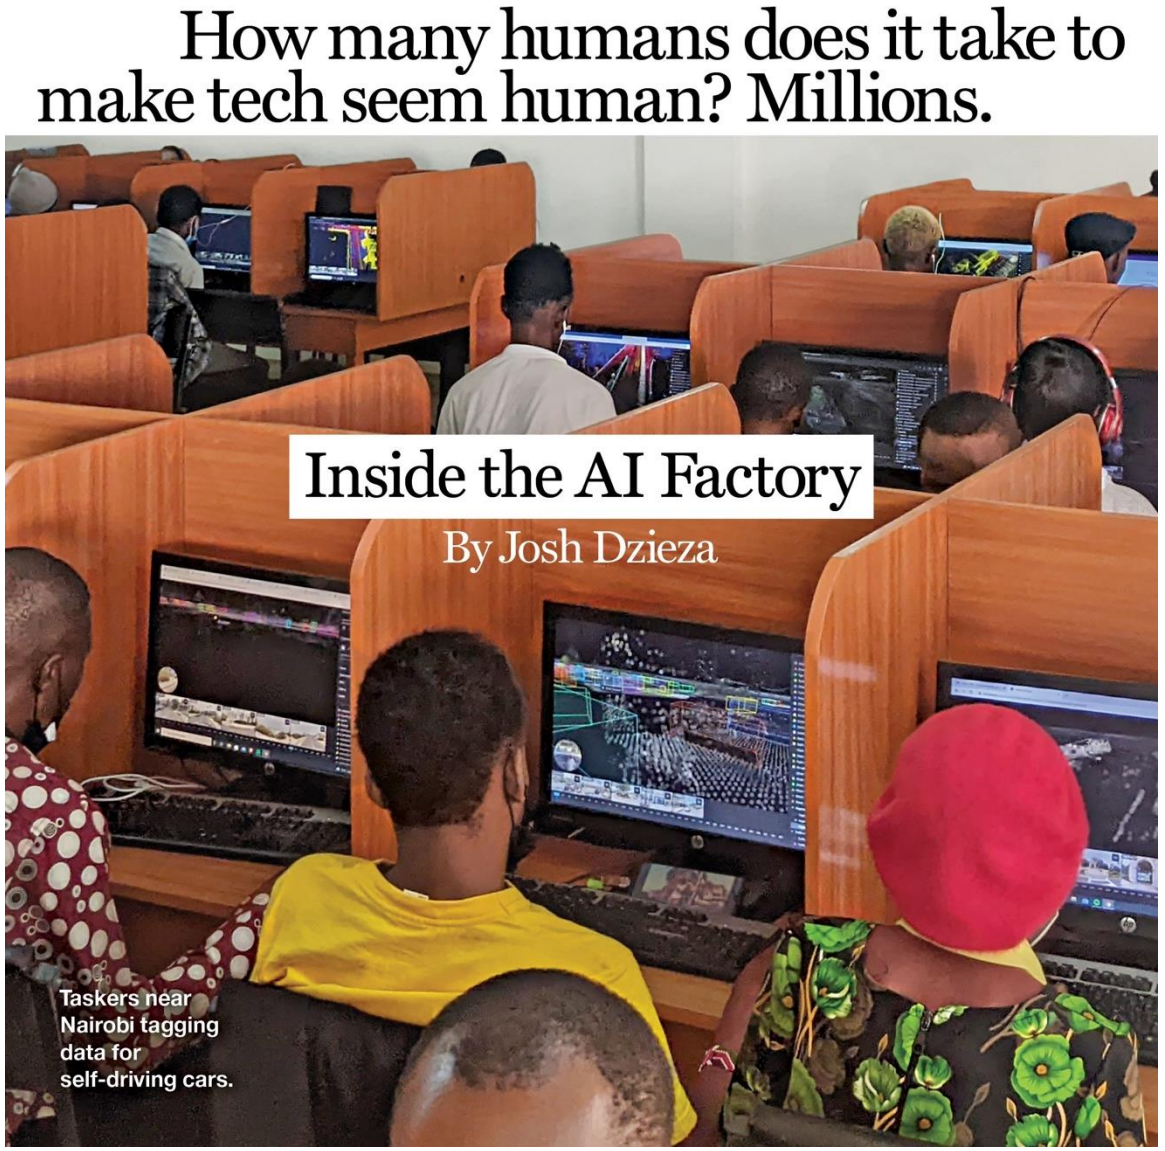

FITZPATRICK SCHAAL
Type 1
Type 2
Type 3
Type 4
Type 5
Type 6
Type 1
Type 2
Type 3
Type 4
Type 5
Type 6

Risico's?

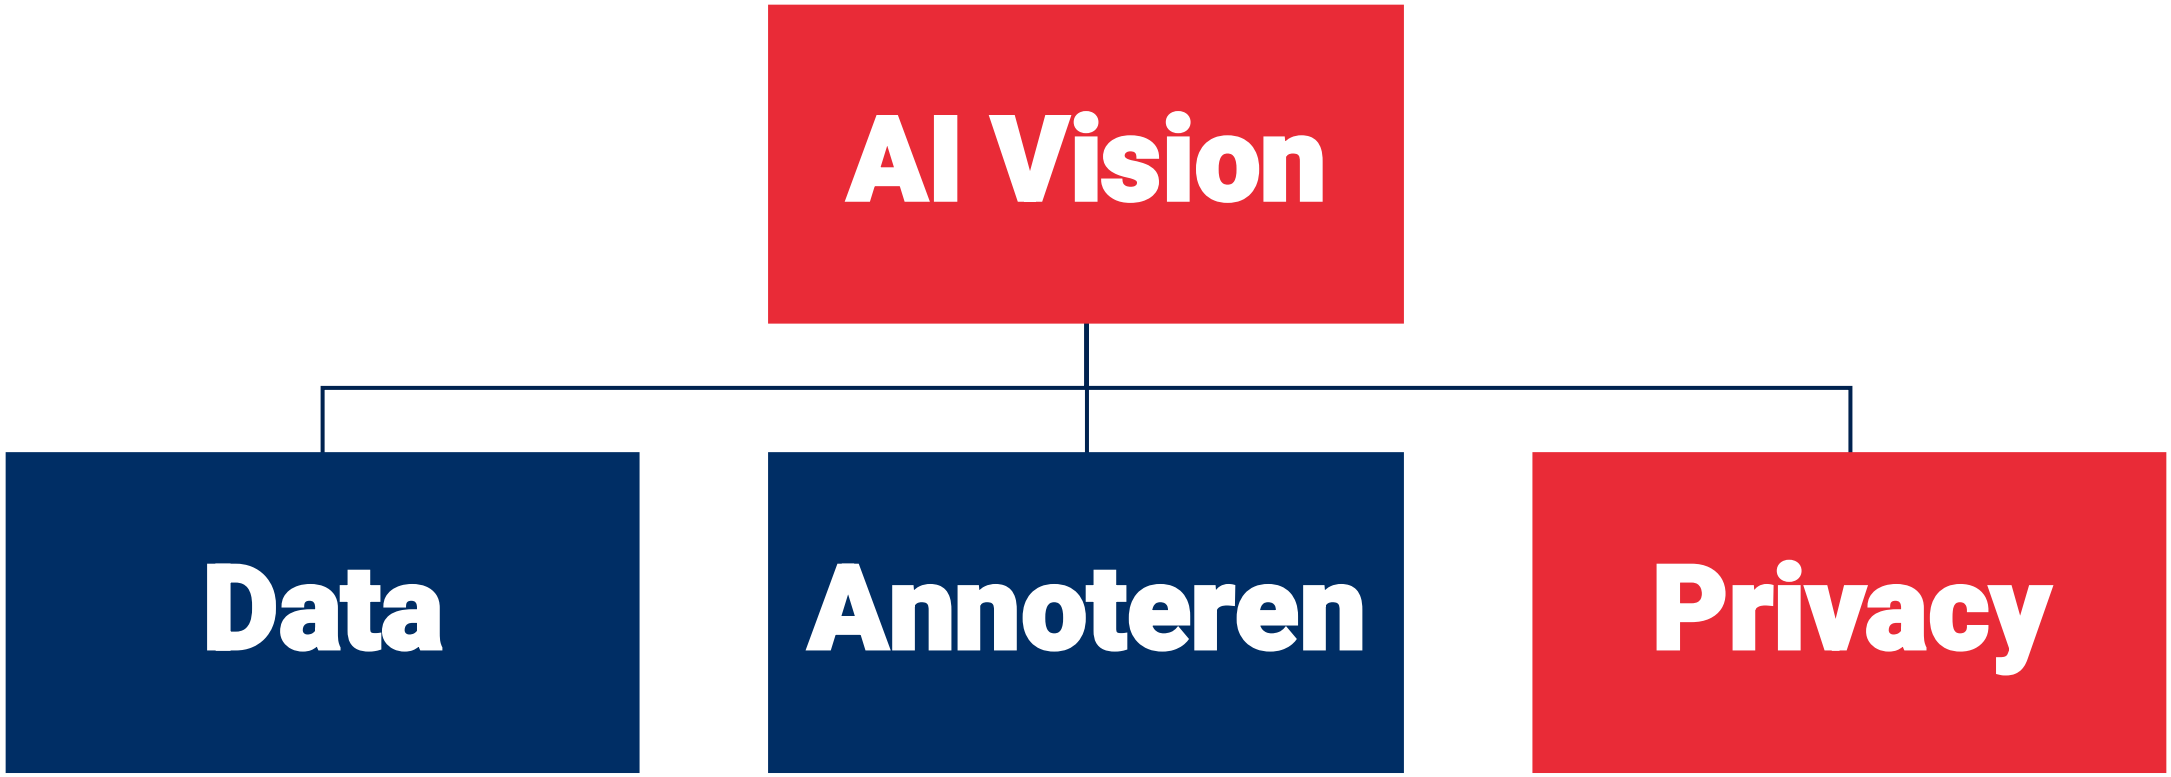


Annoteren

- Supervised learning
- Mensen annoteren data
- Wat met grote datasets?
  - CAPTCHA
  - Outsourcing
  - Silicon Savannah
- Wat met foute annotaties?



Risico's?

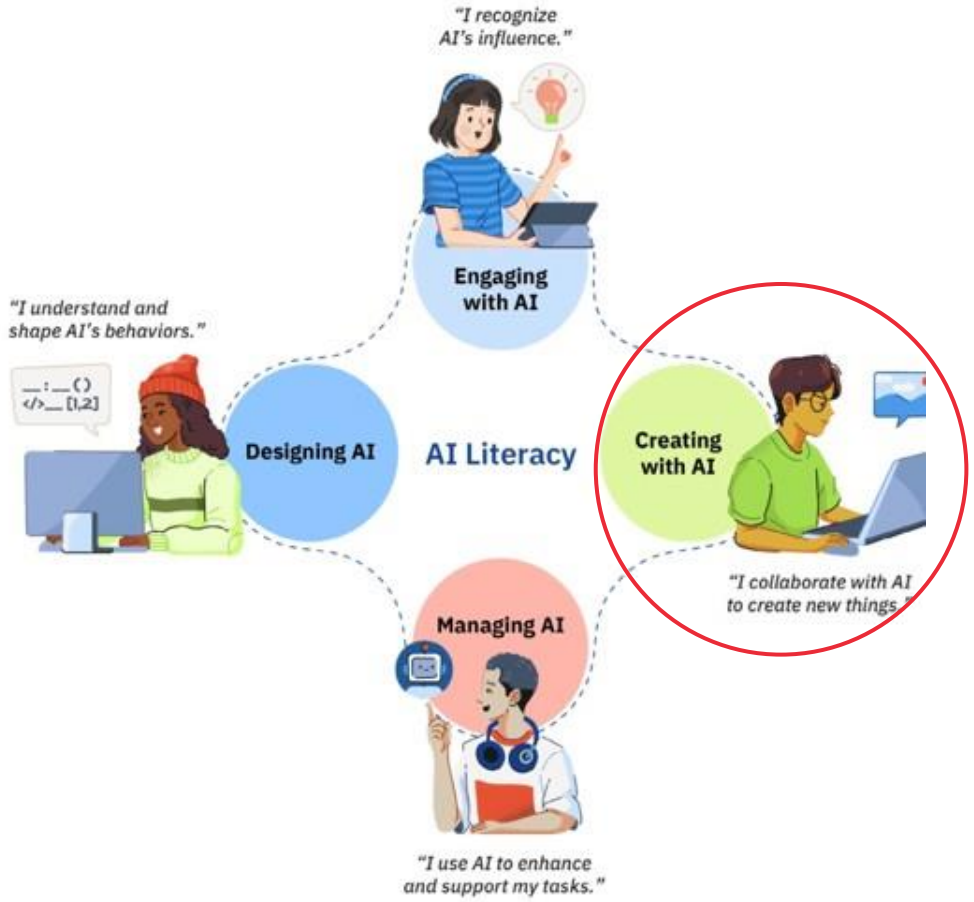


Privacy

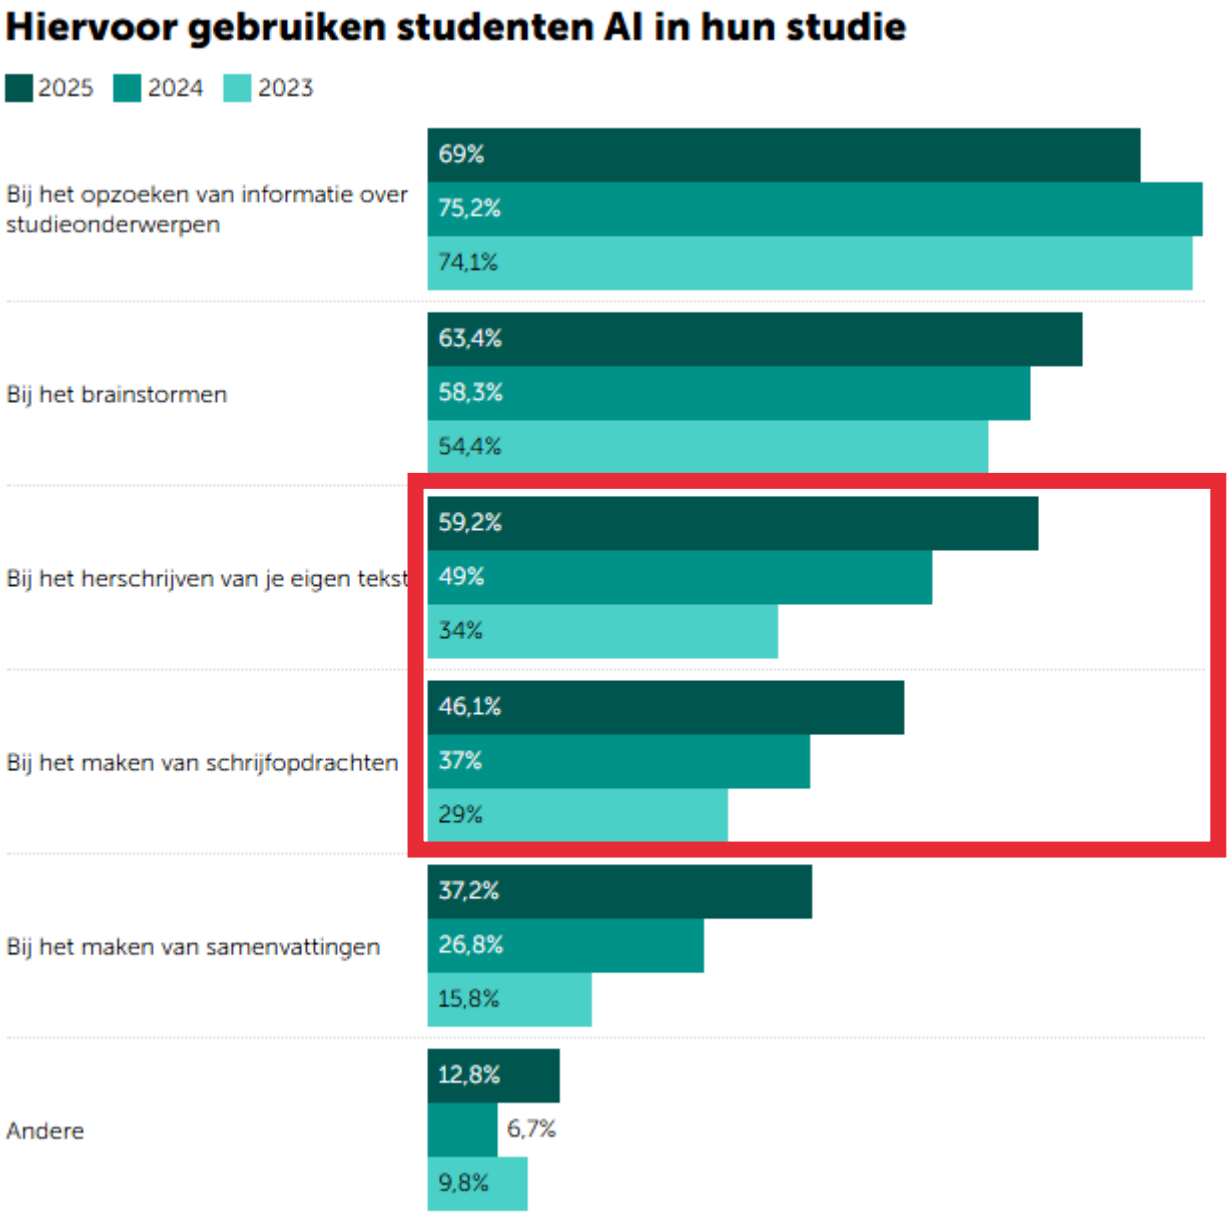

@wbeke 51.9%
@Zu_Demir 71.8%
PHONE 85.5%
PHONE 76.9%
@JanJambon 67.0%
@BartSomers 51.9%
PHONE 81.2%
PHONE 61.2%

Geletterdheid naar leerlijn





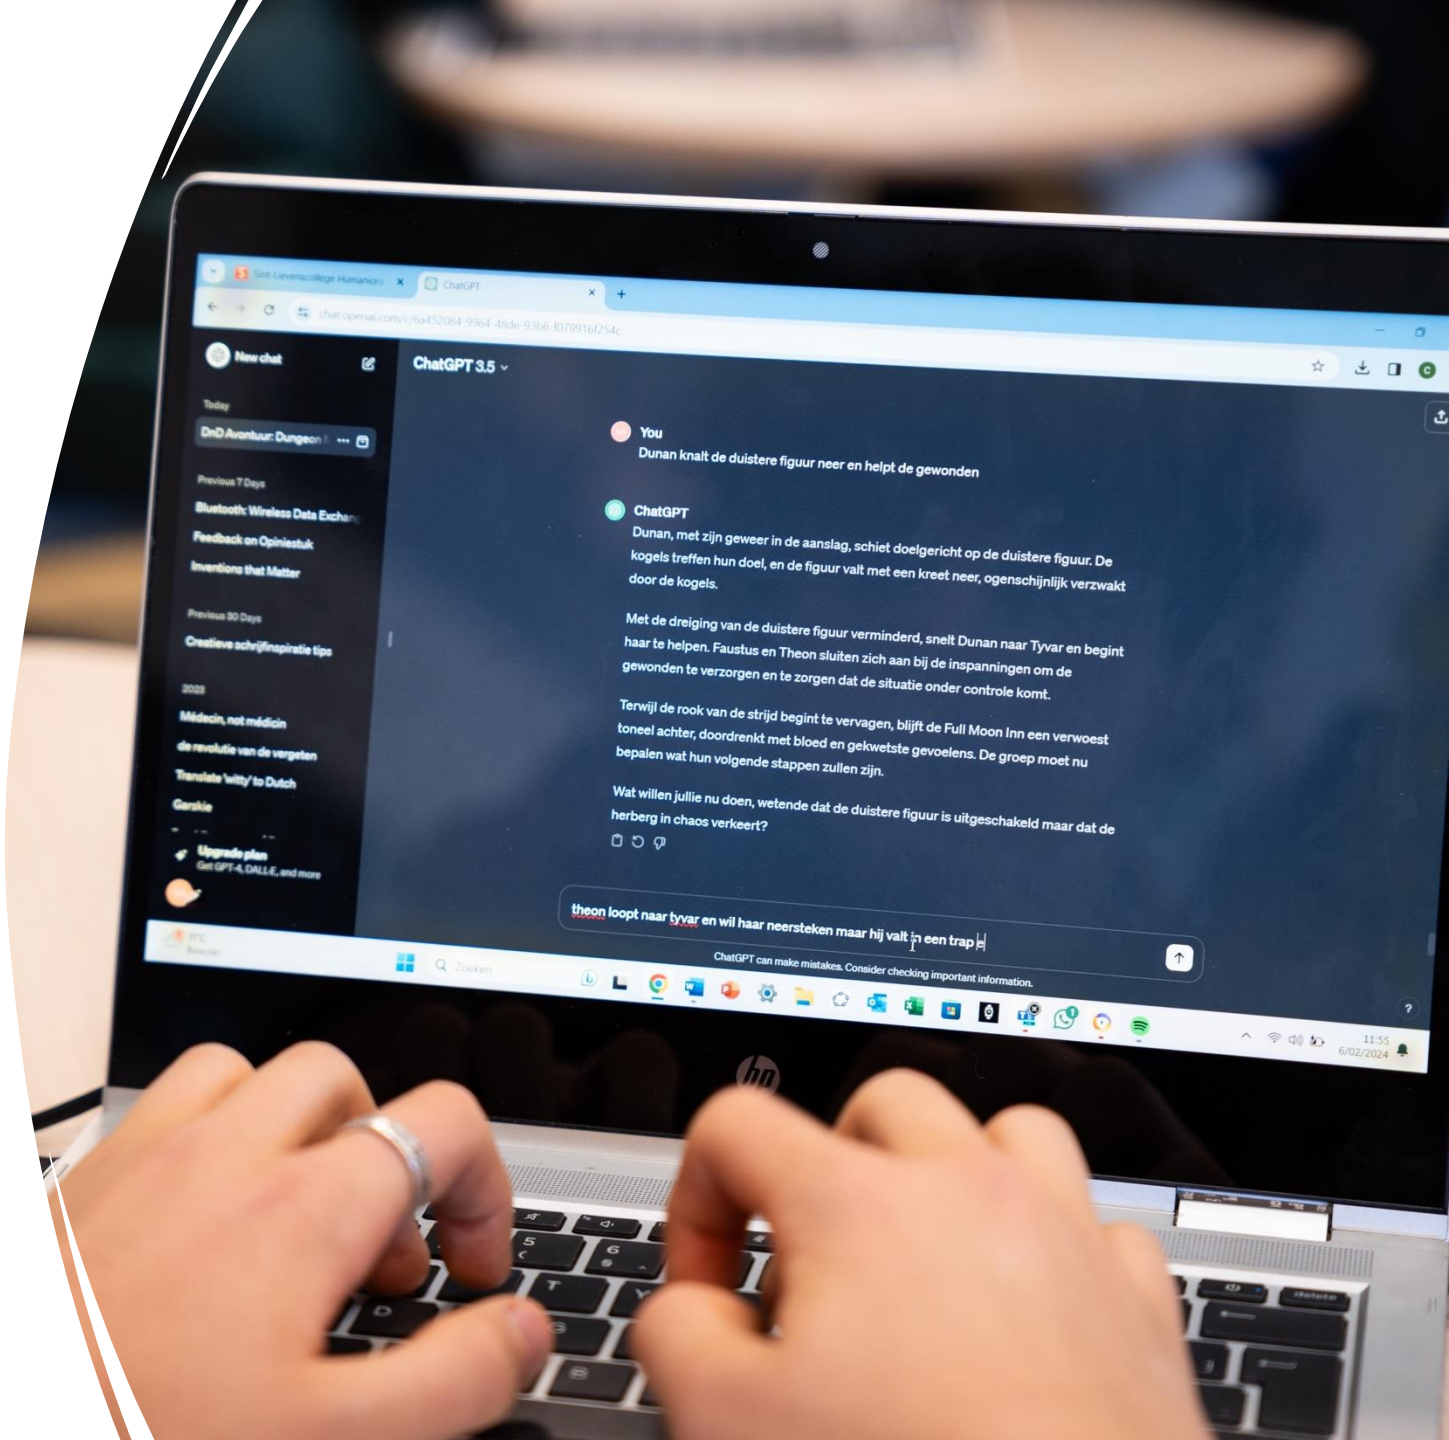
Soort gebruik?



BRON: ACCO

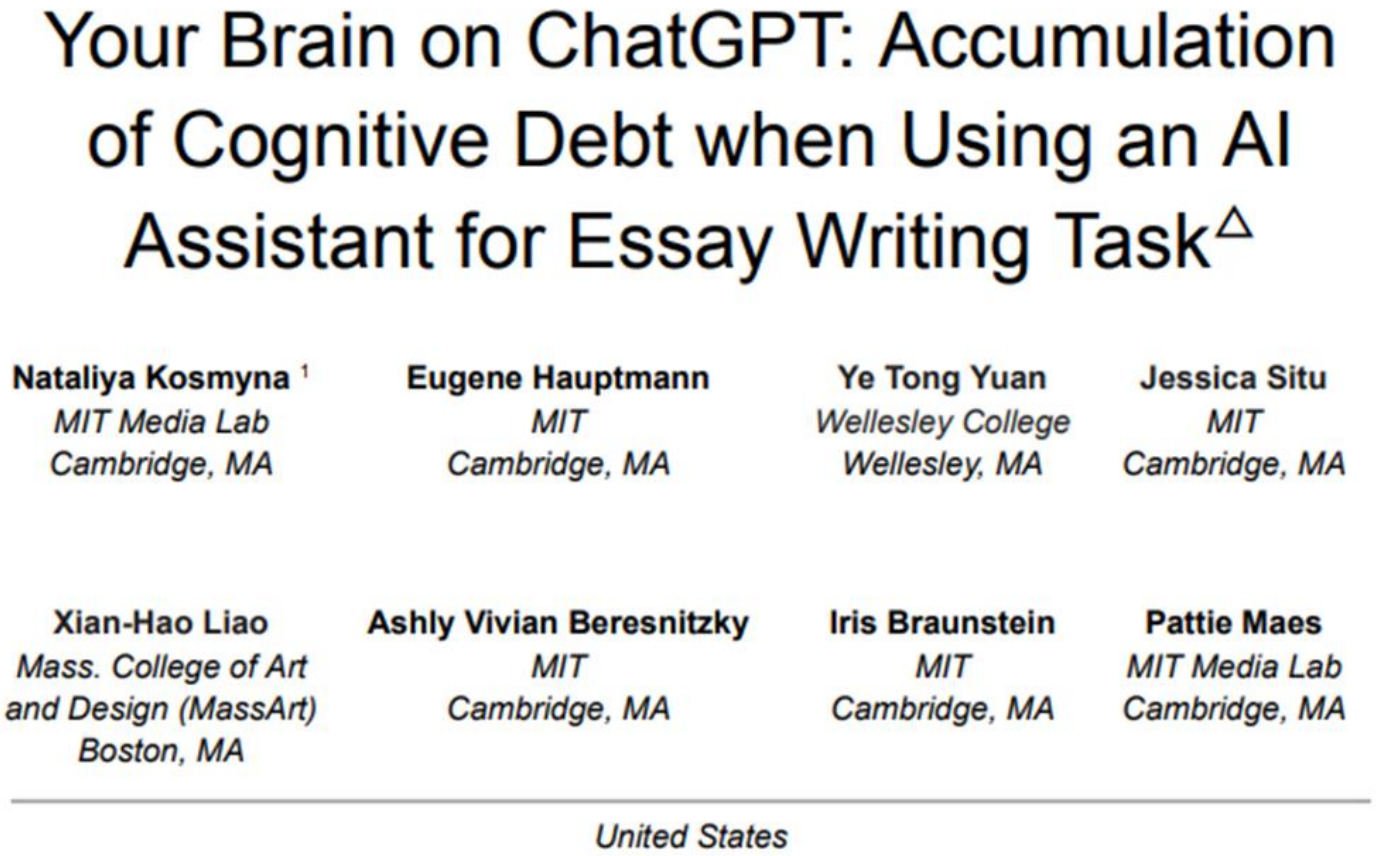
Creëren met AI

- **OPDRACHT**
- **Welke superkracht zou jij willen als schoolleider?**
- **Groep 1: eerst zelf**
- **Groep 2: eerst AI**
- **Telkens 5 min**



Creëren met AI

- **Schrijftaak**
- **Groep 1: brain-to-LLM (brein eerst)**
- **Groep 2: LLM-to-brain (LLM eerst)**
- ***Kan je iets citeren uit jouw tekst?***



Your Brain on ChatGPT: Accumulation of Cognitive Debt when Using an AI Assistant for Essay Writing Task△

Nataliya Kosmyna [1]
MIT Media Lab
Cambridge, MA

Eugene Hauptmann
MIT
Cambridge, MA

Ye Tong Yuan
Wellesley College
Wellesley, MA

Jessica Situ
MIT
Cambridge, MA

Xian-Hao Liao
Mass. College of Art and Design (MassArt)
Boston, MA

Ashly Vivian Beresnitzky
MIT
Cambridge, MA

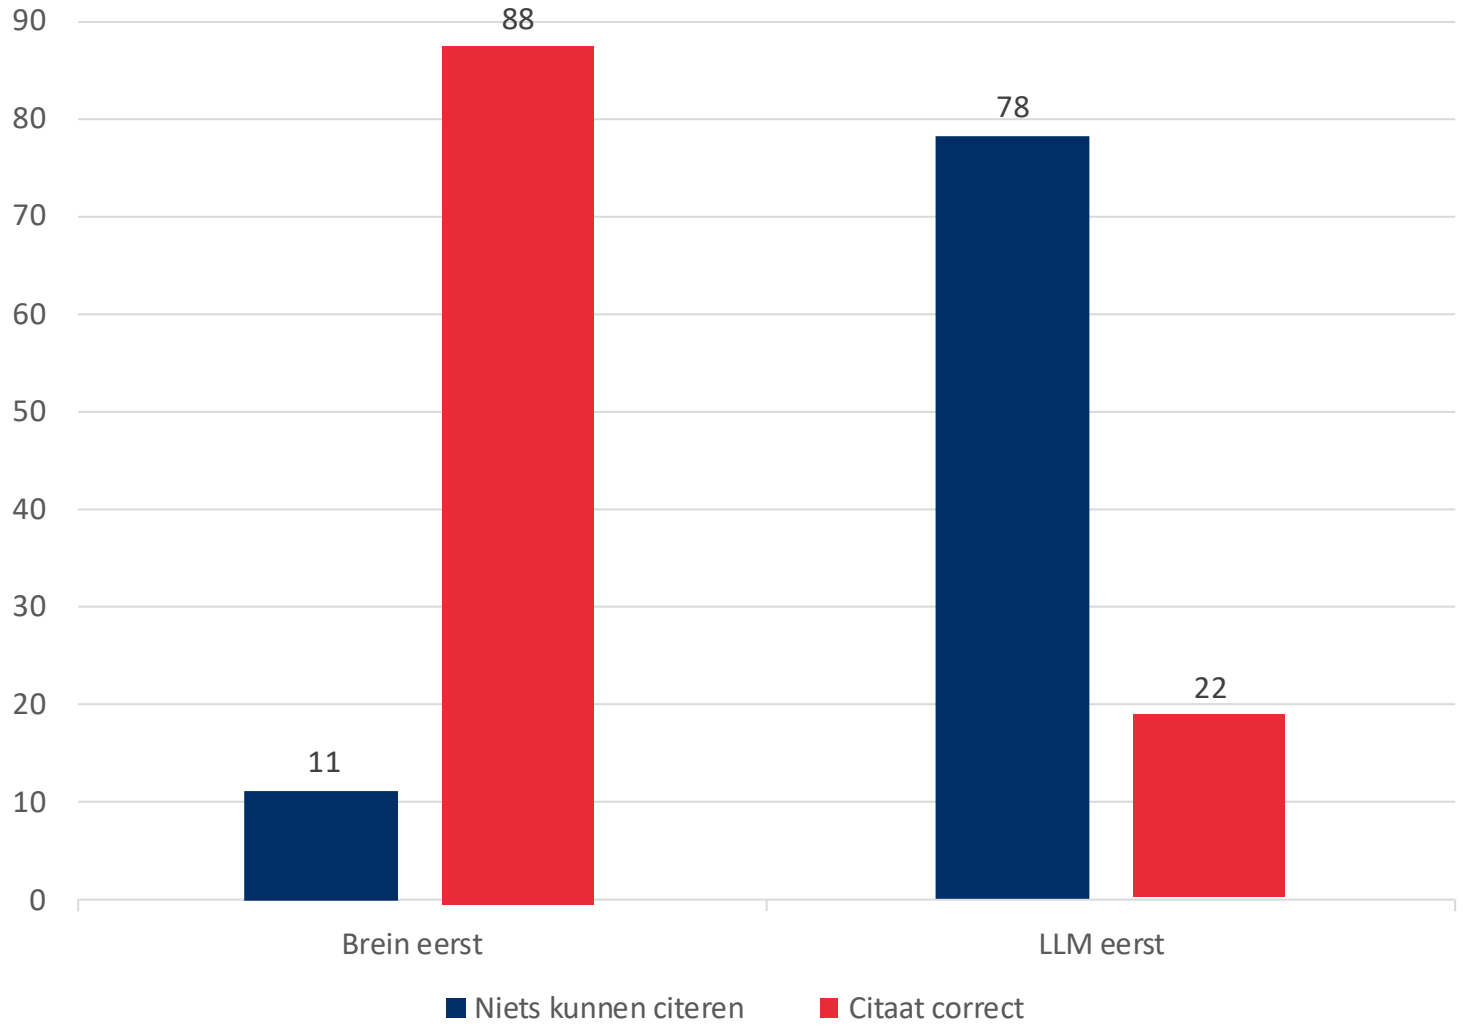
Iris Braunstein
MIT
Cambridge, MA

Pattie Maes
MIT Media Lab
Cambridge, MA

United States

Creëren met AI

- **Schrijftaak**
- **Groep 1: brain-to-LLM (brein eerst)**
- **Groep 2: LLM-to-brain (LLM eerst)**
- ***Kan je iets citeren uit jouw tekst?***



Creëren met AI

- **Schrijftaak**
- **Groep 1: brain-to-LLM (brein eerst)**
- **Groep 2: LLM-to-brain (LLM eerst)**
- ***Kan je iets citeren uit jouw tekst?***
- **Hersenscans**

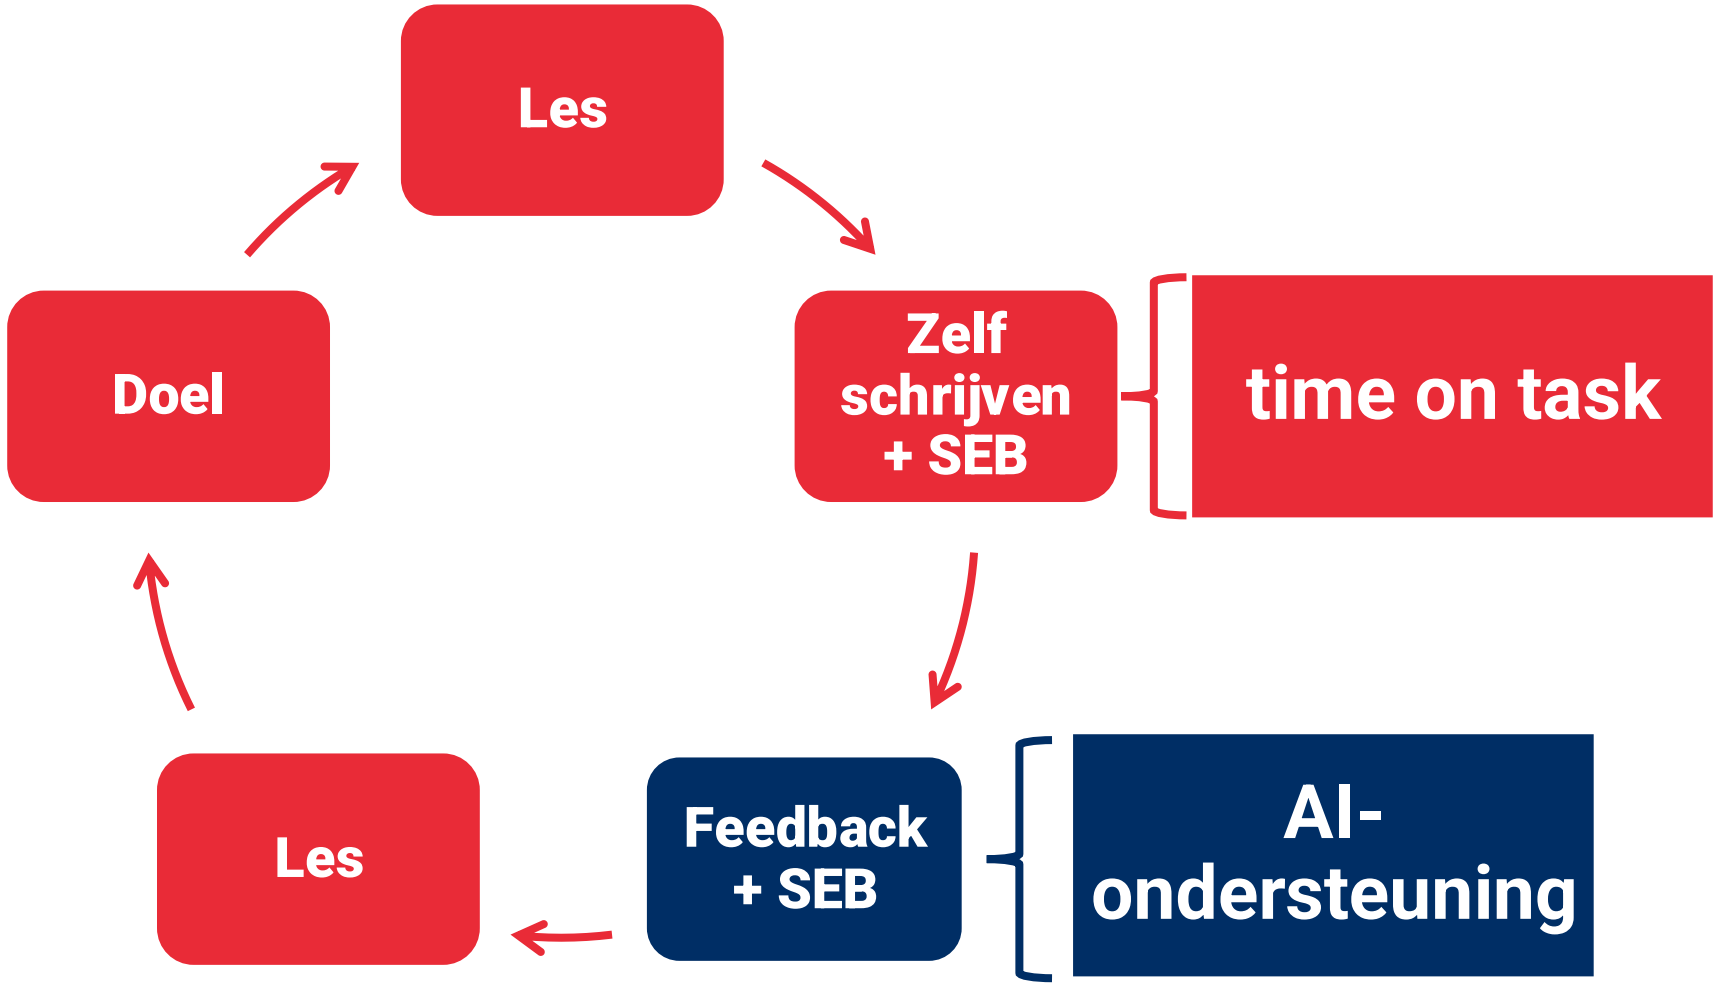
→

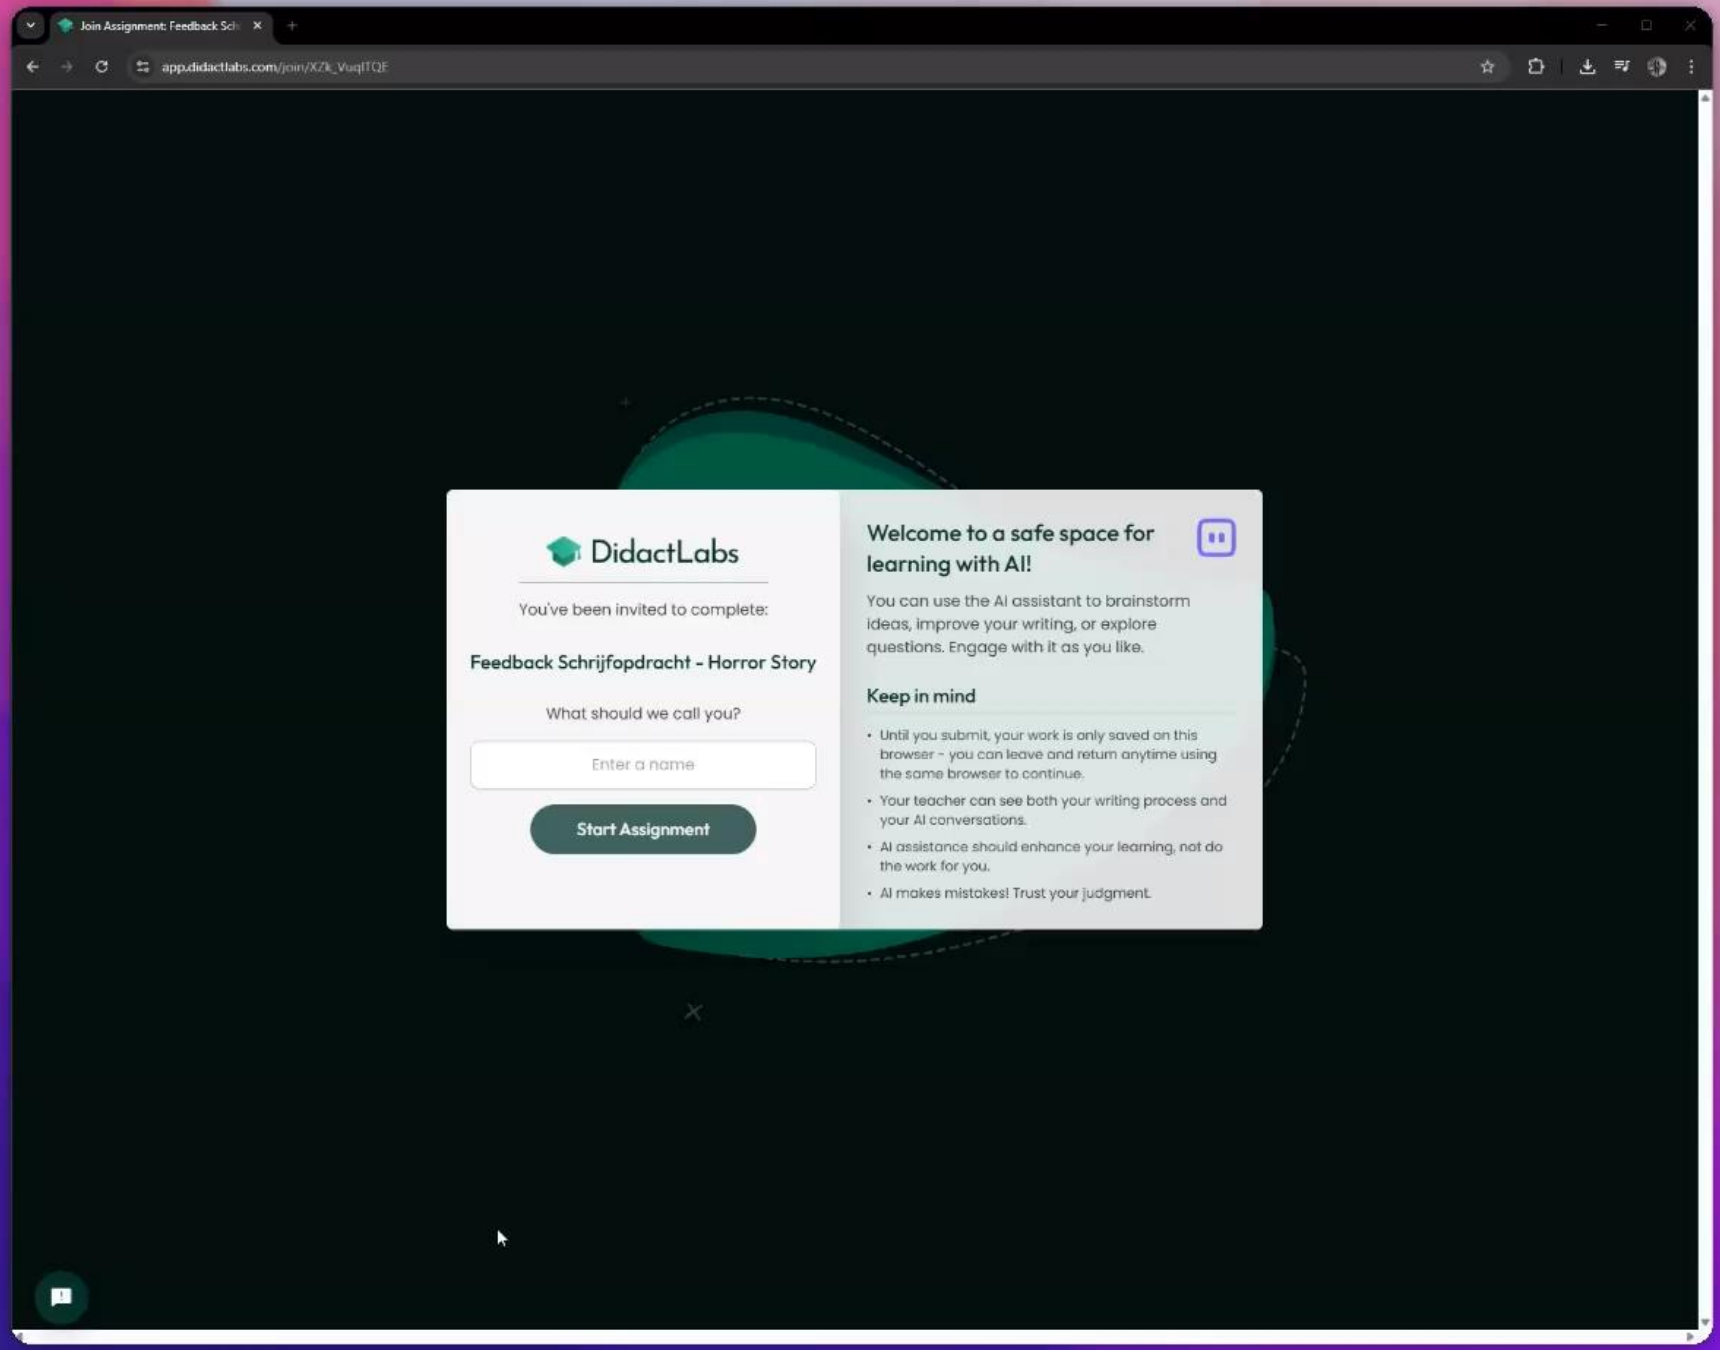
- **Sterkere verbindingen**
- **Dieper creatief process**

→

- **Verminderde verbindingen**
- **Voelt eenvoudiger**

Creëren met AI




Join Assignment: Feedback Sch
app.didactlabs.com/join/XZk_VuqITQE
DidactLabs
You've been invited to complete:
Feedback Schrijfopdracht - Horror Story
What should we call you?
Enter a name
Start Assignment
Welcome to a safe space for learning with AI!
You can use the AI assistant to brainstorm ideas, improve your writing, or explore questions. Engage with it as you like.
Keep in mind
Until you submit, your work is only saved on this browser - you can leave and return anytime using the same browser to continue.
Your teacher can see both your writing process and your AI conversations.
AI assistance should enhance your learning, not do the work for you.
AI makes mistakes! Trust your judgment.

In 1989 my whole life changed. It happened in my senior year of high school. On the evening of our graduation, we had an after party with my classmates and our mentor. It was supposed to be the best party ever, but it ended in a nightmare ... Four years of high school torture were finally over, four years of misabele classes, uninspiring teachers and classes riddled with bullies and mean girls, or so I thought. "Finally!" I woke up, a scream catching in my throat. I opened the curtains; the sun blazed onto my face. This was it: the best day of my life.

It was already 8 am, so I rushed downstairs, skipped breakfast, and quickly brushed my teeth before I left. "My best friend was already honking, so I knew I'd need to hurry. Once we arrived at school, we ran to class. We couldn't be late for our last day of school!

11 o 'clock in the morning and the final bell rang through the hallways I'd never walk through again, its echo lingering a moment too long, like a mournful sigh. Gretchen and I went to the restrooms one last time, the last time gossiping with our other friends. "Dang, I'm really going to miss this", I say to myself, "but tonight will be the last goodbye." The words felt somehow heavier than they should have, like a promise I didn't understand.

4 pm: All the girls came to my house and now we were all getting ready for the biggest moment of our life: The Graduation. Everyone was already there when we arrived. The room was decorated beautifully and each one looked gorgeous. After all the names were said, we all throw our graduation hat into the air and some of us even cried, because this was really the end of an era.

At 10 pm the after-party started. Every student of our class was invited, even our mentor. When we arrived, we saw drinks and food everywhere. There was also a pool and super loud music. I grabbed a cup of punch, but the first sip tasted strangely metallic, like old pennies, or something worse. I shrugged it off, blaming the cheap ingredients.

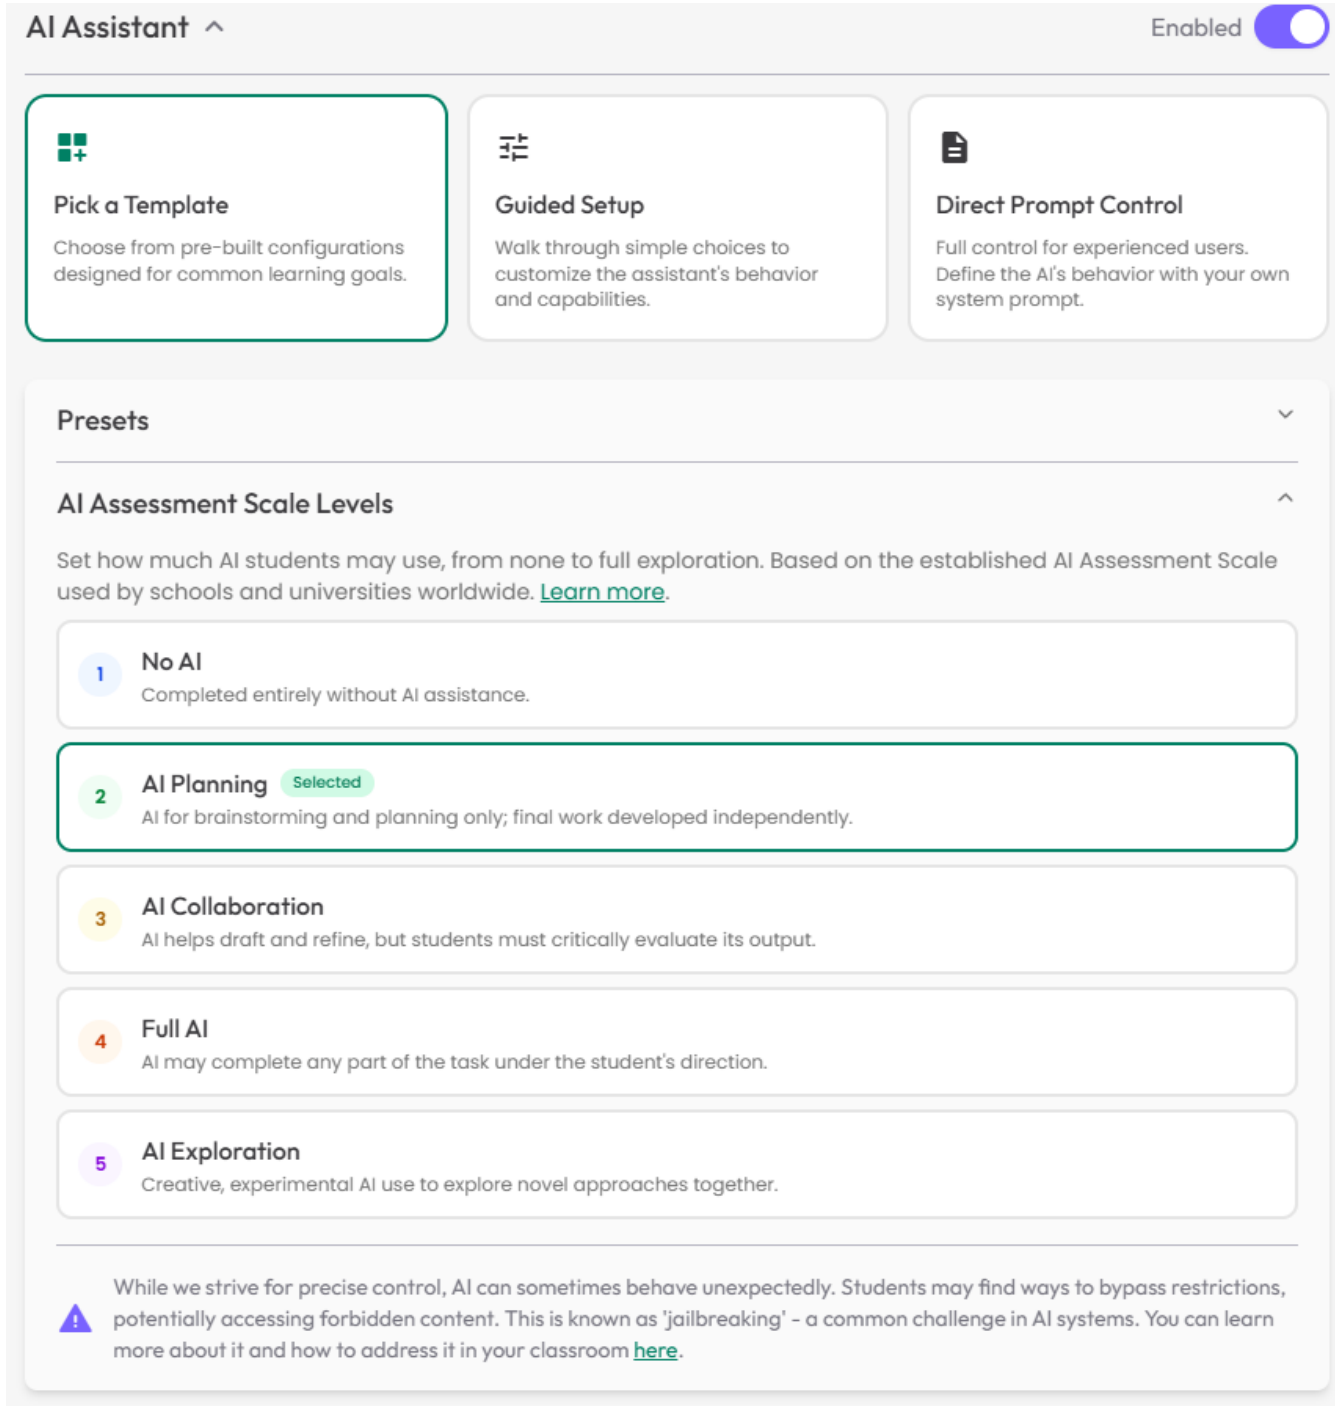
It was 11 pm; the party was insane. Everyone was having a great time, and most people were already drunk and dancing on the dance floor, even the mentor.

11"11:30: the teacher was acting strange, too strange; something wasn't right. He stood all alone in the corner of the room; it looked like he was talking to the wall, eventually even punching it, but everyone was dancing so only I saw it. I went to Gretchen to tell her; she looked at me strangely, as if she hadn't heard, or perhaps was too drunk to care, and she started to dance again.

11:45: I was getting some drinks for me and my friends. I look back to the corner to see if the counsellor is still standing there but he is gone. I start to look around the whole building, but no sign of him until I saw him with a few people in the restrooms, holding something strange. I went back to Gretchen to tell her for the

DidactLabs

- **Slechts één voorbeeld**
- **Neg. Offloading afremmen**
- **Beperkte tutor**
- **Op één punt leerproces**
- **GDPR & VLAIO**
- **OPDRACHT**



Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

Waarom deze aanpak?

- Copy-paste is géén leerstrategie
- Plaats in leerproces
- Vermijd cog. offloaden
- Scaffold
  - Bewust
  - Doelgericht
  - Tutors

Hoe ondersteunen we ons team?

AI IN DE KLAS

Deel 3: Schoolbeleid zonder AIAIAI

Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs

Rode Draad

- Focus schoolteam
- Groeipad (UNESCO)
- Handvat bij lesontwerp
  - Waar ondersteuning
  - Wat is belangrijk?
- Handvat bij ethisch gebruik



AI-geletterdheid naar leerlijn

- **Toewerken naar AI-geletterdheid**
- **Binnen schoolteam**
- **Drie niveaus**
- **Vijf aspecten**
- **Groeipad!**



AI IN DE LERARENKAMER

Professionalisering – geletterdheid als team

Aspecten	Progressieniveau		
	1 - Theorie	2 - Toegepaste Theorie	3 – Creëren
Antropocentrisch perspectief	Menselijk handelen	Menselijke verantwoordelijkheid	Sociale verantwoordelijkheid
Ethiek & AI	Ethische principes	Veilig en verantwoord gebruik	Samen ethische regels opstellen
Fundamenten en toepassingen van AI	Basis AI-technieken en toepassingen	Vaardigheden in AI toepassen	Creëren met AI
Pedagogie en AI	AI-ondersteund onderwijs	Integratie van AI-pedagogie	AI-ondersteunde pedagogische toepassingen
AI voor professionele ontwikkeling	AI voor levenslang leren en professionaliseren	AI om onderwijsorganisatie te ondersteunen	AI om professionele transformatie te ondersteunen.
	Alle leerkrachten	Groep leerkrachten	Groepje leerkrachten

Detectie

GPT detectors are biased against non-native English writers

Weixin Liang[1*], Mert Yuksekgonul[1*], Yining Mao[2*], Eric Wu[2*], and James Zou[1,2,3,+]

[1]Department of Computer Science, Stanford University, Stanford, CA, USA
[2]Department of Electrical Engineering, Stanford University, Stanford, CA, USA
[3]Department of Biomedical Data Science, Stanford University, Stanford, CA, USA
[+]Correspondence should be addressed to: jamesz@stanford.edu
[*]these authors contributed equally to this work

ABSTRACT

The rapid adoption of generative language models has brought about substantial advancements in digital communication, while simultaneously raising concerns regarding the potential misuse of AI-generated content. Although numerous detection methods have been proposed to differentiate between AI and human-generated content, the fairness and robustness of these detectors remain underexplored. In this study, we evaluate the performance of several widely-used GPT detectors using writing samples from native and non-native English writers. Our findings reveal that these detectors consistently misclassify non-native English writing samples as AI-generated, whereas native writing samples are accurately identified. Furthermore, we demonstrate that simple prompting strategies can not only mitigate this bias but also effectively bypass GPT detectors, suggesting that GPT detectors may unintentionally penalize writers with constrained linguistic expressions. Our results call for a broader conversation about the ethical implications of deploying ChatGPT content detectors and caution against their use in evaluative or educational settings, particularly when they may inadvertently penalize or exclude non-native English speakers from the global discourse. The published version of this study can be accessed at: www.cell.com/patterns/fulltext/S2666-3899(23)00130-7

Introduction

Generative language models based on GPT, such as ChatGPT[1], have taken the world by storm. Within a mere two months of its launch, ChatGPT attracted over 100 million monthly active users, making it one of the fastest-growing consumer internet applications in history[2,3]. While these powerful models offer immense potential for enhancing productivity and creativity[4–6], they also introduce the risk of AI-generated content being passed off as human-written, which may lead to potential harms, such as the spread of fake content and exam cheating[7–11].

Recent studies reveal the challenges humans face in detecting AI-generated content, emphasizing the urgent need for effective detection methods[7–9,12]. Although several publicly available GPT detectors have been developed to mitigate the risks associated with AI-generated content, their effectiveness and reliability remain uncertain due to limited evaluation[13–21]. This lack of understanding is particularly concerning given the potentially damaging consequences of misidentifying human-written content as AI-generated, especially in educational settings[22,23].

Given the transformative impact of generative language models and the potential risks associated with their misuse, developing trustworthy and accurate detection methods is crucial. In this study, we evaluate several publicly available GPT detectors on writing samples from native and non-native English writers. We uncover a concerning pattern: GPT detectors consistently misclassify non-native English writing samples as AI-generated while not making the same mistakes for native writing samples. Further investigation reveals that simply prompting GPT to generate more linguistically diverse versions of the non-native samples effectively removes this bias, suggesting that GPT detectors may inadvertently penalize writers with limited linguistic expressions.

Our findings emphasize the need for increased focus on the fairness and robustness of GPT detectors, as overlooking their biases may lead to unintended consequences, such as the marginalization of non-native speakers in evaluative or educational settings. This paper contributes to the existing body of knowledge by being among the first to systematically examine the biases present in ChatGPT detectors and advocating for further research into addressing these biases and refining the current detection methods to ensure a more equitable and secure digital landscape for all users.

Can AI-Generated Text be Reliably Detected?

Vinu Sankar Sadasivan vinu@umd.edu
Department of Computer Science, University of Maryland

Aounon Kumar aounon@umd.edu
Department of Computer Science, University of Maryland

Sriram Balasubramanian sriramb@umd.edu
Department of Computer Science, University of Maryland

Wenxiao Wang wwx@umd.edu
Department of Computer Science, University of Maryland

Soheil Feizi sfeizi@umd.edu
Department of Computer Science, University of Maryland

Abstract

The rapid progress of Large Language Models (LLMs) has made them capable of performing astonishingly well on various tasks, including document completion and question answering. The unregulated use of these models, however, can potentially lead to malicious consequences such as plagiarism, generating fake news, spamming, etc. Therefore, reliable detection of AI-generated text can be critical to ensure the responsible use of LLMs. Recent works attempt to tackle this problem either using certain model signatures present in the generated text outputs or by applying watermarking techniques that imprint specific patterns onto them. In this paper, we show that these detectors are not reliable in practical scenarios. In particular, we develop a *recursive paraphrasing* attack to apply on AI text, which can break a whole range of detectors, including the ones using the watermarking schemes as well as neural network-based detectors, zero-shot classifiers, and retrieval-based detectors. Our experiments include passages around 300 tokens in length, showing the sensitivity of the detectors even in the case of relatively long passages. We also observe that our *recursive paraphrasing* only degrades text quality slightly, measured via human studies, and metrics such as perplexity scores and accuracy on text benchmarks. Additionally, we show that even LLMs protected by watermarking schemes can be vulnerable against spoofing attacks aimed to mislead detectors to classify human-written text as AI-generated, potentially causing reputational damages to the developers. In particular, we show that an adversary can infer hidden AI text signatures of the LLM outputs without having white-box access to the detection method. Finally, we provide a theoretical connection between the AUROC of the best possible detector and the Total Variation distance between human and AI text distributions that can be used to study the fundamental hardness of the reliable detection problem for advanced language models. Our code is publicly available at https://github.com/vinusankars/Reliability-of-AI-text-detectors.

1 Introduction

Artificial Intelligence (AI) has made tremendous advances in recent years, from generative models in computer vision (Rombach et al., 2022; Saharia et al., 2022) to generative models in natural language processing (NLP) (Brown et al., 2020; Zhang et al., 2022; Raffel et al., 2019). Large Language Models (LLMs) can now generate texts of supreme quality with the potential in many applications. For example, the recent model of ChatGPT (OpenAI, 2022) can generate human-like texts for various tasks such as writing codes for computer

Perkins et al. Int J Educ Technol High Educ (2024) 21:53
https://doi.org/10.1186/s41239-024-00487-w

International Journal of Educational Technology in Higher Education

RESEARCH ARTICLE Open Access

Simple techniques to bypass GenAI text detectors: implications for inclusive education

Mike Perkins[1*], Jasper Roe[2], Binh H. Vu[1], Darius Postma[1], Don Hickerson[1], James McGaughran[1] and Huy Q. Khuat[1]

*Correspondence:
Mike.p@buv.edu.vn
[1] British University Vietnam, Hanoi, Vietnam
[2] James Cook University Singapore, Singapore, Singapore

Abstract

This study investigates the efficacy of six major Generative AI (GenAI) text detectors when confronted with machine-generated content modified to evade detection (n = 805). We compare these detectors to assess their reliability in identifying AI-generated text in educational settings, where they are increasingly used to address academic integrity concerns. Results show significant reductions in detector accuracy (17.4%) when faced with simple techniques to manipulate the AI generated content. The varying performances of GenAI tools and detectors indicate they cannot currently be recommended for determining academic integrity violations due to accuracy limitations and the potential for false accusation which undermines inclusive and fair assessment practices. However, these tools may support learning and academic integrity when used non-punitively. This study aims to guide educators and institutions in the critical implementation of AI text detectors in higher education, highlighting the importance of exploring alternatives to maintain inclusivity in the face of emerging technologies.

Keywords: Generative artificial intelligence, Adversarial techniques, Academic integrity, Higher education, AI text detectors

Introduction

Recent developments in Artificial Intelligence (AI) have led to paradigm-shifting applications and technologies which have significantly impacted multiple aspects of society. The 'AI Spring' (Manyika & Bughin, 2019) of the early 2020s and its ongoing consequences have already garnered a great deal of attention in academia and education in a short span of time. At the time of writing, AI is receiving greater adoption both formally and informally among students and teachers and has become a 'hot topic' (Cotton et al., 2023), of which our understanding is only just beginning. Generative AI (GenAI) tools, that is, those which produce an output of some form in response to user input, whether text, audio, image, or video, have attracted the most attention in this area. Despite many proclaiming the potential benefits of these tools in aiding learning, GenAI also presents several risks, including equity and inclusion in education. For example, students and scholars with access to paid GenAI tools may reap more benefits than those who cannot afford subscription fees, thus impacting educational equity. Furthermore, punitive

Springer Open

© The Author(s) 2024. **Open Access** This article is licensed under a Creative Commons Attribution 4.0 International License, which permits use, sharing, adaptation, distribution and reproduction in any medium or format, as long as you give appropriate credit to the original author(s) and the source, provide a link to the Creative Commons licence, and indicate if changes were made. The images or other third party material in this article are included in the article's Creative Commons licence, unless indicated otherwise in a credit line to the material. If material is not included in the article's Creative Commons licence and your intended use is not permitted by statutory regulation or exceeds the permitted use, you will need to obtain permission directly from the copyright holder. To view a copy of this licence, visit http://creativecommons.org/licenses/by/4.0/.

Detectie

- **Onbetrouwbaar**
  - **Aanpassingen**
  - **Toekomstgericht**
- **Vooroordelen**
- **Ethisch**



English

Can AI-Generated Text be Reliably Detected?

Vinu Sankar Sadasivan vinu@umd.edu
Department of Computer Science, University of Maryland

Aounon Kumar aounon@umd.edu
Department of Computer Science, University of Maryland

Sriram Balasubramanian sriramb@umd.edu
Department of Computer Science, University of Maryland

Wenxiao Wang wwx@umd.edu
Department of Computer Science, University of Maryland

Soheil Feizi sfeizi@umd.edu
Department of Computer Science, University of Maryland

Abstract

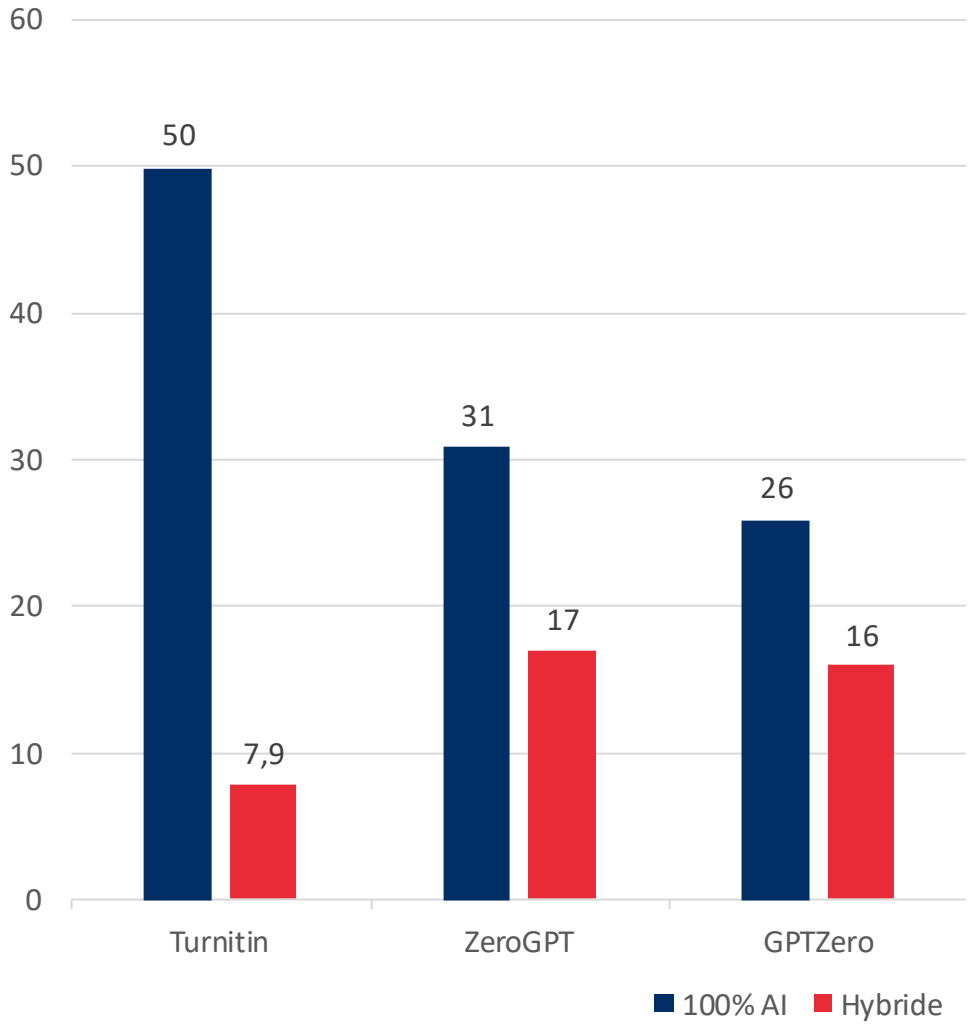
The rapid progress of Large Language Models (LLMs) has made them capable of performing astonishingly well on various tasks, including document completion and question answering. The unregulated use of these models, however, can potentially lead to malicious consequences such as plagiarism, generating fake news, spamming, etc. Therefore, reliable detection of AI-generated text can be critical to ensure the responsible use of LLMs. Recent works attempt to tackle this problem either using certain model signatures present in the generated text outputs or by applying watermarking techniques that imprint specific patterns onto them. In this paper, we show that these detectors are not reliable in practical scenarios. In particular, we develop a *recursive paraphrasing* attack to apply on AI text, which can break a whole range of detectors, including the ones using the watermarking schemes as well as neural network-based detectors, zero-shot classifiers, and retrieval-based detectors. Our experiments include passages around 300 tokens in length, showing the sensitivity of the detectors even in the case of relatively long passages. We also observe that our *recursive paraphrasing* only degrades text quality slightly, measured via human studies, and metrics such as perplexity scores and accuracy on text benchmarks. Additionally, we show that even LLMs protected by watermarking schemes can be vulnerable against spoofing attacks aimed to mislead detectors to classify human-written text as AI-generated, potentially causing reputational damages to the developers. In particular, we show that an adversary can infer hidden AI text signatures of the LLM outputs without having white-box access to the detection method. Finally, we provide a theoretical connection between the AUROC of the best possible detector and the Total Variation distance between human and AI text distributions that can be used to study the fundamental hardness of the reliable detection problem for advanced language models. Our code is publicly available at https://github.com/vinusankars/Reliability-of-AI-text-detectors.

1 Introduction

Artificial Intelligence (AI) has made tremendous advances in recent years, from generative models in computer vision (Rombach et al., 2022; Saharia et al., 2022) to generative models in natural language processing (NLP) (Brown et al., 2020; Zhang et al., 2022; Raffel et al., 2019). Large Language Models (LLMs) can now generate texts of supreme quality with the potential in many applications. For example, the recent model of ChatGPT (OpenAI, 2022) can generate human-like texts for various tasks such as writing codes for computer

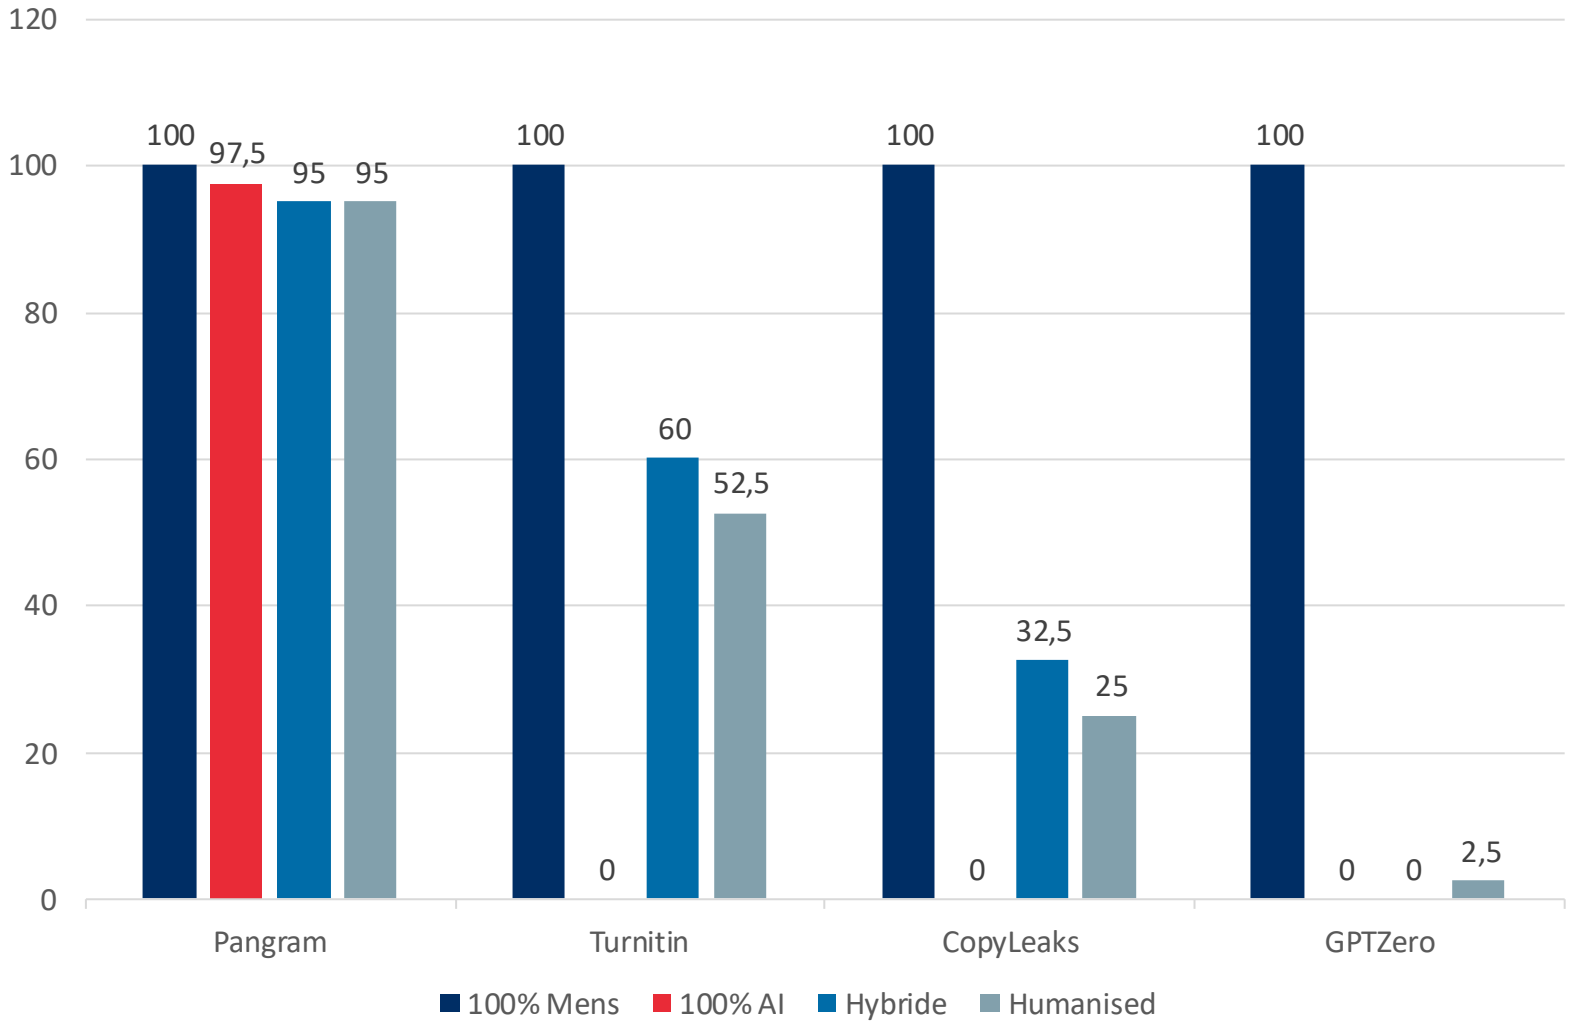
Detectie 2023

- 3 bekende tools
- Niet-aangepaste AI-tekst
- Aangepaste AI-tekst
- Gemiddeld



Detectie 2026 (VUB)

- 4 bekende tools
- 100% mens
- 100% AI-tekst
- Hybride
- Humanised AI-tekst
- OPDRACHT




21
22
23
24
25

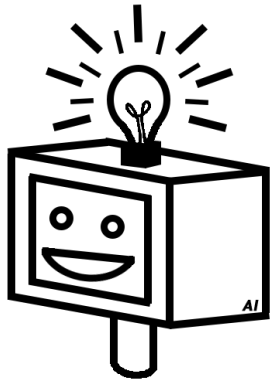
Handvat bij opdrachten

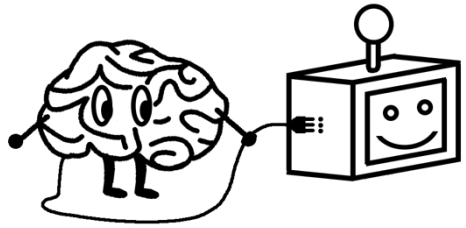
- **Handvat bij ontwerp**
- **Geen waardeoordeel**
- **Vertrekken vanuit de vakdoelen**
- **Validiteit als gids**
- **Doelen boven tools!**

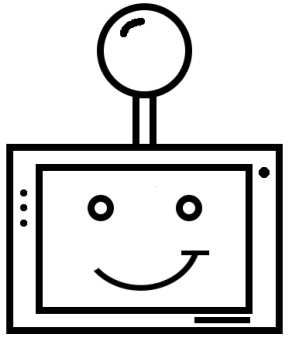


Handvat bij opdrachten

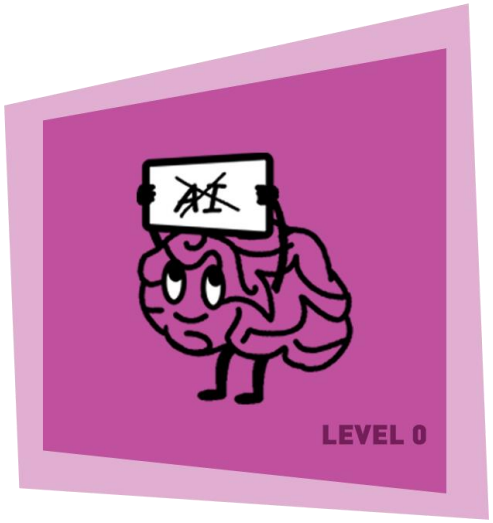


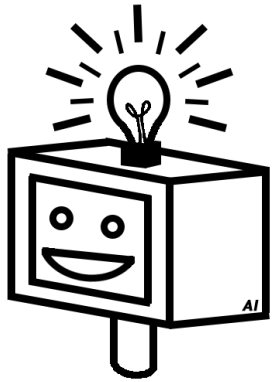


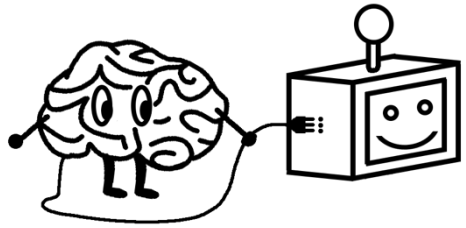


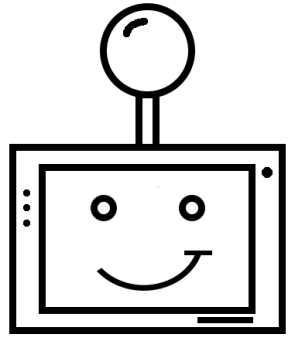


Level 0 – Geen AI

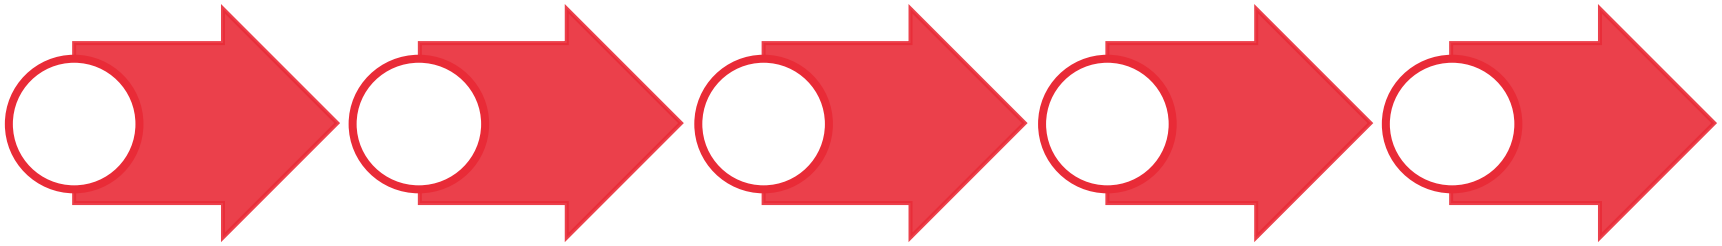








Level 0 – Geen AI (workflow)

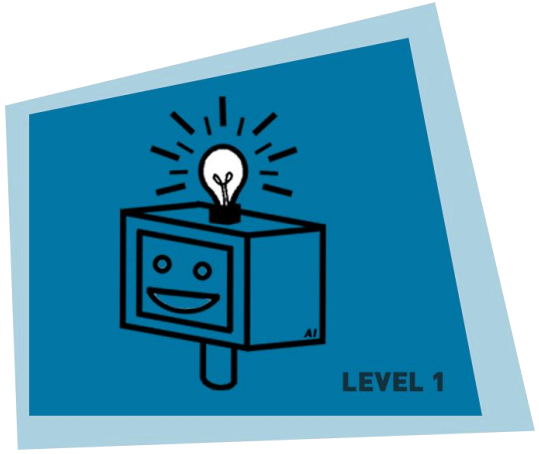


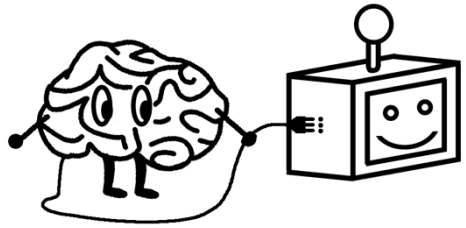
- Leerling
- Leerling & AI

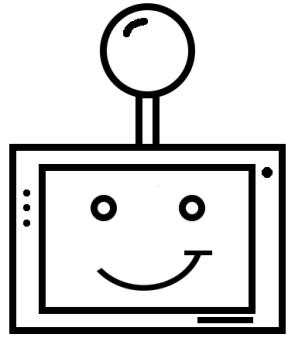


Level 1 - Planning

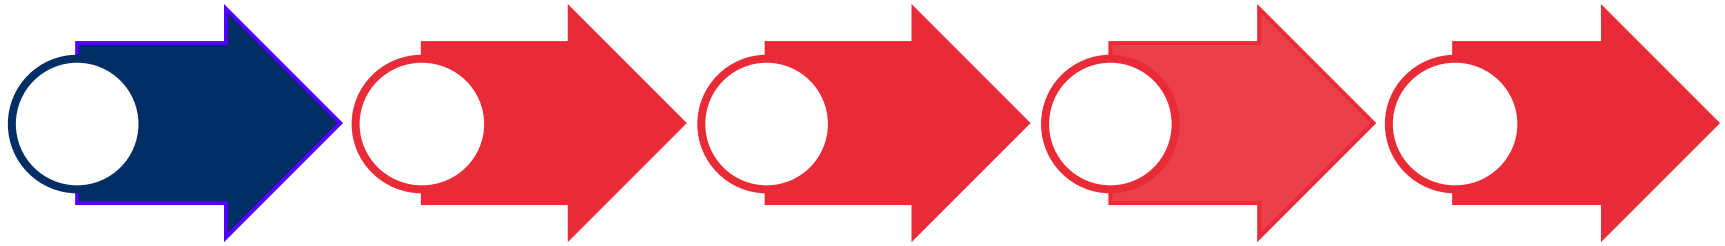




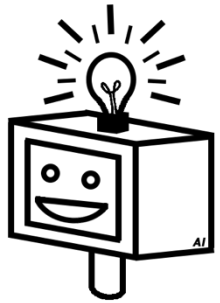




Level 1 – Planning (workflow)

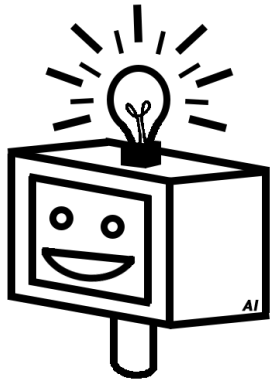


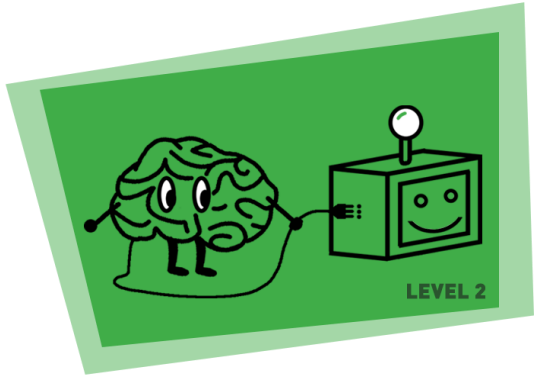
- Leerling
- Leerling & AI

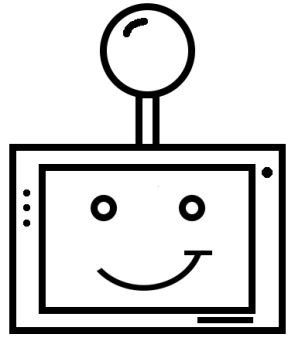


Level 2 – Samenwerken

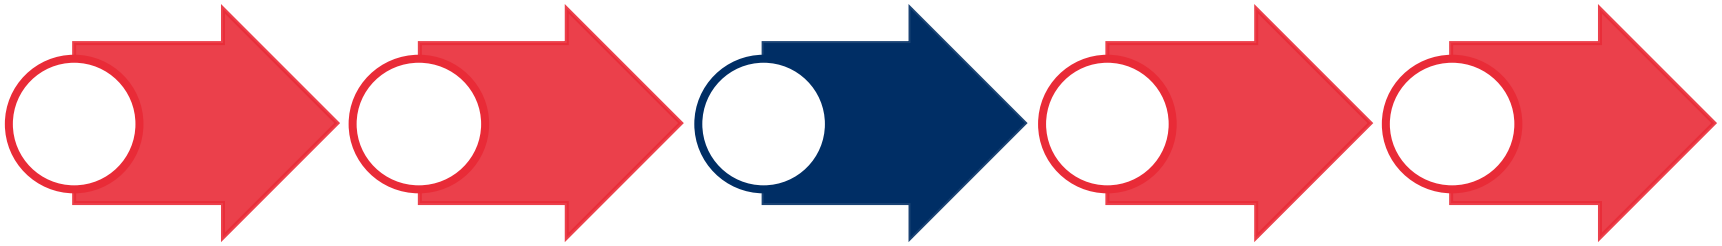




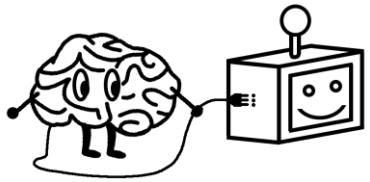




Level 2 – Samenwerken (workflow)

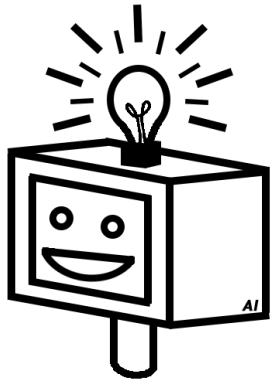


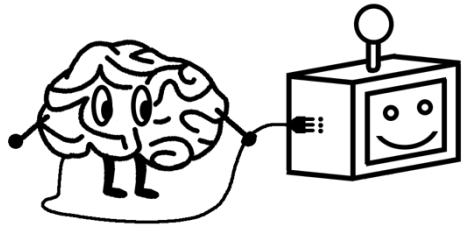
- Leerling
- Leerling & AI



Level 3 – AI zonder beperkingen

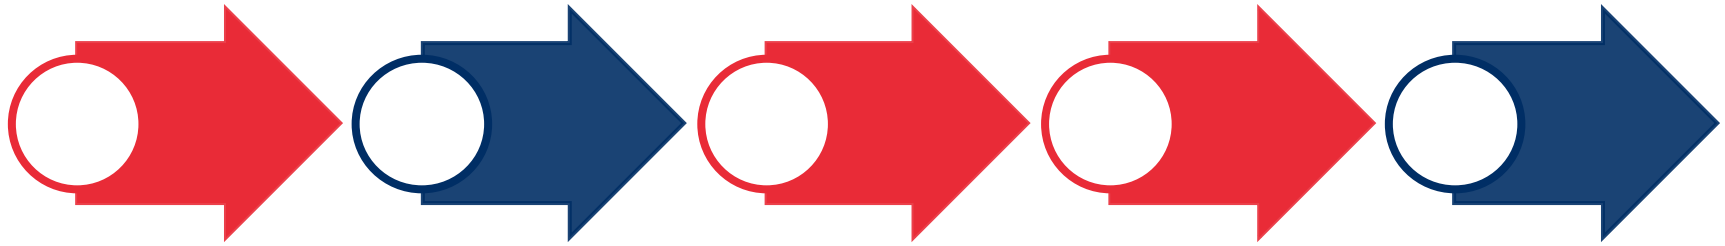




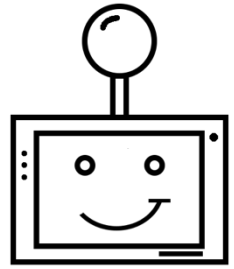




Level 3 – AI zonder beperkingen (flow)



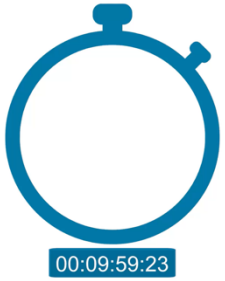
- Leerling
- Leerling & AI

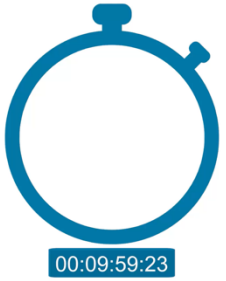


Handvat bij opdrachten

Level	Categorie	Duiding
0	Geen AI	Je mag op geen enkel moment tijdens de opdracht AI gebruiken. Je moet je kernvaardigheden en kennis aantonen.
1	Planning	Je mag AI gebruiken voor planning, ideevorming en onderzoek. Jouw eindopdracht moet laten zien hoe je deze ideeën verder hebt ontwikkeld en verfijnd. Jouw verwerking staat centraal!
2	Samenwerken	Je mag AI gebruiken om specifieke taken te ondersteunen, zoals het gericht herschrijven van jouw tekst. Je moet AI-gegenereerde inhoud altijd kritisch evalueren en aanpassen. Blijf eigenaar van jouw eigen werk!
3	AI zonder beperking	Je mag AI uitgebreid gebruiken gedurende je werk zoals je wilt of zoals specifiek wordt voorgeschreven in de evaluatie. Richt je op het aansturen van AI om je doelen te bereiken. Wees kritisch en toon jouw voorkennis!
4	Creatief aan de slag	Je moet AI creatief gebruiken om de taak op te lossen, waarbij je mogelijk nieuwe benaderingen samen ontwerpt met jouw leerkracht.

INTERVISIE





Level	Categorie	Duiding
0	Geen AI	Je mag op geen enkel moment tijdens de toets AI gebruiken. Je moet je kernvaardigheden en kennis aantonen.
1	Planning	Je mag AI gebruiken voor planning, ideevorming en onderzoek. Jouw eindopdracht moet laten zien hoe je deze ideeën verder hebt ontwikkeld en verfijnd. Jouw verwerking staat centraal!
2	Samenwerken	Je mag AI gebruiken om specifieke taken te ondersteunen, zoals het gericht herschrijven van jouw tekst. Je moet AI-gegenereerde inhoud altijd kritisch evalueren en aanpassen. Blijf eigenaar van jouw eigen werk!
3	AI zonder beperking	Je mag AI uitgebreid gebruiken gedurende je werk zoals je wilt of zoals specifiek wordt voorgeschreven in de evaluatie. Richt je op het aansturen van AI om je doelen te bereiken. Wees kritisch en toon jouw voorkennis!
4	Creatief aan de slag	Je moet AI creatief gebruiken om de taak op te lossen, waarbij je mogelijk nieuwe benaderingen samen ontwerpt met jouw leerkracht.

Geletterdheid als team

Aspecten	Progressieniveau		
	1 - Theorie	2 - Toegepaste Theorie	3 – Creëren
Antropocentrisch perspectief	Menselijk handelen	Menselijke verantwoordelijkheid	Sociale verantwoordelijkheid
Ethiek & AI	Ethische principes	Veilig en verantwoord gebruik	Samen ethische regels opstellen
Fundamenten en toepassingen van AI	Basis AI-technieken en toepassingen	Vaardigheden in AI toepassen	Creëren met AI
Pedagogie en AI	AI-ondersteund onderwijs	Integratie van AI-pedagogie	AI-ondersteunde pedagogische toepassingen
AI voor professionele ontwikkeling	AI voor levenslang leren en professionaliseren	AI om onderwijsorganisatie te ondersteunen	AI om professionele transformatie te ondersteunen.
	Alle leerkrachten	Groep leerkrachten	Groepje leerkrachten

AI & Taal

COMPETENTIE 1:
Weet dat AI-systemen gebruikt kunnen worden om automatisch digitale inhoud te creëren (bv. teksten, nieuws, essays, tweets, muziek, afbeeldingen) met bestaande digitale inhoud als bron. Dergelijke inhoud kan moeilijk te onderscheiden zijn van menselijke creaties.



Ethiek

- Is het gebruik van AI-stemklonen oké?
- Neutraal +/-
- Voordelig +
- Nadelig -
- 6 x criteria

1. Consent	2. Transparantie	3. Fair
4. Mogelijk misbruik	5. Impact en Risico	6. Privacy

6 criteria

1. **Consent:** is er op voorhand toestemming gevraagd?
2. **Transparantie:** kan luisteraar achterhalen dat het een kloon is?
3. **Fair:** hoe worden bepaalde accenten of groepen benadeeld?
4. **Misbruik:** wat is het ergste dat kan gebeuren en zijn er veiligheidsmaatregelen?
5. **Impact en risico:** als het fout loopt, hoe groot is de schade? Omkeerbaar?
6. **Privacy:** wat gebeurt er met de opnames?

Casus 12 – 100 Dagen Show

Voor een satirisch stuk in de 100-dagenshow maken leerlingen een stemkloon van de directeur.



TAAK:

- Welke criteria zijn van toepassing? (kies 2)
- Gebruik jouw criteria bij argumentatie
- Beoordeel casus: nadelig – neutraal – voordelig

Tip: je kan elk criterium een score geven.

- 0 tot 2
- Maak de som van jouw twee criteria:
  - 0-1: rood
  - 2: onzeker
  - 3 of 4: groen

CRITERIA:

1. **Consent:** is er op voorhand toestemming gevraagd?
2. **Transparantie:** kan luisteraar achterhalen dat het een kloon is?
3. **Fair:** hoe worden bepaalde accenten of groepen benadeeld?
4. **Misbruik:** wat is het ergste dat kan gebeuren en zijn er veiligheidsmaatregelen?
5. **Impact en risico:** als het fout loopt, hoe groot is de schade? Omkeerbaar?
6. **Privacy:** wat gebeurt er met de opnames?

Een leerling met een beperking gebruikt een stemkloon om een mondelinge presentatie te geven.	Leerling maakt stiekem kloon van de directeur. “Morgen geen examen wiskunde” en stuurt rond via Smartschool.	Tijdens een geschiedenisles gebruikt een leerling een AI-video waarin een bekende politicus een opvallende uitspraak doet.	Een leerling moet voor Frans een mondelinge presentatie opnemen. Hij schrijft de tekst zelf, maar gebruikt een stemkloon om de opname met een correcte uitspraak en intonatie te laten inspreken.
Een leerkracht maakt met AI een podcast waarin twee historische figuren de oorzaken van de FR Revolutie bespreken. Leerlingen gebruiken de podcast om zich op een toets voor te bereiden.	Een school introduceert een digitale assistent die vragen van leerlingen en ouders over studierichtingen, examens en schoolregels beantwoordt.	Voor een erfgoedproject maken leerlingen een AI-reconstructie van een overleden oud-leerling die tijdens de 2de Wereldoorlog leefde.	Leerkracht maakt geluidsopnames van eigen lesmateriaal met de eigen stemkloon voor leerlingen.
Tijdens de verkiezingen voor de leerlingenraad verspreidt een kandidaat een geluidsfragment waarin de directeur zijn kandidatuur lijkt te steunen. Het fragment blijkt met AI gemaakt.	Ouders van een leerling met specifieke onderwijsbehoeften zijn ontevreden over de uitvoering van het individueel handelingsplan (IHP) en examens. Ze gebruiken AI om een klacht te schrijven naar de school.	In de chat van de klas post iemand een stemkloon van een klasgenoot door de opname uit de uploadzone te downloaden.	Voor een satirisch stuk in de 100-dagenshow maken leerlingen een stemkloon van de directeur.

Criteria opstellen

1. Ga na wat jouw school belangrijk vindt. Bv. pedagogische pijlers
2. Verzamel casussen
3. Doorloop deze en toets ze aan jullie criteria
4. Zijn er hiaten? Casus waar de aanpak uiteen loopt?
5. Niet volledig futureproof,
   maar zo tuimel je niet van verrassing naar verrassing

Geletterdheid als team

- **OPDRACHT**
- **Waar zit jouw team op dit moment?**
- **Wat loopt goed?**
- **Wat neem jij mee uit deze sessie?**
- **Waar wil jij persoonlijk dit schooljaar op inzetten?**
- **Waar hoop jij dat jouw school op inzet?**

Terugblik

- Kennis in tijden van AI
- AI-geletterdheid
  - AI-technologie als onderwerp
  - AI-technologie als ondersteuning
- AI-beleid

VASTSTELLING

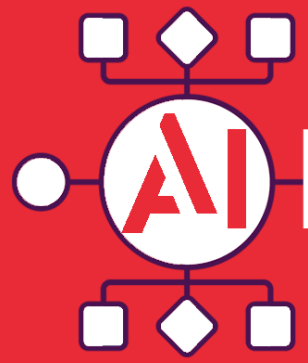
2 PERSPECTIEVEN
OESO COMPETENTIES

WAT NU?

Contact

- Vragen, opmerkingen
- Programmeren,
  AI in de klas…
- Contact?
  robbewulgaert.be
- Vergeet de evaluatie en feedback niet!





AI IN DE KLAS

... any questions / prompts?

Universiteit Antwerpen
CNO | Centrum Nascholing Onderwijs